

Facultad de Ciencias Económicas y Estadística

Universidad Nacional de Rosario

Modelos de probabilidad de gol: evaluación del efecto jugador en la Liga Profesional de Fútbol

Tesina de grado

Alumno: Luchini Matías

Director: Capretto Tomás

Octubre de 2026

Agradecimientos

A la UNR, universidad pública de calidad, y a sus profesores, en especial a Tomi, que me ayudó y acompañó en el armado de este trabajo final.

A mis amigos, los de siempre y los de la facu, los de acá y los de allá. A los de siempre, que están desde antes de que aprendiera siquiera a despejar una incógnita y que, truco y asado mediante, hacen que me olvide de que tengo que saber cómo hacerlo. A los de la facu, que con mates y salidas hicieron parecer que completar una carrera de grado trata solo de eso, de tomar mates y salir de joda. Se puede estudiar solo, pero verdaderamente se aprende cuando te rodeás de gente que te guía y que aprende con vos.

A mi novia, que, aunque quizá no lo acepte, tiene tanto mérito como yo en los resultados de estos años. Más que nada en ese tiempo en que las cosas no fueron del todo sencillas, cuando es más difícil estar al pie del cañón.

A mi familia, que estuvo siempre, ya sea bancando las horas de estudio, escuchando cómo repetía teoría en pandemia o discutiendo sobre el reglamento de algún deporte injunable para descontracturar los momentos de cansancio. Estuvieron para todo y en todo momento.

A mis abuelas, a las que les debo más que a cualquiera.

A todos ellos, loco, gracias.

Contenido

1. Introducción 4
2. Objetivos 7
   2.1. Objetivo general 7
   2.2. Objetivos específicos 7
3. Metodología 8
   3.1. Modelos de xG 8
   3.2. Modelos de regresión logística 12
   3.3. Inferencia Bayesiana 17
   3.4. Cálculo del xG mediante modelos de regresión logística con enfoque bayesiano 25
   3.5. Modelos de regresión logística jerárquicos 29
   3.6. Herramientas para la comparación de modelos 35
4. Materiales 39
   4.1. Fuentes de datos 39
   4.2. Recolección de datos 41
   4.3. Limpieza de la base de datos 44
5. Aplicación 49
   5.1. Modelo 1 49
   5.2. Modelo 2 51
   5.3. Modelo 3 53
   5.4. Comparación de modelos 56
6. Conclusiones 72
7. Anexo 75
8. Bibliografía 82

1. Introducción

Dentro del deporte de alto rendimiento, y como en tantos otros ámbitos con eje central en la competencia y en la toma de decisiones, la estadística y el análisis de datos se han convertido en herramientas fundamentales, casi indispensables (Fujii, 2025). Tal es su importancia dentro de este mercado, que hoy en día resulta difícil concebir un escenario en el que entrenadores, clubes o empresas dedicadas no hagan uso de datos para, entre otras cosas, diagramar entrenamientos, estudiar rivales o detectar potenciales talentos. Muchas instituciones deportivas cuentan con departamentos específicos para sus principales disciplinas que constantemente recopilan y analizan grandes volúmenes de información (NBA Stuffer, s. f.). El avance computacional ha permitido agilizar y amplificar el almacenaje y procesamiento de datos, permitiendo así que tanto protagonistas como periodistas y espectadores puedan contar con información detallada de cada deporte y de cada competencia alrededor del mundo.

Aunque la mayoría de los deportes ya han adoptado la "cultura de los datos" desde hace años para mejorar sus competiciones, en algunos otros esta tendencia es mucho más reciente y parece encontrar cierta resistencia, como ocurre en el fútbol. Mientras que disciplinas como el béisbol, el baloncesto o el automovilismo han incorporado de manera sistemática la evidencia empírica en la preparación de partidos, carreras y para seleccionar deportistas (Catapult, 2024; Landino, 2025; NBAstuffer, s. f.), en el fútbol sigue persistiendo una ideología más tradicional que pone el foco en el ojo de los entrenadores y dirigentes por sobre el análisis de datos. Esta resistencia también se manifiesta en el discurso mediático. Un ejemplo de ello son las declaraciones del exfutbolista Oscar Ruggeri, quien, tras escuchar al entrenador del Futebol Clube do Porto, Martín Anselmi, referirse al uso de métricas y estadísticas en una conferencia de prensa, descalificó dicho enfoque con la expresión "qué quilombo tiene en la cabeza" (ESPN Argentina, 2025).

Los espectadores y consumidores habituales pueden justificar su desconfianza hacia los datos apelando a un mismo argumento: la incertidumbre del fútbol. Una de las principales características que lo diferencia de otras disciplinas es que no siempre gana el que mejor juega, permitiendo que equipos con menos recursos se equiparen a los económicamente más fuertes, nivelando así las competencias. Esto genera en el público la expectativa de que el resultado no esté definido de antemano, transformando en atractivo cualquier encuentro, pero, a su vez, avivando la resistencia antes mencionada frente al uso de datos para la toma de decisiones. Se argumenta que, en un deporte en el que los factores emocionales juegan un papel fundamental y donde el azar es sumamente influyente en el resultado final, las estadísticas no alcanzan para explicar lo que sucede dentro de la cancha. Si bien esta afirmación no se encuentra completamente alejada de la realidad, también es cierto que, si se los usa correctamente, los datos permiten, entre otras cosas, construir modelos que pueden utilizarse para describir la peligrosidad de las jugadas de un partido y, en consecuencia, reducir en parte la incertidumbre referida con antelación.

Sin embargo, es importante resaltar que no todas las ligas del mundo son principiantes en el uso de información como herramienta para la mejora de sus partidos. Muchos clubes han adoptado de manera progresiva el análisis de datos para la gestión deportiva y el entrenamiento, demostrando que la resistencia mencionada no es un obstáculo ineludible (Sport Analytics, 2025). Según Carey (2024), tres de cada cuatro equipos de la máxima categoría del fútbol inglés cuentan con analistas de datos especializados y, en muchos casos, con equipos de trabajo conformados por múltiples profesionales dedicados exclusivamente a esta función. Empresas como Stats Perform, Wyscout o StatsBomb, dedicadas al estudio de partidos y de situaciones de juego, mantienen desde hace años convenios con numerosas ligas a nivel mundial, proveyéndoles datos de cada uno de los encuentros en ellas disputados (Stats Perform, s. f.-a).

En este contexto de creciente profesionalización en el uso de datos a nivel global en este deporte, es pertinente considerar el caso de la Liga Profesional de Fútbol de Argentina. Si bien la utilización de departamentos de análisis en el fútbol argentino es aún incipiente en comparación con las grandes ligas europeas, se comienza a dimensionar un progresivo interés de parte de los clubes en incorporar herramientas de este tipo en la gestión deportiva (Aguirre, 2018; Gantman, 2021; Universidad Nacional de La Plata, 2017). Los datos y métricas de los partidos son utilizados cada vez más por los clubes locales para monitorear y evaluar situaciones de juego, siendo los goles esperados una de las más instaladas dentro de esta industria y una clara prueba de la utilidad de la traducción de datos en peligrosidad.

Los goles esperados, *expected goals* o simplemente xG, constituyen una métrica que busca representar la probabilidad de conversión de cada disparo al arco que se produce en un partido. Para su cálculo se hace uso de modelos estadísticos que estiman la probabilidad de gol en función de un amplio conjunto de factores presuntamente asociados a ella.

Dado que existen muchas variables, medibles o no, que podrían modificar el resultado de un disparo en concreto, cada una de las empresas recolectoras y proveedoras de datos que generan estos modelos se valen de diferentes criterios a la hora de construirlos. Y es aquí donde resulta importante destacar un factor que a priori parece ser sumamente importante para determinar la probabilidad de gol, pero que la mayoría de las veces no es tenido en cuenta en la construcción de los modelos de xG: el jugador que dispara. Esto es, si se consideran dos disparos al arco ejecutados bajo las mismas condiciones, pero por dos jugadores diferentes, los modelos le asignan la misma probabilidad a cada uno de ellos. Sin embargo, es sabido que en todas las competiciones hay jugadores que, ya sea por su habilidad o por el buen momento que atraviesan, obtienen mejores resultados en las distintas situaciones de los partidos, por lo que estos modelos tradicionales no lograrán capturar dichas diferencias individuales en la ejecución de los disparos. Si bien existen motivos válidos por los cuales las empresas suelen no considerar al jugador como un factor en sus modelos, muchas veces su inclusión puede generar mejoras significativas en los resultados a los que se arriba (Scholtes & Karakuş, 2024), alcanzando una mayor precisión a la hora de determinar la relevancia de cada situación de un partido.

El objetivo central de esta tesina consiste en estudiar en profundidad el funcionamiento de los modelos de probabilidad de gol aplicados a los tiros al arco realizados en la Liga Profesional de Fútbol de Argentina. Así, se intenta determinar qué tan pertinente resulta incorporar información específica sobre el jugador que realiza cada uno de los disparos, analizando si existen futbolistas en el ámbito local que se distingan del resto, ya sea por obtener sistemáticamente mejores resultados o, por el contrario, por presentar desempeños por debajo de lo esperado. Además, se estudia si es adecuado incorporar la posición en la que se desempeña cada uno de los futbolistas que dispara, variable con un menor número de categorías y, por ende, con una mayor cantidad de observaciones en cada una de ellas, permitiendo así estimar sus efectos con una mayor precisión.

El presente trabajo se organiza en ocho secciones, incluidas esta sección introductoria, una instancia con la bibliografía consultada y un anexo. En primer lugar, se detallan los objetivos tanto generales como específicos, seguidos de una sección que presenta la metodología implementada, con una revisión de los modelos de xG y con apartados dedicados a la inferencia bayesiana y a los modelos de regresión logística jerárquicos. Posteriormente, en la sección de materiales se explican las fuentes de datos utilizadas, el proceso de recolección mediante técnicas de *web scraping* y los procedimientos de filtrado y procesamiento, así como la descripción de las variables empleadas. Los resultados obtenidos se organizan en torno a la presentación de modelos ajustados con diferentes predictores y a su posterior comparación. Por último, se exponen conclusiones y consideraciones finales. De esta manera, la presente

investigación pretende ofrecer un aporte tanto al conocimiento académico como a la práctica del análisis de datos en el fútbol argentino.

2. Objetivos

2.1. Objetivo general

La presente tesina tiene como objetivo principal construir y analizar modelos de probabilidad de gol, como los utilizados por empresas proveedoras de datos en la industria del fútbol, tomando como base los datos de la Liga Profesional de Fútbol de Argentina. Se busca, además, comprobar la pertinencia de incorporar un efecto asociado al jugador que dispara y a la posición en el campo de juego en la que este se desempeña.

2.2. Objetivos específicos

- Estudiar en detalle los modelos de probabilidad de gol utilizados en la industria del fútbol, haciendo énfasis en cómo se construyen, los motivos de su utilización, sus principales aplicaciones, limitaciones y en las fuentes de datos empleadas para su entrenamiento.
- Comprender las decisiones de modelado que adoptan las empresas proveedoras de datos, en particular la habitual omisión de efectos asociados al jugador que ejecuta el disparo.
- Determinar si existen futbolistas en el ámbito local que se distinguen significativamente del resto, sea positiva o negativamente, en términos de su capacidad de convertir disparos en gol.
- Evaluar si los modelos propuestos alcanzan resultados comparables a los reportados por las empresas proveedoras que hacen uso de un mayor número de variables.

3. Metodología

3.1. Modelos de xG

A diferencia de otros deportes, el fútbol presenta una particularidad que lo vuelve sumamente atractivo para los espectadores: no siempre gana el mejor. Antes de comenzar cada partido, las individualidades, el momento actual de cada equipo o su historial pueden sugerir un claro favorito; sin embargo, el desarrollo mismo del partido introduce un nivel de incertidumbre que puede alterar dichas previsiones. Esa imprevisibilidad se debe, en gran medida, a la fuerte influencia del componente del azar en los resultados. Un rebote inesperado, un pase mal ejecutado o una decisión arbitral pueden cambiar por completo el desarrollo y desenlace de un encuentro, provocando que cada acción individual tenga un peso crucial y, en consecuencia, que los jugadores estén en todo momento bajo la presión de intentar no cometer ningún error grave. Esto se ve incrementado en contextos como el del fútbol argentino, donde la pasión de los hinchas y la exigencia ejercida a través de los medios multiplican las expectativas. Todo ello explicado, en última instancia, por la escasa cantidad de goles que suelen registrarse en los partidos, lo que otorga a cada acción un valor potencialmente determinante en el resultado final (Brechot & Flepp, 2018).

Una de las consecuencias del bajo número de goles es que el marcador final de los enfrentamientos no siempre refleje con claridad lo que sucedió en el desarrollo del juego. De este modo, no es inusual que un equipo que domina y genera más situaciones de gol durante los noventa minutos que duran los encuentros termine perdiendo frente a otro que aprovecha mejor sus pocas llegadas, lo que muestra que la relación entre cantidad de intentos y efectividad dista de ser lineal y permite concluir que lo verdaderamente decisivo no es el volumen de situaciones creadas, sino la "calidad" de cada una de ellas. Surge así la necesidad por parte de los analistas de intentar cuantificar de alguna manera dicha calidad, más allá del resultado final de la acción –de si termina en gol o no–, entrando en juego los modelos estadísticos. Con este propósito, una de las métricas más difundidas a nivel mundial es la de los denominados goles esperados (*expected goals* o xG), cuyo objetivo es justamente cuantificar la probabilidad de conversión de cada disparo al arco en función de sus características. Que un remate presente entonces un valor de xG de 0,2 significa que, bajo las mismas condiciones, normalmente se convierten solamente dos de cada diez veces que este se realice.

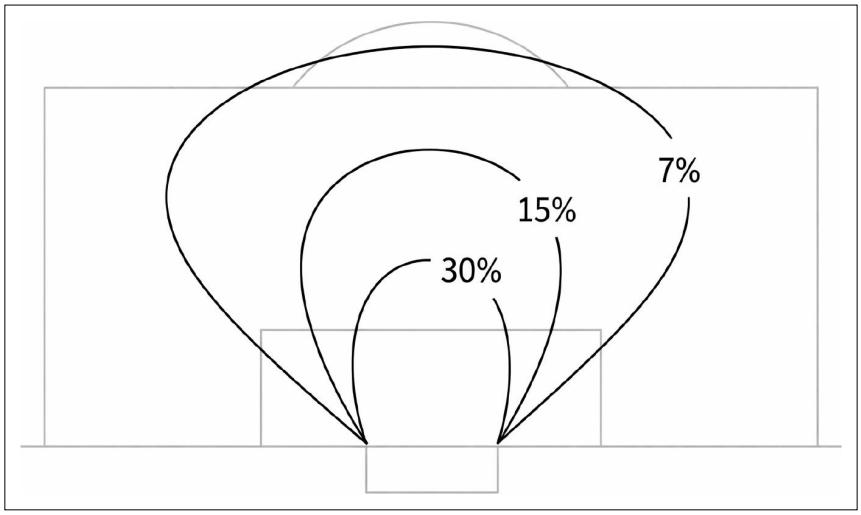
Para el cálculo de la mencionada métrica se recurre normalmente al ajuste de modelos estadísticos –más concretamente a modelos de regresión logística– que consideran el resultado de los disparos al arco (si fueron gol o no) como variable respuesta, y que estiman la probabilidad de conversión en función de un amplio conjunto de factores que la incrementan o la disminuyen. En los modelos de goles esperados los factores que suelen tener mayor influencia son la distancia al arco y el ángulo del disparo con respecto a los palos (Mead et al., 2023; Sumpter, 2022). Remates efectuados de frente al arco suelen ser más fáciles de convertir que aquellos realizados desde los costados, donde el ángulo de tiro es más reducido. La Figura 1 representa, de manera hipotética, cómo se modifican las probabilidades de conversión conforme cambia la distancia y el ángulo de tiro.

Si bien la distancia y el ángulo son variables que permiten obtener predicciones aceptables, las empresas tienen en cuenta muchas otras, algunas un poco más complejas de obtener. Factores adicionales que suelen considerarse en este cálculo son, por ejemplo, la parte del cuerpo con la que se efectúa el remate, el tipo de asistencia (si la hubo), la posición del arquero, la presión ejercida por los defensores, la cantidad de jugadores dentro del triángulo formado por el balón y los palos, entre otros tantos posibles.

Debe considerarse que toda jugada que termine con un disparo al arco es tenida en cuenta en el cálculo del xG, ya sea una situación de juego, un remate de cabeza posterior a

Figura 1

Representación hipotética de cómo cambia la probabilidad de gol al modificarse la distancia y el ángulo de tiro



Nota. Figura tomada de *Soccermatics*, por D. Sumpter, 2022.

un tiro de esquina, un tiro libre o un penal. Como es de esperar, cada una de estas presenta condiciones diferentes dentro del juego y, por ende, los factores que influyen en el cálculo de la métrica difieren, especialmente en estos últimos mencionados. Las empresas proveedoras consideran fijo el valor de gol esperado para los penales, basándose para su cálculo en la proporción de goles en relación a todos los disparos de este tipo. El fijar esta cantidad ve su justificación en suponer que todos los penales se dan, en general, bajo las mismas condiciones. Si bien hay factores que se modifican y que pueden influir en el resultado final –contextos, presión del momento, minuto del partido, entre otros–, también es cierto que la distancia, el ángulo de tiro, la utilización del pie hábil, la distancia al arquero y otros parámetros adicionales serán siempre iguales. StatsBomb asigna a los penales un xG igual 0,7835; Stats Perform, uno de 0,7884 y David Sumpter en *Soccermatics* recomienda darle un valor igual a 0,8. Si bien las empresas difieren en el número exacto, todas coinciden en que se convertirán entre siete y ocho de cada diez penales que se intenten.

Por último, si bien existen diversas técnicas para estimar el valor de xG de cada disparo al arco, la más extendida por las empresas proveedoras consiste en ajustar los mencionados modelos de regresión logística, valiéndose de un enfoque clásico o frecuentista. En este trabajo se propone obtener la mencionada métrica mediante el uso de modelos de este tipo, pero adoptando un enfoque bayesiano.

3.1.1. Errores comunes en la interpretación del xG

La gran difusión de datos e información a través de redes sociales, foros o programas de noticias, ha ayudado a que muchas personas puedan conocer sobre la existencia de nuevas métricas y herramientas que facilitan la transformación de situaciones de juego en números. No obstante, esta popularización también acarreó un problema de interpretación que podría potenciar el rechazo de los protagonistas frente a la utilización de datos. Resulta fundamental resaltar que los datos constituyen solo un elemento más dentro de los tantos existentes para ayudar a los clubes a preparar sus partidos y que, como toda pieza de información, deben estudiarse bajo un adecuado contexto y realizando las lecturas pertinentes. Esta idea ha sido subrayada por distintos autores. Por ejemplo, en un artículo publicado en *Jot Down Sport*,

Matías Conde (2023) cuestiona algunas afirmaciones de Jorge Valdano en contra del uso de datos en el fútbol y muestra cómo ciertas métricas populares adquieren sentido únicamente cuando se interpretan de manera contextualizada. Siguiendo esa misma lógica, los goles esperados se utilizan para medir la peligrosidad de una jugada en particular. Un valor alto en un disparo representa que este se correspondió con una situación clara dentro del partido. Sin embargo, es importante ser cautelosos con su interpretación, ya que muchas veces se la utiliza sin comprender completamente qué significan sus valores (Whitmore, 2023).

Uno de los errores más comunes que se suele encontrar (principalmente en redes sociales) es el de utilizar el xG acumulado de un partido como reflejo de qué tan bien jugó el correspondiente equipo. Muchos resúmenes de partidos presentan el valor de xG total para ambos conjuntos, obtenido como la suma de los xG de todos los disparos generados por estos. Y, si bien esto no es un procedimiento erróneo, los resultados que se obtengan no deben considerarse motivo suficiente para determinar que un equipo mereció ganar ese encuentro específico. En primer lugar, es sabido que no todas las jugadas de peligro terminan necesariamente en un remate al arco y, por lo tanto, no todas son tenidas en cuenta en el cálculo de esta métrica. Además, un equipo puede dominar durante los noventa minutos, generando situaciones sumamente importantes, pero que finalicen con disparos realizados desde ubicaciones o contextos que no sean favorables para obtener altos valores de xG. Del mismo modo, otro conjunto puede defenderse durante la totalidad del partido y tener una única jugada de alto valor que le permita dominar el marcador de goles esperados. En *Soccermatics* se presenta un ejemplo que puede ayudar a comprender este problema del xG. En la Figura 2 se muestran con un círculo cada uno de los disparos al arco que se produjeron en el enfrentamiento entre Bayern de Múnich (Alemania) y OL Lyonnes (Francia) por la Liga de Campeones Femenina de la UEFA en el año 2021. Si solamente se centra la atención en los valores acumulados de xG se puede pensar que el equipo francés, a pesar de haber sido derrotado, mereció ganar el duelo. Sin embargo, en el minuto 58 el conjunto de Lyon tuvo dos ocasiones claras que acumularon un xG total de 0,7 y que representaron casi la mitad del xG total del equipo. En ambos casos, problemas en el control del balón impidieron que las jugadas terminaran en gol, dejando en evidencia que pequeños márgenes pueden determinar el resultado de las jugadas y también que no siempre el mayor xG total se corresponde con el equipo que mejor disputó el encuentro.

Como punto adicional, Sutirth Mukherjee (2024) detalla que un alto valor acumulado de xG puede deberse tanto a una gran cantidad de disparos con bajos valores individuales de xG, como a pocos disparos con valores altos, o incluso a una combinación de muchos disparos con valores elevados. En consecuencia, el autor señala que no basta con estudiar esta métrica de manera aislada, sino que resulta relevante complementarla con otras que permitan resumir adecuadamente lo sucedido en el encuentro. Entre las alternativas mencionadas se encuentran ponderar el xG por la cantidad de disparos realizados o considerar métricas derivadas como la diferencia entre xGOT (*expected goals on target*) y xG, siendo el primero otra de las métricas definidas y desarrolladas en la literatura especializada (Goodman, 2018; Whitmore, 2021). En el artículo en cuestión, se menciona como ejemplo el partido entre Wolverhampton Wanderers Football Club y Chelsea Football Club que se muestra resumido en la Figura 3. Puede observarse que, si bien el equipo perdedor presentó un mayor valor de xG acumulado, también obtuvo un valor de $\mathrm{xGOT} - \mathrm{xG}$ igual a $-1{,}19$, a diferencia del 1,56 obtenido por el equipo londinense. En resumen, aunque el Chelsea generó menos en relación a las "situaciones de calidad" pudo finalizar mejor sus disparos en dichas ocasiones. Es importante contextualizar las métricas y no utilizarlas de manera aislada como un reflejo total de lo ocurrido en un juego de tanta complejidad, como lo es el fútbol.

Figura 2

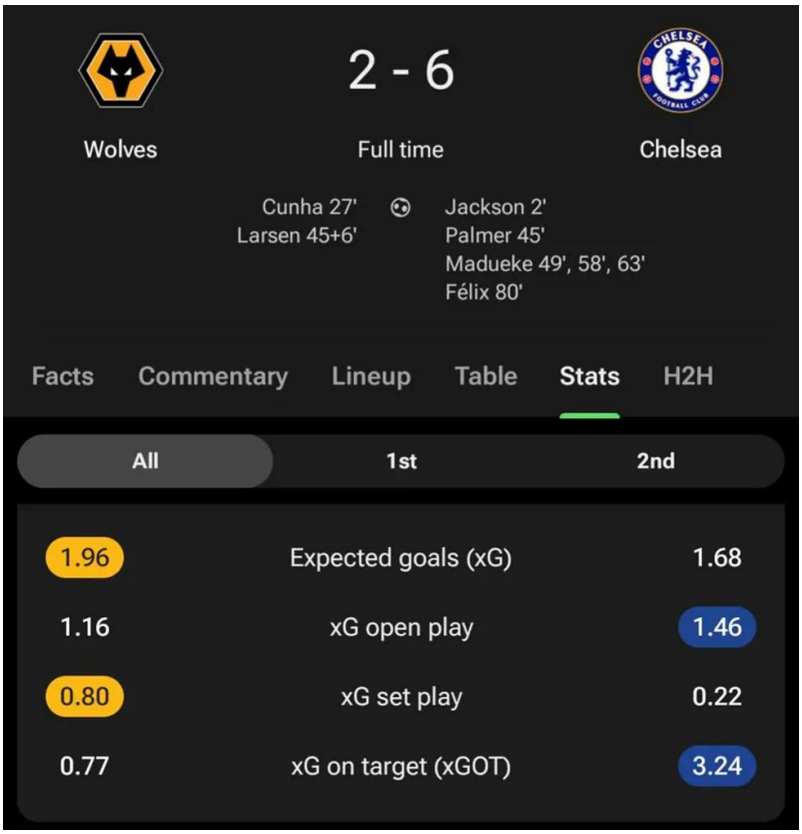
Distribución espacial de los disparos y xG por minuto en el partido entre Bayern de Múnich y OL Lyonnes por la Liga de Campeones Femenina de la UEFA, año 2021



Nota. Figura tomada de *Soccermatics*, por D. Sumpter, 2022.

Figura 3

Estadísticas resumen del partido entre Wolverhampton y Chelsea por la segunda fecha de la Premier League Temporada 2024/25



Nota. Figura tomada de FotMob, 2024.

El segundo error de interpretación que suele aparecer está relacionado con el nombre de esta métrica. Con base en lo señalado por Jonny Whitmore (2023), no se "espera" que los goles ocurran tal y como lo indican las probabilidades, sino que su nombre proviene del concepto matemático de valor esperado, entendido como la probabilidad de que un determinado evento ocurra. En ese sentido, el autor explica que "el valor esperado de una moneda al aire es del 50% para que salga cara y 50% para que salga cruz. No esperamos con esto que la moneda caiga de cada lado exactamente la mitad de las veces, pero al realizar cada vez más lanzamientos es probable que se genere ese equilibrio". A partir de este concepto equivocado, Whitmore desprende lo que se conoce como la falacia del apostador: si un equipo tiene un rendimiento mayor a lo que sugiere su índice de xG, no necesariamente debe empeorar para cumplir con sus expectativas, debido a que ya ha "depositado" ese rendimiento mejorado. De la misma manera que si tras lanzar una moneda diez veces se obtienen diez caras, las probabilidades siguientes continúan siendo de $50/50$.

Con el fin de comprender cómo se construyen los modelos de xG, a continuación, se presentan cinco subsecciones destinadas a este fin. En primer lugar, se presenta una descripción general de los modelos de regresión logística tradicionales, para continuar con la exposición de los fundamentos de la inferencia bayesiana. Finalmente, se abordan los modelos de regresión logística con enfoque bayesiano, los modelos jerárquicos, que amplían este enfoque al permitir la incorporación de niveles adicionales de variabilidad, y las herramientas que suelen utilizarse para su comparación. También se incluye una leve introducción al concepto de *odds* y a su relación con las probabilidades, dado que resulta fundamental para la correcta interpretación de los parámetros del modelo.

3.2. Modelos de regresión logística

Cada jugada que termine con un disparo al arco tiene dos posibles resultados, que finalice en gol o no. Si bien los modelos de xG se construyen con el objetivo de traducir cada situación en un valor de probabilidad que, naturalmente, se encuentre entre cero y uno, para su ajuste es necesario contar con una variable respuesta binaria. Existen diferentes métodos de clasificación para este tipo de respuestas; enfoques como los árboles de decisión, Random Forest o XGBoost han sido estudiados en el contexto del fútbol (Herranz Martínez, 2026; Senn, 2024). Sin embargo, los modelos de regresión logística continúan siendo los más populares dentro de esta industria, principalmente debido a su facilidad de cómputo y a la interpretabilidad de sus resultados por parte de personas ajenas al mundo de los modelos estadísticos. La idea detrás de la construcción de este tipo de modelos es sencilla. Se requiere información sobre un gran número de disparos al arco, incluyendo tanto el resultado final de la jugada (si fue gol o no) como un conjunto de variables que permitan explicar dicho resultado. Luego, se procede a entrenar el modelo para determinar si una jugada, con ciertos valores de las variables explicativas, será convertida o no, o bien con qué probabilidad ocurrirá dicho suceso.

En primer lugar, resulta pertinente indagar en los modelos de regresión logística tradicionales de manera general. Sea Y una variable indicadora construida sobre la ocurrencia de un evento de interés. Esto es:

$$Y = \begin{cases} 1 \text{ si ocurre el evento} \\ 0 \text{ si no ocurre} \end{cases} \tag{1}$$

Sea también π la probabilidad de que ocurra el evento, es decir, $\pi = P(Y = 1)$ y sea $\boldsymbol{X} = (X_1, X_2, ..., X_P)$ un vector P-dimensional de variables explicativas de cualquier tipo. En este caso particular, asumiendo independencia entre los ensayos y probabilidad de éxito constante, Y sigue una distribución Bernoulli de parámetro π. Planteado así, es fácil concluir que:

$$\begin{aligned}\mathbb{E}(Y) &= \sum_{y=0}^{1} y \times P(Y=y) = 0 \times P(Y=0) + 1 \times P(Y=1) = \\ &= 0 \times (1-\pi) + 1 \times \pi = \pi\end{aligned} \tag{2}$$

En los problemas de regresión, en general, el objetivo es modelizar la esperanza de la variable respuesta condicionada a un valor del vector $\boldsymbol{X}$. Si se considera que los ensayos son equiprobables dadas las variables explicativas, se puede notar:

$$\mathbb{E}(Y \mid \boldsymbol{X} = \boldsymbol{x}) = \pi(\boldsymbol{X} = \boldsymbol{x}) \tag{3}$$

donde $\pi(\boldsymbol{X} = \boldsymbol{x})$ representa la probabilidad de ocurrencia del evento condicionada a valores determinados de las variables explicativas. Por simplicidad, de aquí en adelante se considera que $\mathbb{E}(Y \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbb{E}(Y \mid \boldsymbol{x})$ y que $\pi(\boldsymbol{X} = \boldsymbol{x}) = \pi(\boldsymbol{x})$.

Por otro lado, los modelos de regresión plantean, de manera general, la siguiente igualdad:

$$\mathbb{E}(Y \mid \boldsymbol{x}) = f(\boldsymbol{x}) \tag{4}$$

donde $f(.)$ es una función que describe la relación entre la esperanza de la variable respuesta y las variables explicativas. Luego, por ejemplo, si se busca plantear una relación lineal entre ambas partes de la igualdad planteada en (4), resulta:

$$\mathbb{E}(Y \mid \boldsymbol{x}) = f(\boldsymbol{x}) = \eta = \beta_0 + \sum_{p=1}^{P} \beta_p x_p \tag{5}$$

donde η es lo que se denomina predictor lineal, β_0 es el intercepto, que representa el valor de la esperanza de Y cuando todas las variables explicativas se anulan, y β_p para $p = 1, ..., P$ son los coeficientes de regresión que cuantifican la relación entre cada variable explicativa y la mencionada esperanza. Todos estos coeficientes pueden tomar cualquier valor real.

Con todo lo presentado, es posible advertir que, al incluir variables explicativas de cualquier tipo –léase, categóricas o numéricas, discretas o continuas, binarias o con múltiples categorías, entre otras–, la parte derecha de la igualdad presentada en (5) puede adoptar cualquier valor en el conjunto de los números reales. Sin embargo, según lo expuesto en (3), la parte izquierda de dicha igualdad corresponde a $\pi(\boldsymbol{x})$ y, por lo tanto, únicamente puede asumir valores entre cero y uno, dado que representa la probabilidad de ocurrencia de un evento. Es por esto que, si se quiere utilizar un predictor lineal como el de (5), es necesario hacer uso de una función que transforme la esperanza condicional de la variable Y, denominada función de enlace. Esta función debe tener como dominio al intervalo $(0; 1)$ y como imagen a los números reales, además de ser monótona e invertible. Si bien existen diversas alternativas que satisfacen las características deseadas, la función de enlace más utilizada en la práctica es la función logit, definida como:

$$\text{logit}[\pi(\boldsymbol{x})] = \ln\left[\frac{\pi(\boldsymbol{x})}{1-\pi(\boldsymbol{x})}\right] \tag{6}$$

que se corresponde con la inversa de la función de distribución acumulada de una distribución logística y que permite obtener interpretaciones simples de los parámetros del modelo, en base a las *odds* de ocurrencia.

Un modelo de regresión logística (llamado así por la utilización del enlace presentado) que considera una relación lineal entre las variables explicativas y el logit de la esperanza de la variable respuesta, tiene entonces la siguiente forma:

$$g[\mathbb{E}(Y \mid \boldsymbol{x})] = g[\pi(\boldsymbol{x})] = \text{logit}[\pi(\boldsymbol{x})] = \ln\left[\frac{\pi(\boldsymbol{x})}{1-\pi(\boldsymbol{x})}\right] = \beta_0 + \sum_{p=1}^{P} \beta_p x_p \tag{7}$$

3.2.1. Definición de *odds*

Se define como *odds* a la razón entre la probabilidad de ocurrencia de un evento y la probabilidad de que este no se presente. Si se denota con π a la probabilidad de ocurrencia de un evento cualquiera, entonces:

$$odds = \frac{\pi}{1-\pi} \tag{8}$$

De esta manera, si π está restringido entre cero y uno, $\frac{\pi}{1-\pi}$ puede tomar cualquier valor entre cero e infinito.

A modo de ejemplo, si la probabilidad de ocurrencia de un determinado evento es $\pi = 2/3$, entonces la *odds* de ocurrencia se obtiene como:

$$odds = \frac{2/3}{1-2/3} = 2 \tag{9}$$

y que se interpreta como que es dos veces más probable que el evento suceda por sobre que no lo haga. En cambio, si se considera una probabilidad de $\pi = 1/3$, se tiene que:

$$odds = \frac{1/3}{1-1/3} = 0{,}5 \tag{10}$$

y su interpretación refiere a que es dos veces más probable que no ocurra el evento por sobre que sí lo haga. Por último, si $odds = 1$ entonces es igualmente probable tanto que el evento ocurra como que no.

Además, es posible transformar nuevamente las *odds* en probabilidades, simplemente haciendo:

$$\pi = \frac{odds}{1+odds} \tag{11}$$

Muchos autores traducen el término *"odds"* como la "chance de ocurrencia" de un evento, a riesgo de que esto genere confusiones debido a que, en el español, las palabras "probabilidad" y "chance" suelen utilizarse como sinónimos. De todas maneras, para favorecer la claridad de las interpretaciones, en este trabajo se opta por emplear "chance" y *"odds"* de manera equivalente.

3.2.2. Modelos de regresión logística en el contexto del fútbol

Una vez presentados los modelos de regresión logística de manera genérica, es posible adoptar un enfoque más práctico y orientado al tema sobre el que se refiere este trabajo. Como primer punto, se debe considerar como evento de interés el hecho de que un disparo en particular termine en gol. Así, la variable respuesta del modelo resulta:

$$Y = \begin{cases} 1 \text{ si el disparo termina en gol} \\ 0 \text{ en caso contrario} \end{cases} \tag{12}$$

Nuevamente, se considera un vector de variables explicativas $\boldsymbol{X} = (X_1, X_2, ..., X_P)$ que representa características del disparo que se suponen asociadas a su resultado final. Por simplicidad, se considera, en un principio, una única variable explicativa numérica para

intentar determinar si la jugada será convertida o no: la distancia al arco. Sea X la distancia en metros desde el punto del que se realiza el disparo y el centro del arco rival. Por lo visto en la Sección 3.2, el modelo resulta:

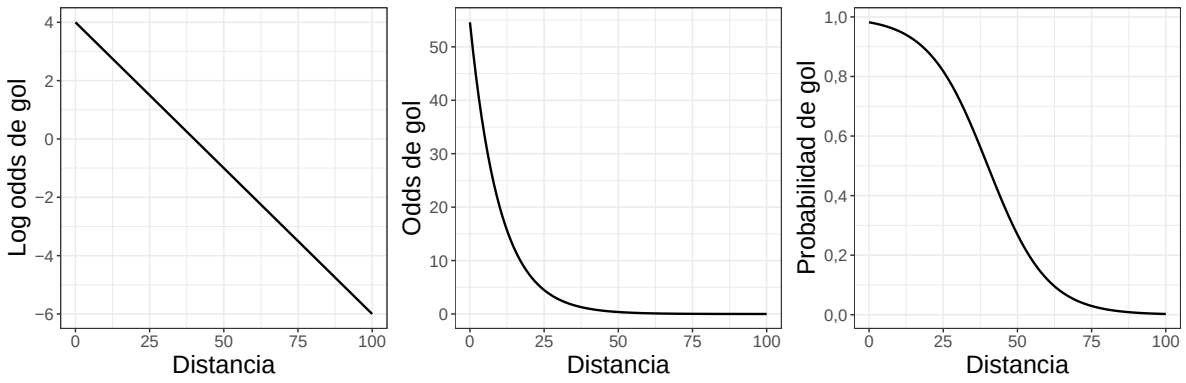
$$\ln\left[\frac{\pi(X)}{1-\pi(X)}\right] = \beta_0 + \beta_1 X \tag{13}$$

siendo:

- $\pi(X) = P(Y = 1 \mid X)$ la probabilidad de que un disparo realizado desde una distancia X termine en gol;
- $\frac{\pi(X)}{1-\pi(X)}$ la *odds* de convertir, es decir, la chance de que un disparo realizado desde una distancia X termine en gol;
- $\ln\left[\frac{\pi(X)}{1-\pi(X)}\right]$ el logaritmo de la chance de que un disparo realizado desde una distancia X termine en gol, también llamado *log odds* de gol;
- β_0 el logaritmo de la chance de gol cuando el disparo se realiza a cero metros de distancia del centro del arco rival; y
- β_1 el cambio en el logaritmo de la chance de gol por incremento unitario en la distancia desde la que se realiza el disparo.

Dado que establecen una relación lineal en la escala del logit, a los parámetros desconocidos β_0 y β_1, se los suele llamar intercepto y pendiente, respectivamente, y el objetivo del modelado está puesto en estimarlos.

Figura 4
Relación entre la distancia al arco y el logit, la odds y la probabilidad de gol



Presentados así resulta difícil encontrar una interpretación práctica para los mencionados parámetros, motivo por el cual resulta conveniente traducir las expresiones a términos de *odds* o de chances de ocurrencia, simplemente haciendo:

$$\frac{\pi(X)}{1-\pi(X)} = \exp\{\beta_0 + \beta_1 X\} \tag{14}$$

De esta manera, la parte izquierda de la igualdad de (14) presenta el cociente entre probabilidades que se estudió previamente en la Sección 3.2.1. Es decir, si β_0 representa el logaritmo de la chance de gol cuando el disparo se realiza desde el centro del arco, $\exp\{\beta_0\}$ es la chance de gol en dicha situación. Es posible aplicar un razonamiento análogo para β_1, aunque, por su

forma, resulta de mayor utilidad si se lo interpreta en términos de razones de *odds*, es decir, a través de cocientes entre dos *odds*. Sea:

- $odds_x$ la chance de gol cuando la distancia al centro del arco es x; y
- $odds_{x+\Delta x}$ la chance de gol cuando dicha distancia se incrementa en Δx.

De esta forma, se tiene que:

- $\ln(odds_x) = \ln\left[\frac{\pi(x)}{1-\pi(x)}\right] = \beta_0 + \beta_1 x$
- $\ln(odds_{x+\Delta x}) = \ln\left[\frac{\pi(x+\Delta x)}{1-\pi(x+\Delta x)}\right] = \beta_0 + \beta_1(x+\Delta x)$

y entonces, por propiedades del logaritmo:

$$\begin{aligned} \ln\left[\frac{odds_{x+\Delta x}}{odds_x}\right] &= \ln(odds_{x+\Delta x}) - \ln(odds_x) \\ &= \beta_0 + \beta_1(x+\Delta x) - (\beta_0 + \beta_1 x) \\ &= \beta_1 \Delta x \end{aligned} \tag{15}$$

En consecuencia:

$$\exp\{\beta_1 \Delta x\} = \frac{odds_{x+\Delta x}}{odds_x} \tag{16}$$

que tiene distintas interpretaciones según el valor de Δx, pero que representa cuántas veces se multiplican las chances de gol por cada aumento de la variable X en Δx unidades, en este caso, por aumento de la distancia en Δx metros.

A modo de ejemplo, se supone que el siguiente modelo estimado:

$$\ln\left[\frac{\hat{\pi}(x)}{1-\hat{\pi}(x)}\right] = \hat{\beta}_0 + \hat{\beta}_1 x = -0{,}7 - 0{,}9x \tag{17}$$

siendo $\hat{\pi}$, $\hat{\beta}_0$ y $\hat{\beta}_1$ las estimaciones puntuales de los parámetros correspondientes. Las interpretaciones, considerando un incremento de $\Delta x = 1$, son las siguientes:

- La chance de gol cuando el disparo se realiza desde cero metros de distancia es $\exp\left\{\hat{\beta}_0\right\} = \exp\{-0{,}7\} = 0{,}5$.
- Se tiene que $\exp\left\{\hat{\beta}_1 \Delta x\right\} = \exp\{-0{,}9 \times 1\} = 0{,}4$. Por ende, la chance de gol disminuye un 60% cuando la distancia al arco se incrementa en un metro.

3.2.3. Cálculo del xG mediante modelos de regresión logística

El caso presentado en la sección previa es un ejemplo simple de cómo se puede utilizar un modelo de regresión logística en el contexto de los disparos al arco. En casos así, con una sola variable explicativa, las interpretaciones de los parámetros son sencillas y directas. Sin embargo, si bien la interpretación de los parámetros es relevante, el objetivo principal de este tipo de modelos es el de asignarle a cada jugada una probabilidad de gol concreta. Para esto, simplemente basta con fijar los valores de las variables explicativas (fijar un valor de distancia, en este caso), hacer uso de la igualdad presentada en (13) y despejar $\pi(x)$:

$$\ln\left[\frac{\hat{\pi}(x)}{1-\hat{\pi}(x)}\right] = \hat{\beta}_0 + \hat{\beta}_1 x \tag{18}$$

$$\begin{aligned} \frac{\hat{\pi}(x)}{1-\hat{\pi}(x)} &= \exp\Big\{\hat{\beta}_0 + \hat{\beta}_1 x\Big\} \\ \hat{\pi}(x) &= \frac{\exp\Big\{\hat{\beta}_0 + \hat{\beta}_1 x\Big\}}{1+\exp\Big\{\hat{\beta}_0 + \hat{\beta}_1 x\Big\}} \end{aligned} \tag{18}$$

Si se considera el modelo estimado planteado en (17) y una distancia igual a 4 metros, se tiene que:

$$\begin{aligned} \hat{\pi}(X=4) &= \frac{\exp\Big\{\hat{\beta}_0 + \hat{\beta}_1 \times 4\Big\}}{1+\exp\Big\{\hat{\beta}_0 + \hat{\beta}_1 \times 4\Big\}} \\ &= \frac{\exp\{-0{,}7 - 0{,}9 \times 4\}}{1+\exp\{-0{,}7 - 0{,}9 \times 4\}} \\ &= \frac{\exp\{-4{,}3\}}{1+\exp\{-4{,}3\}} \\ &= 0{,}013 \end{aligned} \tag{19}$$

Así, según el modelo planteado, el valor de xG de un disparo realizado desde 4 metros de distancia al centro de arco es de 0,013.

Es importante tener en cuenta que el modelo planteado únicamente está considerando la distancia como factor influyente sobre si el disparo es concretado o no. A medida que se incorporen otras variables explicativas –como el ángulo del tiro, la posición del arquero o la parte del cuerpo utilizada–, el modelo podrá captar con mayor precisión la complejidad real de las situaciones de gol. En esos casos, se incorporan más parámetros al modelo y, aunque sus interpretaciones difieren en cierta medida a las presentadas, el procedimiento para obtener el valor de xG resulta idéntico. No obstante, esto no debe entenderse bajo la premisa de que la incorporación de un mayor número de variables garantiza mejores resultados, sino que, en muchas ocasiones, un modelo más parsimonioso puede generar resultados igualmente satisfactorios. Con el fin de obtener un modelo que utilice la menor cantidad posible de parámetros sin perder capacidad explicativa, existen diversos métodos de selección de variables que deben ser tenidos en cuenta, aunque su estudio excede el alcance del presente trabajo.

3.3. Inferencia Bayesiana

Los modelos utilizados en esta tesina se construyen bajo un enfoque bayesiano. Es por esto que, previo a describir específicamente los modelos con los que se trabaja, resulta apropiado revisar los orígenes de la inferencia bayesiana y los fundamentos en los que dicho enfoque se basa.

Según Lambert (2018), inspirado por las reflexiones del filósofo David Hume sobre la relación entre causa y efecto y la inferencia a partir de la experiencia, el reverendo británico Thomas Bayes formuló, hacia 1740, un teorema mediante el cual buscó expresar matemáticamente dichas ideas, sentando así las bases de lo que hoy se conoce como enfoque bayesiano. Sin embargo, su trabajo no se dio a conocer hasta dos años después de su muerte, cuando, en 1763, su amigo Richard Price lo revisó y publicó bajo el título *An Essay towards solving a Problem in the Doctrine of Chances*. Años más tarde, en 1774, Pierre-Simon Laplace publicó *Mémoire sur la probabilité des causes par les évènements*, donde llegó a conclusiones similares a las de Bayes y Price, aunque con un enfoque más general y cercano al que se utiliza actualmente.

La regla de probabilidad que planteó Bayes no es más que una consecuencia de la regla del producto, que establece que, siendo A y B dos eventos cualesquiera, se tiene que:

$$P(A, B) = P(A \cap B) = P(A \mid B) \times P(B) = P(B \mid A) \times P(A) \tag{20}$$

y que puede reescribirse como sigue para obtener lo que hoy se conoce como el teorema o regla de Bayes:

$$P(A \mid B) = \frac{P(B \mid A) \times P(A)}{P(B)} \tag{21}$$

Si bien presentada así esta regla no dice mucho, constituye la base de todo enfoque bayesiano. El enfoque clásico o frecuentista parte del supuesto de que los parámetros –ya sean poblacionales o de un modelo estadístico– son cantidades fijas, pero desconocidas. Bajo este enfoque, la incertidumbre asociada a las estimaciones es consecuencia de la variación muestral, del hecho de que cada muestra seleccionada sea ligeramente distinta y no represente de manera exacta a la población (Lambert, 2018). En contraparte, el enfoque bayesiano utiliza distribuciones de probabilidad para representar la incertidumbre (o certidumbre) que se tiene respecto de las cantidades desconocidas. En otras palabras, dichas cantidades se modelizan como variables aleatorias. Sin embargo, es importante destacar que esto no implica que el enfoque bayesiano asuma que los parámetros sean realmente aleatorios, sino que esta representación se utiliza como un mecanismo para cuantificar la incertidumbre y realizar inferencia a partir de los datos. Para ello (y esto es lo que da nombre al enfoque), se utiliza la regla de Bayes para actualizar las distribuciones a la luz de la información.

En el marco de la inferencia bayesiana se supone una distribución inicial para los parámetros desconocidos, denominada *prior* o distribución *a priori*, que luego, haciendo uso de un modelo, de los datos observados y de la mencionada regla de probabilidad, se transforma en una nueva distribución denominada *posterior* o distribución *a posteriori*. La actualización de la distribución *a priori* a partir de los datos observados puede formularse de la siguiente manera:

$$p(\boldsymbol{\theta} \mid \text{datos}) = \frac{p(\text{datos} \mid \boldsymbol{\theta}) \times p(\boldsymbol{\theta})}{p(\text{datos})} \tag{22}$$

siendo:

- $\boldsymbol{\theta} = (\theta_1, \theta_2, ..., \theta_P)$ un vector de parámetros que se desea estimar;
- $p(\boldsymbol{\theta} \mid \text{datos})$ el *posterior*, es decir, la distribución del vector de parámetros $\boldsymbol{\theta}$ luego de observar los datos;
- $p(\boldsymbol{\theta})$ el *prior*, es decir, la distribución del vector de parámetros $\boldsymbol{\theta}$ antes de observar los datos;
- $p(\text{datos} \mid \boldsymbol{\theta})$ la función de verosimilitud (o *likelihood*) que representa la probabilidad de observar la muestra obtenida para los distintos valores posibles de $\boldsymbol{\theta}$, de acuerdo al modelo observacional asumido; y
- $p(\text{datos})$ una función de densidad marginal que garantiza que la distribución *a posteriori* integre a 1.

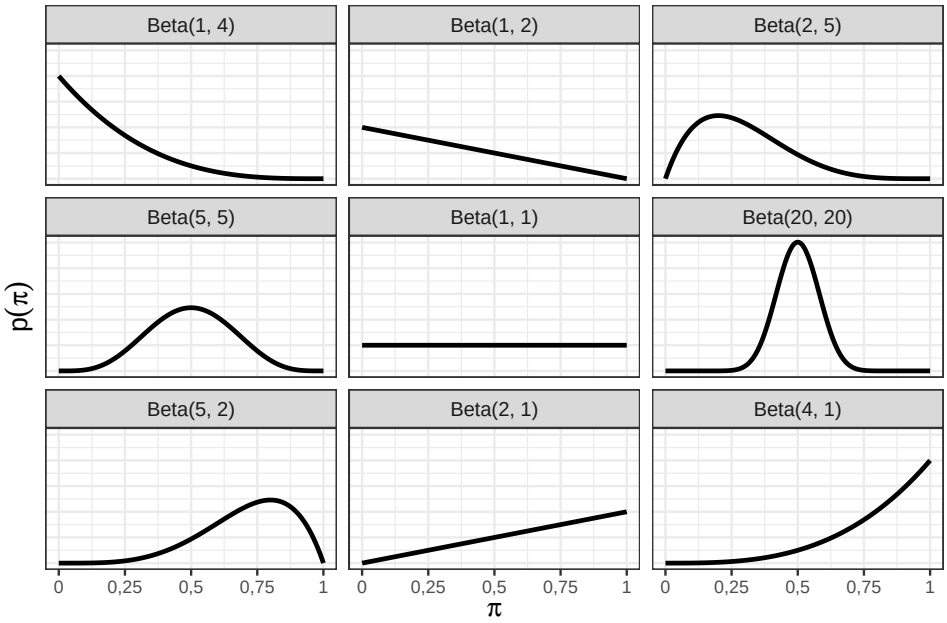
Este último elemento puede generar problemas, ya que para su determinación es necesario resolver una integral P-dimensional, lo cual puede resultar difícil o, en ciertos casos, imposible. No obstante, al tratarse de un valor constante que no afecta la forma del *posterior*, puede omitirse de su cálculo para luego normalizar la expresión final. La relación presentada en (22) se suele escribir como sigue:

$$p(\boldsymbol{\theta} \mid \text{datos}) \propto p(\text{datos} \mid \boldsymbol{\theta}) \times p(\boldsymbol{\theta}) \tag{23}$$

3.3.1. Ejemplo de aplicación de la regla de Bayes

Sea E un ensayo de Bernoulli, A un evento de interés con $P(A) = \pi$ y sea Y el número de veces que se presenta A en un total de N repeticiones independientes de E. Para obtener la distribución *a posteriori* del parámetro desconocido π, primero es necesario establecer una distribución inicial para este, un *prior*. En este contexto, se debe considerar una distribución para variables continuas con valores entre 0 y 1, siendo la distribución Beta una opción muy utilizada por su flexibilidad y conveniencia para reflejar los conocimientos previos disponibles sobre el comportamiento del parámetro. La Figura 5 muestra distribuciones teóricas de este tipo para distintos valores de sus parámetros, ilustrando la flexibilidad antes mencionada.

Figura 5
Posibles distribuciones Beta para distintos valores de los parámetros



En particular, se asume que el parámetro π sigue una distribución Beta con parámetros $a > 0$ y $b > 0$. Esto es:

$$\pi \sim \text{Beta}(a, b)$$
$$p(\pi) = p(\pi \mid a, b) = \frac{\pi^{a-1}(1-\pi)^{b-1}}{B(a,b)} \quad \text{siendo} \quad B(a,b) = \int_0^1 \pi^{a-1}(1-\pi)^{b-1} d\pi \tag{24}$$

Además, por definición, la variable Y se distribuye Binomial de parámetros N y π, es decir:

$$Y \mid N, \pi \sim \text{Binomial}(N, \pi)$$
$$p(y \mid N, \pi) = \binom{N}{y} \pi^y (1-\pi)^{N-y} = p(y \mid \pi) \tag{25}$$

donde (25) es la función de masa de probabilidad de la distribución Binomial que, para un valor de Y dado, define la función de verosimilitud y cuantifica la probabilidad de observar los datos obtenidos para los distintos valores posibles del parámetro π.

Haciendo uso de la regla de Bayes, es posible obtener el *posterior* para π:

$$p(\pi \mid y) = \frac{p(y \mid \pi)p(\pi)}{p(y)} = \frac{\binom{N}{y}\pi^y(1-\pi)^{N-y}\frac{\pi^{a-1}(1-\pi)^{b-1}}{B(a,b)}}{\int p(y \mid \pi)p(\pi)d\pi} \tag{26}$$

Como se mencionó anteriormente, la integral del denominador puede resultar difícil de resolver; sin embargo, haciendo uso de la relación presentada en (23), es posible obtener la siguiente expresión:

$$\begin{aligned} p(\pi \mid y) &\propto p(y \mid \pi)p(\pi) \\ &\propto \binom{N}{y}\pi^y(1-\pi)^{N-y}\frac{1}{B(a,b)}\pi^{a-1}(1-\pi)^{b-1} \\ &\propto \binom{N}{y}\frac{1}{B(a,b)}\pi^{y+a-1}(1-\pi)^{N-y+b-1} \\ &\propto K\pi^{y+a-1}(1-\pi)^{N-y+b-1} \end{aligned} \tag{27}$$

Luego, para que se cumpla la condición de cierre

$$\int_0^1 p(\pi \mid y)d\pi = 1 \tag{28}$$

debe ocurrir que

$$K = \frac{1}{B(y+a, N-y+b)} = \frac{\Gamma(N+a+b)}{\Gamma(y+a)\Gamma(N-y+b)} \tag{29}$$

y, por lo tanto, la distribución *a posteriori* del parámetro de interés resulta una distribución Beta de parámetro $y+a$ y $N-y+b$. En resumen:

$$\begin{aligned} \pi &\sim \text{Beta}(a,b) \\ y \mid N, \pi &\sim \text{Binomial}(N,\pi) \\ \pi \mid y &\sim \text{Beta}(y+a, N-y+b) \end{aligned} \tag{30}$$

que identifica al modelo conocido como Beta-Binomial.

El caso presentado sirve para observar que, mediante la regla de Bayes, es posible obtener la distribución *a posteriori* para los parámetros de interés de manera exacta. No obstante, resulta pertinente destacar que este procedimiento no siempre resulta tan directo. Este ejemplo pertenece a un conjunto de casos conocidos como familias conjugadas, en los cuales, la familia del *posterior* resultante es igual a la del *prior* elegido. Modelos como estos facilitan en gran medida los cálculos y permiten obtener expresiones exactas para la distribución *a posteriori*, pero únicamente ocurren cuando la distribución para el modelo observacional (o para las observaciones) pertenece a la familia exponencial.

3.3.2. Inferencia aproximada utilizando métodos de Monte-Carlo basados en cadenas de Markov

Si bien en algunos modelos simples es posible obtener de manera exacta la distribución *a posteriori*, en cuanto el modelo se complejiza, incluso levemente, este procedimiento analítico suele resultar inviable debido a la complejidad de la integral involucrada en el denominador. Por este motivo, en la práctica se recurre a métodos de inferencia aproximada, que permiten estimar cantidades de interés del *posterior* sin necesidad de obtenerlo explícita-

mente. Entre las distintas estrategias desarrolladas para este fin, una de las más utilizadas es la simulación mediante métodos de Monte-Carlo basados en cadenas de Markov. Estos métodos se denominan *Markov Chain Monte-Carlo* (MCMC) y permiten generar muestras del *posterior* para, a partir de ellas, aproximar las propiedades de dicha distribución.

La idea central detrás de estos métodos es generar una secuencia de muestras que se comporte como extracciones de la distribución objetivo. Para ello, se construye una cadena de Markov, es decir, una sucesión de valores en la que cada nuevo elemento depende únicamente del valor actual y no de los anteriores. Dado un valor inicial para el vector de parámetros, el algoritmo produce una secuencia de valores mediante un proceso probabilístico de aceptación y rechazo diseñado para favorecer las regiones de mayor probabilidad de la distribución objetivo. En la práctica, el procedimiento suele ejecutarse utilizando múltiples cadenas de Markov, cada una iniciada en distintos puntos del espacio paramétrico, lo que permite evaluar si todas exploran la misma región del espacio de parámetros y facilita el diagnóstico de la bondad del algoritmo. Además, dado que las cadenas pueden inicializarse en una región lejana a la que concentra la mayor masa de probabilidad, se descartan las primeras iteraciones de cada una durante un período de calentamiento o *burn-in*. Luego de este período inicial, las muestras obtenidas se utilizan para aproximar cantidades de interés.

Existen numerosos algoritmos dentro de la familia MCMC, pero tanto en la academia como en la industria se considera al método No-U-Turn Sampler o NUTS (Hoffman & Gelman, 2014) como el referente de excelencia o *gold standard* para la inferencia bayesiana moderna. En este trabajo se hace uso de dicho algoritmo utilizando la librería `{PyMC}` del *software* libre Python (Abril-Pla et al., 2023).

3.3.3. Análisis del *posterior*

Las técnicas de inferencia basadas en MCMC permiten estimar valores esperados de las distribuciones de interés, tales como la media, la varianza o los percentiles, sin la necesidad de conocer su forma exacta. No obstante, es importante tener en cuenta que, al obtener dichas estimaciones mediante métodos de simulación, la validez de los resultados dependerá en gran medida de la representatividad o calidad de las muestras generadas. En este caso, es importante tener en cuenta que los métodos de MCMC no generan muestras independientes, ni está garantizado que, en un tiempo finito, las muestras provengan del *posterior* sobre el que se busca extraer conclusiones. Por estos motivos, es de suma importancia realizar un análisis de diagnóstico que permita determinar si es confiable concluir sobre las características de la distribución *a posteriori*.

Cuando se realiza un análisis de este tipo, se busca que las cadenas generadas cumplan con cuatro condiciones:

- que exploren todo el dominio del *posterior*, o bien, la región del dominio donde se concentra prácticamente la totalidad de la masa de probabilidad;
- que se comporten de manera similar cuando se las somete a diferentes condiciones iniciales;
- que presenten una baja dependencia entre los valores de las muestras (autocorrelación); y
- que sean eficientes, es decir, que requieran de la menor cantidad de muestras posible.

No existe una única prueba que permita determinar con total certeza la fiel representación del *posterior* por las muestras obtenidas. Es por esto que, para corroborar el cumplimiento de los puntos planteados, se hace uso de gráficos y de resúmenes numéricos.

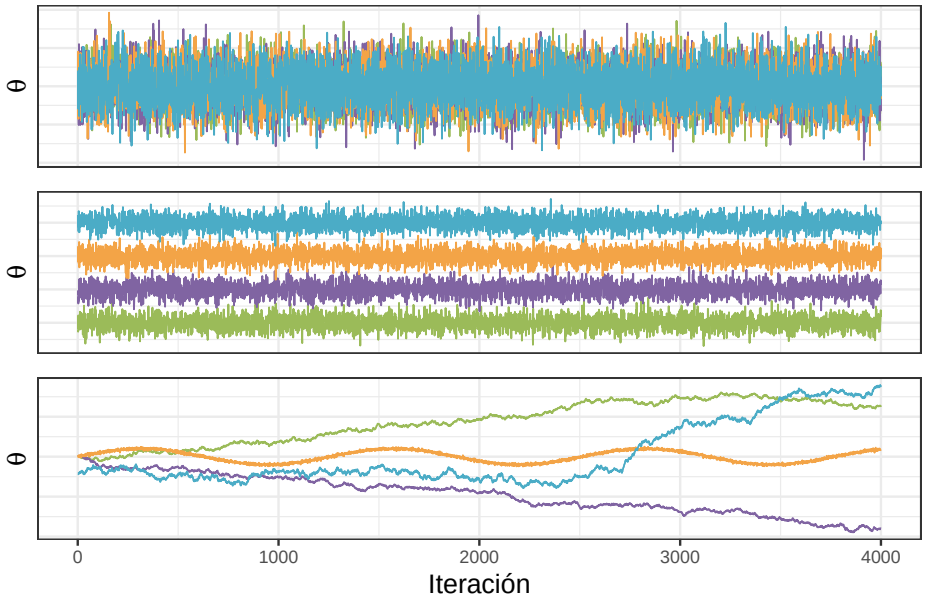
3.3.3.1. Gráficos de trazas

Los valores muestreados por un algoritmo de MCMC se obtienen uno después de otro. Así, un primer diagnóstico puede realizarse al estudiar cómo fue la generación de estos valores de manera secuencial, esto es, a modo de serie de tiempo. Surgen así los gráficos de trazas o *traceplots*, que muestran los valores obtenidos por el algoritmo en función del tiempo.

Se busca que las trayectorias de las cadenas se asemejen lo más posible a un ruido blanco y que el rango que recorren en el eje Y sea uniforme a lo largo del tiempo; en consecuencia, no debería ser posible distinguir una cadena de la otra. El asemejarse a un patrón de ruido blanco permite concluir que la autocorrelación entre las muestras es baja y que el algoritmo es estable, ya que todas las cadenas recorren la misma región del espacio paramétrico. Por otro lado, dado que cada cadena comienza desde un valor distinto, el hecho de que sean indistinguibles entre sí permite concluir que estas son insensibles a cambios en las condiciones iniciales. En la Figura 6 se presentan algunos ejemplos de *traceplots* para poder visualizar diferencias en los aspectos mencionados.

Figura 6

Ejemplos de traceplots para el diagnóstico de convergencia en MCMC



Nota. Se muestran cuatro cadenas por panel bajo distintos escenarios: buena mezcla, cadenas estacionarias sin superposición y cadenas no estacionarias.

3.3.3.2. Estadístico de Gelman-Rubin

A partir de lo observado en los *traceplots*, puede extraerse una conclusión sobre el comportamiento ideal de las cadenas: si estas convergen, la variabilidad entre ellas será aproximadamente igual a la variabilidad dentro de cada una. No solo se pretende que cada cadena sea individualmente estable, sino también que exista una consistencia entre ellas. Para cuantificar dicha convergencia, Gelman y Rubin (1992) propusieron un estadístico que recibiría su nombre.

Sean C cadenas de muestras generadas, cada una de ellas con S observaciones y sea $\theta_c^{(s)}$ el s-ésimo valor de la c-ésima cadena. Entonces, el estadístico de Gelman-Rubin se obtiene como sigue:

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}} = \sqrt{\frac{\frac{S-1}{S}W + \frac{1}{S}B}{W}} \tag{31}$$

siendo $\hat{V}$ la estimación de la variabilidad total.

En (31) aparecen involucradas tanto la variabilidad dentro de las cadenas (W) como la variabilidad entre cadenas (B). Estos valores se obtienen de la siguiente manera:

$$\begin{aligned} W &= \frac{1}{C}\sum_{c=1}^{C} s_c^2 \\ B &= \frac{S}{C-1}\sum_{c=1}^{C}\left[\overline{\theta}_c^{(\bullet)} - \overline{\theta}_\bullet^{(\bullet)}\right]^2 \end{aligned} \tag{32}$$

siendo:

- $s_c^2 = \frac{1}{S-1}\sum_{s=1}^{S}\left[\theta_c^{(s)} - \overline{\theta}_c^{(\bullet)}\right]^2$ la varianza muestral dentro de la c-ésima cadena;
- $\overline{\theta}_c^{(\bullet)} = \frac{1}{S}\sum_{s=1}^{S}\theta_c^{(s)}$ la media de la c-ésima cadena; y
- $\overline{\theta}_\bullet^{(\bullet)} = \frac{1}{C}\sum_{c=1}^{C}\overline{\theta}_c^{(\bullet)}$ la media global.

Si el muestreo realizado por el algoritmo es representativo del *posterior*, la diferencia promedio entre cadenas debe ser similar a la diferencia promedio dentro de cada cadena. Por lo tanto, un valor de $\hat{R}$ cercano a 1 indica convergencia, mientras que valores iguales o mayores a 1,01 conducen a cuestionar la convergencia y mezcla de las cadenas.

En el año 2021, Vehtari, Simpson, Carpenter, Bürkner y el mismo Gelman, propusieron una versión mejorada de este estadístico, que permite detectar con mayor facilidad ciertos problemas de convergencia que suelen presentarse en la práctica (Vehtari et al., 2021). Esta última versión es la implementada en la librería `{posterior}` (Bürkner et al., 2020) utilizada para el análisis de los resultados mediante el *software* libre R.

3.3.3.3. Gráficos de autocorrelación

Como se menciona con anterioridad, las muestras generadas por un algoritmo de MCMC no son independientes entre sí. Si bien el método NUTS tiene la ventaja de, en general, producir muestras con una autocorrelación baja, esto no implica que esta sea nula. En consecuencia, siempre resulta adecuado verificar la dependencia entre los valores de la cadena.

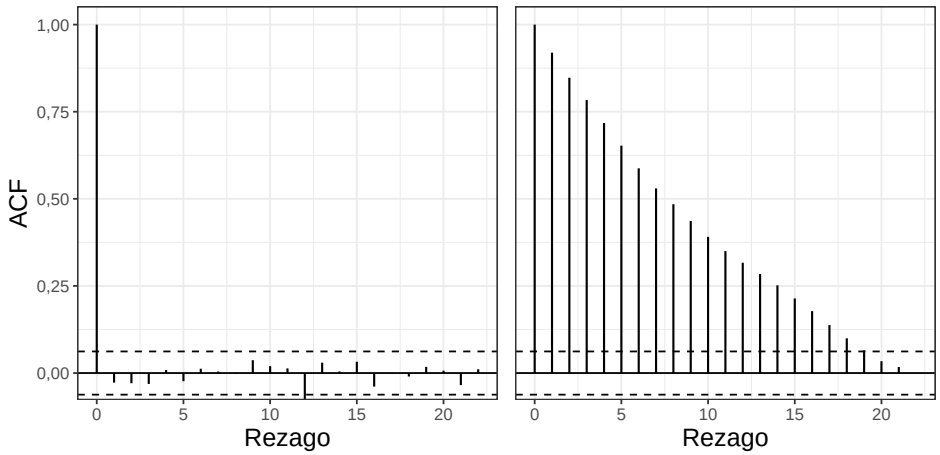
Sea $\theta^{(s)}$ el s-ésimo elemento generado por una cadena de MCMC. La función de autocorrelación para el rezago h se define como:

$$\mathrm{ACF}(h) = \frac{\mathrm{COV}\left[\theta^{(s)}, \theta^{(s+h)}\right]}{\sqrt{V\left[\theta^{(s)}\right]}\sqrt{V\left[\theta^{(s+h)}\right]}} \tag{33}$$

Esta función mide el grado de dependencia lineal entre valores separados por h pasos en la cadena y puede representarse mediante un gráfico de autocorrelación, donde el eje horizontal indica el rezago h y el eje vertical el valor de $\mathrm{ACF}(h)$. Idealmente se busca obtener valores de $\mathrm{ACF}(h)$ cercanos a cero para todo $h > 0$.

Figura 7

Ejemplos de gráficos de autocorrelación para el diagnóstico de las muestras generadas con MCMC



Nota. A la izquierda se muestra un gráfico de autocorrelación construido a partir de observaciones con baja autocorrelación, mientras que a la derecha se observa un caso con alta autocorrelación.

3.3.3.4. Tamaño efectivo de muestra

Un procedimiento para cuantificar qué tanta información se pierde al trabajar con muestras correlacionadas en lugar de con un conjunto de muestras independientes es el cálculo del tamaño efectivo de muestra o N_{eff}. Este valor representa el número de observaciones independientes que resultarían en el mismo error de Monte-Carlo que las muestras correlacionadas obtenidas mediante MCMC, y por lo tanto constituye una medida del grado de eficiencia del muestreo.

Sea una cadena con S muestras correlacionadas y sea $\text{ACF}(.)$ la función de autocorrelación, el tamaño efectivo de muestra se obtiene como se muestra a continuación:

$$N_{\text{eff}} = \frac{S}{1 + 2\sum_{h=1}^{\infty} \text{ACF}(h)} \tag{34}$$

y se espera obtener valores de N_{eff} altos, cercanos a S.

Del mismo modo que en el caso del estadístico de Gelman-Rubin, la librería `{posterior}` hace uso de una alternativa a la fórmula presentada en esta sección, también propuesta por Vehtari et al. (2021).

3.3.3.5. Cadenas paralelas

Otra manera de verificar que un algoritmo de MCMC genere cadenas consistentes se basa en analizar gráficamente las densidades generadas por cada una de las C cadenas paralelas. Si bien es esperable que las distintas cadenas sigan trayectorias diferentes, deberían mostrar un comportamiento similar y producir aproximaciones al *posterior* equivalentes. En condiciones de buena convergencia, se espera observar densidades prácticamente indistinguibles.

3.4. Cálculo del xG mediante modelos de regresión logística con enfoque bayesiano

Luego de presentar tanto la regresión logística clásica como los fundamentos de la inferencia bayesiana, se combinan ambas ideas para construir los modelos de regresión logística con enfoque bayesiano. En este marco, resulta útil contrastar brevemente la interpretación de los parámetros bajo los dos enfoques estudiados.

En el enfoque frecuentista, existen diversos métodos para obtener estimaciones puntuales de cada uno de los parámetros del modelo, es decir, para obtener $\hat{\beta}_p$. Estas estimaciones se corresponderán con un número real, ya sea positivo o negativo según la dirección de la influencia de su correspondiente variable explicativa. En los modelos bayesianos, en cambio, la lógica es diferente. Tal como se expuso en la sección anterior, bajo este enfoque toda cantidad desconocida se modela mediante una distribución de probabilidad. En consecuencia, cada uno de los parámetros no se estima mediante un único valor, sino que se asocia a una distribución de muchos valores posibles que refleja el conjunto de valores plausibles compatibles con la información previa y con los datos observados. Para ello, es necesario especificar distribuciones *a priori* para los parámetros (basadas en creencias, conocimiento experto o supuestos razonables) que luego serán actualizadas a la luz de los datos.

Para mostrar la construcción de un modelo de regresión logística con enfoque bayesiano se supone la misma variable binaria Y presentada en (12) y, nuevamente, sea X la distancia en metros desde el punto del que se realiza el disparo y el centro del arco rival. Como se detalla en la mencionada sección, por definición de la variable, se tiene que:

$$Y \mid \pi \sim \text{Bernoulli}(\pi) \quad \text{siendo} \quad E(Y) = \pi \tag{35}$$

Y es necesario detallar cómo ese valor esperado depende de las variables explicativas, en este caso, de la distancia al arco. Para esto, de igual manera a lo planteado en la sección previa, se requiere de una función de enlace que, nuevamente, resulta ser la función logit. El modelo es el siguiente:

$$Y \mid \pi \sim \text{Bernoulli}(\pi) \quad \text{con} \quad \ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X \tag{36}$$

a lo que se debe incorporar la especificación de la distribución *a priori* para las cantidades desconocidas del modelo:

$$\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \sim F \tag{37}$$

Por simplicidad, suele suponerse independencia *a priori* entre los parámetros, especificando *priors* marginales para cada uno de ellos:

$$\begin{aligned} \beta_0 &\sim F_0 \\ \beta_1 &\sim F_1 \end{aligned} \tag{38}$$

donde F_0 y F_1 son distribuciones de probabilidad fijadas por el investigador. Bajo este supuesto de independencia, el *prior* conjunto viene dado por:

$$F = F_0 \times F_1 \tag{39}$$

Una vez definidas las distribuciones *a priori* para los parámetros del modelo, el siguiente paso consiste en actualizarlas incorporando la información proveniente de los datos observados para obtener el *posterior*. Si se utiliza un método de inferencia, como MCMC, el resultado será un conjunto de muestras de la distribución *a posteriori* de los parámetros.

En el contexto de los modelos de probabilidad de gol, se puede resumir el procedimiento de construcción y ajuste de la siguiente manera:

1. Se define la distribución *a priori* para β_0 y β_1, que refleja la información previa o el conocimiento inicial acerca de los posibles valores de estos parámetros.
2. Mediante la observación de un conjunto de datos (pares de valores de la variable distancia al arco y de la variable respuesta que indica si la jugada resultó o no en gol), se computa la verosimilitud del modelo, que expresa qué tan probable es observar los datos para distintos valores de los parámetros.
3. El método MCMC combina la información del *prior* y de la verosimilitud para generar una gran cantidad de muestras de la distribución *a posteriori* de los parámetros, esto es, pares del tipo $\left[\beta_0^{(s)}, \beta_1^{(s)}\right]$ con $s = 1, ..., S$. El *posterior* representa un compromiso entre la información previa y aquella aportada por los datos, y estos pares de muestras obtenidas permiten aproximar y caracterizar dicha distribución.
4. En base a lo planteado en (36), cada uno de esos S pares pueden combinarse con los valores de la variable explicativa para los que se desea encontrar la probabilidad de gol. Luego, se despeja $\hat{\pi}^{(s)}$ de la misma manera que se estudió en la Sección 3.2.3. Para un disparo desde 4 metros, por ejemplo, resulta:

$$\hat{\pi}^{(s)} = \frac{\exp\left[\beta_0^{(s)} + \beta_1^{(s)} \times 4\right]}{1 + \exp\left[\beta_0^{(s)} + \beta_1^{(s)} \times 4\right]} \tag{40}$$

   obteniendo así, S valores posibles de xG para un disparo realizado desde 4 metros de distancia, esto es, una distribución para la probabilidad de gol de los disparos desde dicha distancia.
6. Si se desea obtener un único valor de xG para un disparo de esta clase, es posible resumir la distribución hallada de distintas maneras: a través de la mediana, de la media, o de cualquier otra medida resumen que el investigador considere adecuada.
7. A modo de ejemplo, si se obtiene un valor medio de la distribución *a posteriori* para la probabilidad de gol igual a 0,2, se concluye que, dado el modelo, el *prior* elegido y la información disponible, el grado de creencia medio de que un remate realizado desde 4 metros se convierta en gol es del 20%, donde 0 indica certeza de que el disparo no será gol y 1 certeza de que lo será.

3.4.1. Elección de *priors*

En el ejemplo presentado se consideran dos distribuciones genéricas (F_0 y F_1) como *priors* para los parámetros del modelo. Puede elegirse cualquier tipo de distribución, siempre y cuando su soporte coincida con el conjunto de valores posibles que pueden tomar los parámetros correspondientes. Su elección estará relacionada con la información previa disponible y con los supuestos razonables que puedan establecerse, pudiendo optar por *priors* más informativos o más conservadores en función del conocimiento sobre los parámetros del modelo.

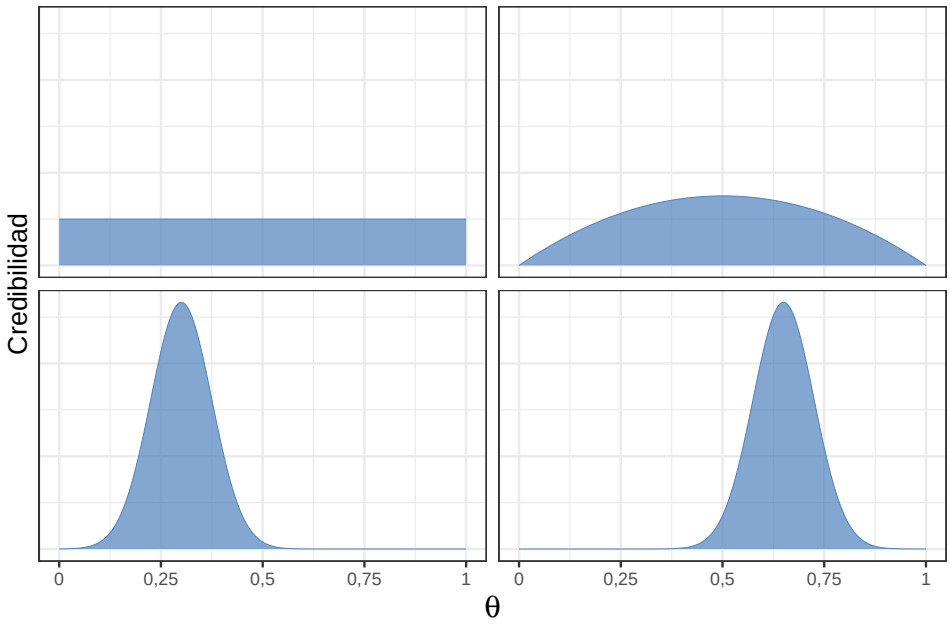
El concepto de *priors* menos o más informativos se vincula con la variabilidad de la distribución seleccionada. Para Johnson, Ott y Dogucu (2021) un *prior* informativo refleja información específica sobre el parámetro desconocido con un alto grado de certeza –es decir, con baja variabilidad–, mientras que un *prior* poco informativo o "vago" refleja solo una cantidad limitada de información específica sobre dicha variable. Estos últimos suelen utilizarse con el fin de mitigar el efecto de observaciones atípicas, al asignar probabilidad

prácticamente nula únicamente a regiones del espacio paramétrico que puedan considerarse imposibles. Existe un caso particular dentro de esta última clase de distribuciones: aquel que asigna igual plausibilidad previa a todos los valores posibles de la variable, conocido como *prior* plano o uniforme.

Suponiendo un parámetro θ que puede tomar valores en el intervalo $[0; 1]$, la Figura 8 muestra cuatro posibles *priors* a ser elegidos, dos muy informativos (ambos con poca variabilidad, pero centrados en valores diferentes), otro poco informativo (con mucha variabilidad) y uno nada informativo o plano.

Figura 8

Posibles priors para un parámetro θ que toma valores en el intervalo $[0; 1]$



Nota. Se muestra un *prior* nada informativo (arriba a la izquierda), uno poco informativo (arriba a la derecha), uno muy informativo centrado en un valor bajo (abajo a la izquierda) y uno muy informativo centrado en un valor alto (abajo a la derecha).

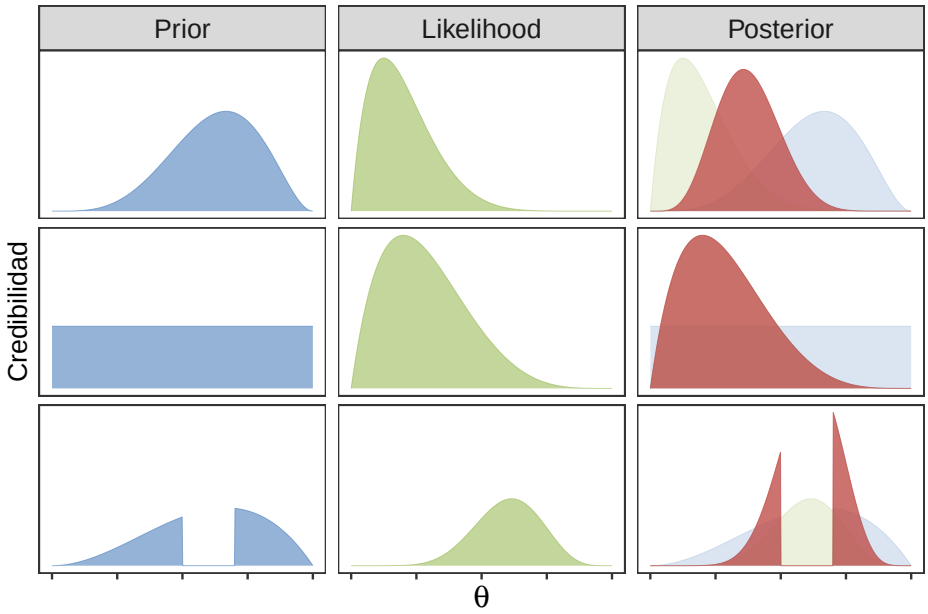
Cuando se trabaja con este tipo de enfoque, además, es necesario tener en cuenta que la distribución *a posteriori* que se obtiene como resultado del proceso mostrado refleja un compromiso entre la información previa (el *prior*) y la brindada por los datos. A medida que la información muestral supera a la información contenida en el *prior*, la distribución *a posteriori* se vuelve menos sensible a la elección de la distribución *a priori*. En la Figura 9 se presentan tres ejemplos para comprender mejor este compromiso que se ve reflejado en el *posterior*.

Uno de los enfoques más extendidos en el ámbito de los modelos de goles esperados consiste en la utilización de distribuciones normales independientes como *priors* para los coeficientes de regresión, tal y como se observa en diversos trabajos de la literatura (Iapteff et al., 2025; Scholtes & Karakuş, 2024). En consecuencia, de aquí en adelante dichos *priors* se expresarán mediante distribuciones normales, en lugar de formularse de manera genérica. En esos casos, el *prior* conjunto para los coeficientes de regresión se corresponde con una distribución normal multivariada con matriz de covarianza diagonal.

Además, en todas las distribuciones se hará uso de desvíos estándares aparentemente pequeños en valor absoluto, con la finalidad de limitar valores extremos poco plausibles sin

Figura 9

Ejemplos del compromiso entre la distribución a priori y el likelihood en la distribución a posteriori

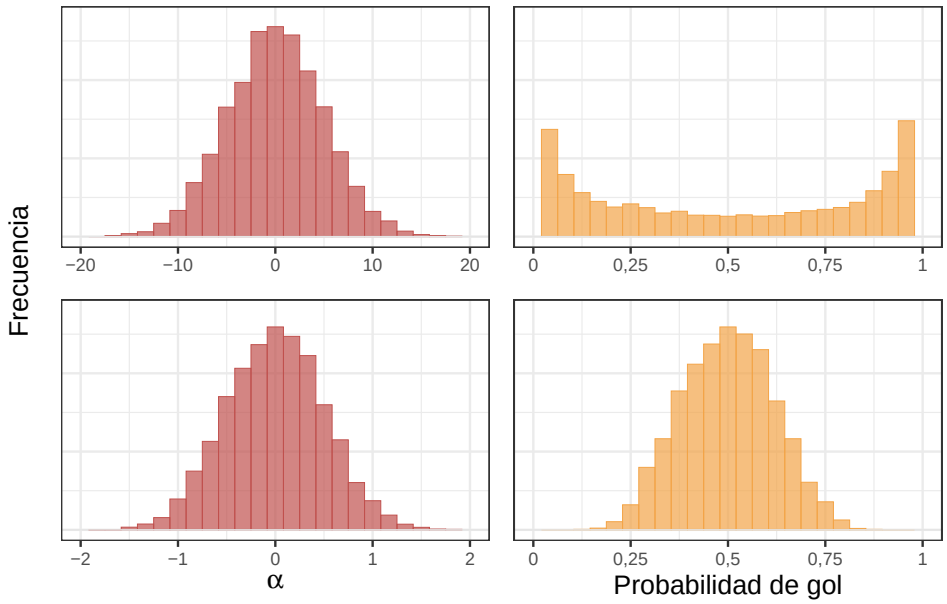


Nota. Figura de elaboración propia a partir de apuntes de clase (Evangelista & Capretto, 2024).

imponer una estructura rígida sobre los parámetros. Si bien esta consideración puede resultar contraintuitiva, la elección de una distribución *a priori* con un desvío estándar demasiado grande, que luego será transformada en probabilidades de gol mediante la inversa de la función logit, genera una mayor masa de probabilidad en los valores extremos de π. En consecuencia, esta especificación induce una creencia *a priori* más restrictiva sobre la probabilidad de gol que la que se obtiene al utilizar un desvío estándar menor. En la Figura 10 se ilustra el comportamiento de la probabilidad de gol al considerar un *prior* con desvío estándar elevado frente a otro con una menor dispersión. Lo que importa destacar es que la elección de *priors* debe realizarse teniendo en cuenta su posterior transformación a términos de probabilidad de gol.

Figura 10

Distribuciones inducidas de la probabilidad de gol a partir de distintas distribuciones para uno de los parámetros



Nota. En la parte superior de la figura se presenta una distribución $\mathcal{N}(0, 5)$ para α (izquierda) y la distribución resultante de la probabilidad de gol π, obtenida al aplicar la inversa de la función logit a α (derecha). En la parte inferior se muestra el mismo procedimiento considerando una $\mathcal{N}(0, 0{,}5)$. En ambos casos se consideran nulas las restantes variables explicativas del modelo.

3.5. Modelos de regresión logística jerárquicos

Uno de los objetivos específicos de esta tesina es el de incorporar a los modelos de xG un efecto asociado al jugador que realiza el disparo. Y, aunque esta idea resulta razonable desde el punto de vista futbolístico, su incorporación en este tipo de modelos no es una práctica frecuente dentro de las empresas proveedoras de datos.

El gol esperado surge como una herramienta para cuantificar la calidad de cada una de las jugadas de un partido de manera global, bajo el supuesto de que existen ocasiones más peligrosas que otras. Desde esa perspectiva, los futbolistas que participan en cada jugada no deberían influir en su valor, incluso aquellos que la finalizan. Además, ya existen métricas que incorporan de manera natural al jugador que ejecuta el disparo y que buscan medir la calidad de los remates una vez realizados, como el ya mencionado *expected goals on target* (xGOT), en el cual resulta especialmente relevante, por ejemplo, la zona del arco en la que finaliza el disparo. Así, si un jugador logra dirigir la mayoría de sus disparos hacia los ángulos del arco, generará valores de xGOT altos y, por ende, en este tipo de métricas, el jugador que dispara adquiere una importancia significativa. En contraparte, el xG mide la calidad de la situación creada previo a la ejecución del disparo, por lo que, en principio, no debería importar en su cálculo quién lo realiza ni dónde termina el remate. No obstante, pese a estos argumentos, también existen razones para considerar al jugador en el cálculo del xG.

En el año 2012, cuando todavía integraba el Fútbol Club Barcelona, Lionel Messi logró uno de los tantos récords de su carrera: convirtió 91 goles en un mismo año calendario,

promediando más de un gol por partido. Dado el contexto competitivo de esas temporadas, no era indiferente para el Barcelona que las jugadas fueran finalizadas por Messi o por cualquier otro jugador. En términos más precisos, resulta razonable pensar que, si un equipo logra que una jugada sea finalizada por un futbolista especialmente habilidoso en esa tarea, al cuantificar su calidad mediante una métrica como el xG, dicha acción reciba un valor mayor.

Adicionalmente, ya se ha mencionado que algunos autores señalan que no siempre basta con estudiar el xG aisladamente, sino que resulta favorable combinar sus valores con los de otras métricas que sí consideran la habilidad del futbolista que define (Mukherjee, 2024). De esta manera, el incorporar directamente el efecto jugador dentro del modelo de xG podría evitar o atenuar los problemas de esta clase.

De todas maneras, incorporar a los modelos un efecto asociado al jugador que finaliza la jugada no es una tarea sencilla, sino que introduce algunas complejidades adicionales, principalmente relacionadas al tamaño muestral. Mientras que para el entrenamiento de los modelos de xG se requiere de un elevado número de disparos, cada jugador tiene por encuentro una cantidad reducida de oportunidades de concretar un gol. Esto implicaría que solo se obtendrían estimaciones confiables para aquellos futbolistas con un volumen elevado de remates, lo que dificultaría (o incluso imposibilitaría) el cálculo del xG para, por ejemplo, jugadores juveniles o nuevos talentos provenientes de otras ligas, para quienes no se dispone de información previa. Sin embargo, existen estrategias de modelización que permiten incorporar la singularidad de cada jugador sin comprometer la estabilidad ni aumentar de forma excesiva la incertidumbre de las estimaciones.

En un modelo construido bajo un enfoque frecuentista, una forma habitual de incorporar un efecto como el del jugador que realiza el disparo es tratarlo como un efecto aleatorio, mientras que, bajo una perspectiva bayesiana, este tipo de estructura se aborda mediante el uso de modelos jerárquicos. La idea central de esta clase de modelos es que los jugadores incluidos en la base de datos representan una muestra extraída de una población mayor de futbolistas con características en común. Cada jugador es un individuo en sí mismo, pero no es completamente independiente de los restantes, permitiendo que parte de la información se comparta entre ellos. Este enfoque permite obtener estimaciones más estables, especialmente en aquellos casos en los que algunos futbolistas cuentan con un número reducido de observaciones. Bajo esta óptica, los parámetros de los modelos bayesianos suelen analizarse en términos del grado de *pooling* que el modelo induce entre ellos.

Según Deming (2018), el *pooling* o agrupamiento "describe la práctica de reunir pequeños conjuntos de datos que se supone comparten el mismo valor de alguna característica y utilizar el conjunto combinado más grande para obtener una estimación más precisa de esa característica". Para estudiar los diferentes tipos de *pooling* en las siguientes subsecciones, se supone un conjunto de datos que cuenta con un total de n disparos al arco realizados por J jugadores distintos. Cada uno de ellos tiene una cantidad determinada de disparos n_j con $j = 1, ..., J$, es decir, $n = \sum_{j=1}^{J} n_j$.

3.5.1. *Pooling* completo

Una de las posibles maneras de estudiar el mencionado conjunto de datos es considerando una única población: el modelo ignora completamente la información acerca del jugador que dispara. No se contempla que existan diferencias entre jugadores, ni el hecho de que algunos futbolistas cuenten con más o menos disparos. Este es, de hecho, el enfoque con el que suelen construirse los modelos más difundidos en el ámbito del fútbol.

En términos de contrucción del modelo, todos los disparos se describen mediante la misma distribución de probabilidad. En ese sentido, el *pooling* completo equivale a fijar los valores de los hiperparámetros, tal y como se especifica en la Sección 3.4. Si se considera

nuevamente la variable indicadora de gol (Y) como variable respuesta y la distancia al arco (X) como única variable explicativa, el modelo de regresión logística utilizando el *pooling* completo para el disparo i-ésimo al arco realizado por el j-ésimo jugador se expresa de la siguiente manera:

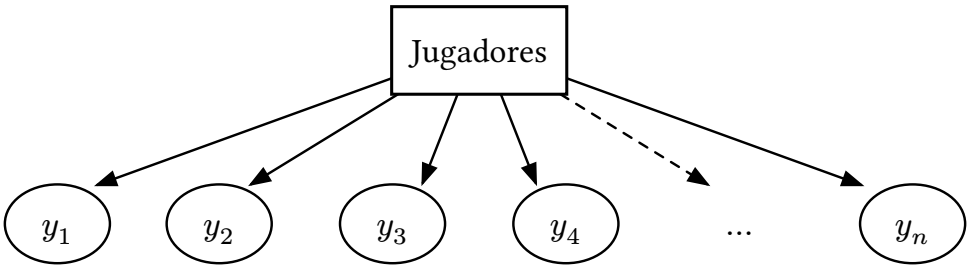
$$\begin{aligned} Y_{ij} \mid \pi_{ij} \sim \text{Bernoulli}(\pi_{ij}) \quad \text{con} \quad \ln\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) &= \beta_0 + \beta_1 x_{ij} \\ \beta_0 &\sim \mathcal{N}(m_0, s_0^2) \\ \beta_1 &\sim \mathcal{N}(m_1, s_1^2) \end{aligned} \tag{41}$$

siendo m_0, s_0, m_1 y s_1 la esperanza y el desvío estándar de cada una de las distribuciones *a priori*. Estos valores deben ser fijados por el investigador en base a previas experiencias.

La consecuencia de construir modelos utilizando el *pooling* completo es que los disparos de algunos jugadores obtendrán valores de xG mayores a los que realmente corresponden (sus actuaciones serán sobreestimadas), mientras que otros recibirán valores más bajos de los que merecen (sus actuaciones serán subestimadas), ya que se está ignorando quién es el futbolista que patea al arco en cada caso.

Figura 11

Estructura general para un modelo con pooling completo



Nota. Figura de elaboración propia a partir de *Bayes Rules! An Introduction to Applied Bayesian Modeling*, por A.A. Johnson, M. Q. Ott & M. Dogucu, 2021.

3.5.2. *No pooling*

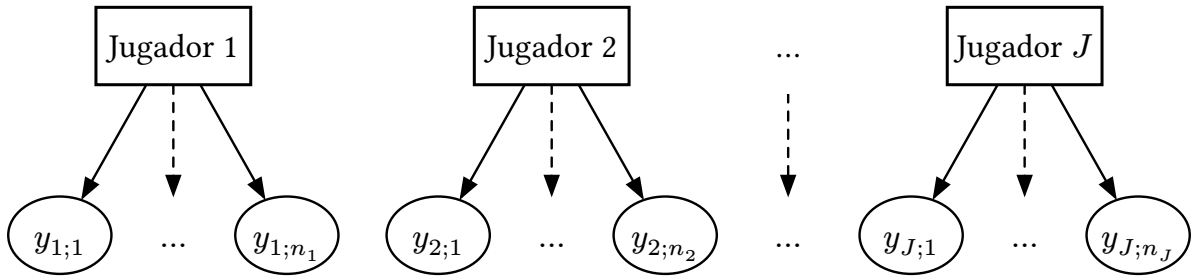
Otra forma de modelar el conjunto de datos mencionado consiste en considerar que cada jugador constituye su propia población. Para el cálculo del xG asociado a un determinado futbolista, se utilizan exclusivamente los datos que refieran a sus disparos, dejando de lado los realizados por cualquier otro. En estos casos, el tamaño muestral sí es un aspecto a tener en cuenta ya que, si se incorpora un disparo de un nuevo deportista a la base, sus valores de xG serán estimados solamente con ese dato, generando estimaciones potencialmente inestables.

En lo relativo a la construcción del modelo, el enfoque de *no pooling* consiste en que cada jugador cuente con sus propios parámetros individuales a los que se les asigna su propia distribución *a priori*, sin introducir una estructura jerárquica que los vincule entre sí. En este caso, no se comparte información entre los jugadores, ya que cada uno cuenta con un intercepto y una pendiente específicos, independientes de los de los demás. Esto es:

$$
\begin{aligned}
Y_{ij} \mid \pi_{ij} \sim \text{Bernoulli}(\pi_{ij}) \quad \text{con} \quad \ln\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) &= \beta_{0j} + \beta_{1j} x_{ij} \\
\beta_{0j} &\sim \mathcal{N}(m_{0j}, s_{0j}^2) \\
\beta_{1j} &\sim \mathcal{N}(m_{1j}, s_{1j}^2)
\end{aligned}
\tag{42}
$$

donde m_{0j}, s_{0j}, m_{1j} y s_{1j} para $j = 1, ..., J$ representan la esperanza y el desvío estándar de cada una de las distribuciones *a priori* para el j-ésimo jugador, siendo estos valores que deben ser fijados por el investigador en base a previas experiencias. También es posible ajustar este tipo de modelos considerando únicamente un intercepto específico por jugador, pero suponiendo una pendiente común para todos, lo que, en términos del problema, equivale a asumir que la probabilidad de gol se modifica de la misma manera ante aumentos en la distancia al arco para todos los futbolistas. Análogamente, es posible ajustar el modelo considerando un intercepto general y pendientes específicas por jugador.

Figura 12
Estructura general para un modelo con no pooling



Nota. Figura de elaboración propia a partir de *Bayes Rules! An Introduction to Applied Bayesian Modeling*, por A.A. Johnson, M. Q. Ott & M. Dogucu, 2021.

3.5.3. *Pooling* parcial y modelos jerárquicos

En tercer lugar, y como punto medio entre los dos enfoques anteriores, existe el *pooling* parcial, que da lugar a lo que se conoce como modelos jerárquicos o multiniveles. Si bien cada futbolista es único, el hecho de provenir de una misma población hace que estén relacionados (Johnson et al., 2021). En el caso particular de los remates al arco realizados por distintos futbolistas, aunque cada uno tenga características propias y existan quienes finalicen las jugadas mejor que otros, todos comparten una cualidad fundamental: son deportistas de élite que dedican su vida al entrenamiento y que, en muchos casos, compiten en contextos similares. Existe una justificación para combinar su información. Así, para obtener las estimaciones que refieran a un jugador en específico, no solo se hace uso de la información de sus disparos, sino también de la proveniente de los restantes jugadores.

En lo que refiere al modelado, para establecer una estructura jerárquica se debe considerar un único *prior* general para los parámetros específicos de todos los jugadores.

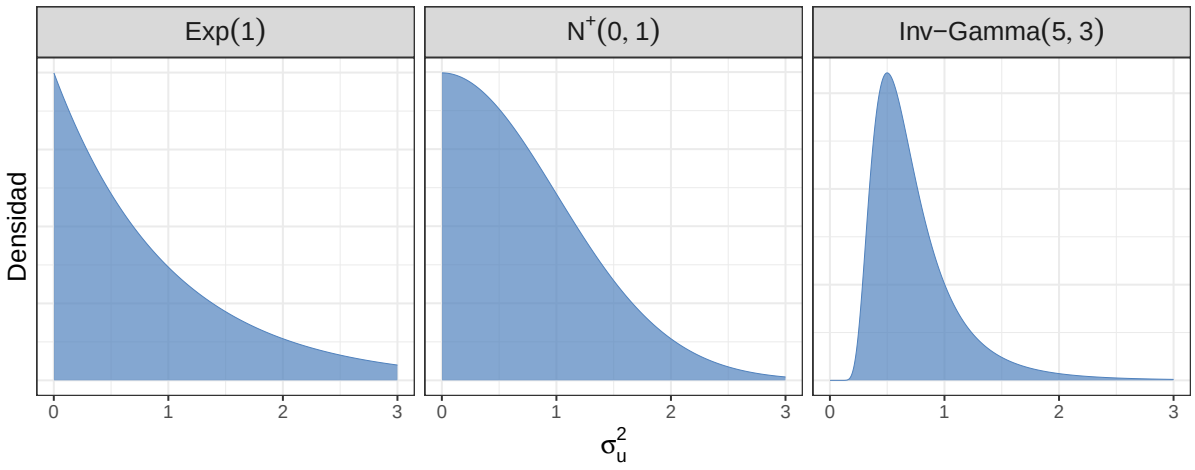
$$
Y_{ij} \mid \pi_{ij} \sim \text{Bernoulli}(\pi_{ij}) \quad \text{con} \quad \ln\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) = \beta_{0j} + \beta_{1j} x_{ij}
$$

$$
\begin{aligned}
&\beta_{0j} \sim \mathcal{N}\left(\mu_{\beta_0}, \sigma^2_{\beta_0}\right) \\
&\mu_{\beta_0} \sim \mathcal{N}(m_0, s_0^2) \quad \text{y} \quad \sigma_{\beta_0} \sim \text{Inv-Gamma}(a_0, b_0) \\
&\beta_{1j} \sim \mathcal{N}\left(\mu_{\beta_1}, \sigma^2_{\beta_1}\right) \\
&\mu_{\beta_1} \sim \mathcal{N}(m_1, s_1^2) \quad \text{y} \quad \sigma_{\beta_1} \sim \text{Inv-Gamma}(a_1, b_1)
\end{aligned}
\tag{43}
$$

Nuevamente, y de la misma manera que en el *no pooling*, el modelo puede ajustarse incorporando interceptos específicos y una pendiente general, o bien un intercepto general y pendientes específicas.

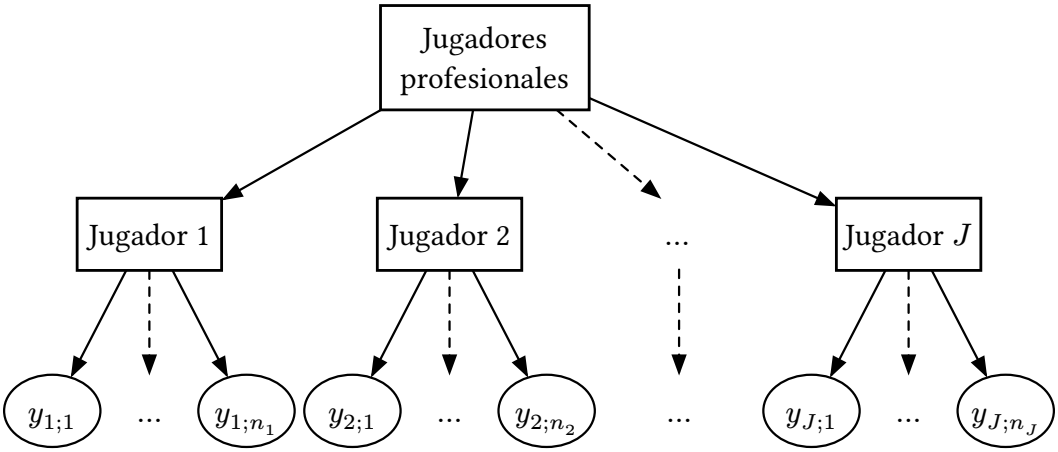
En (43) se consideran distribuciones gamma inversa para los parámetros de variabilidad, pudiendo hacerse uso de cualquier distribución con soporte en los números reales positivos. Su elección por sobre otras alternativas comúnmente utilizadas, como las distribuciones exponencial o media-normal, se debe a que, bajo un enfoque de *pooling* parcial, se busca permitir la estimación de la variabilidad entre grupos a partir de los datos sin imponer *a priori* una concentración excesiva de masa de probabilidad en valores cercanos a cero. En este sentido, como se aprecia en la Figura 13, la distribución gamma inversa asigna una mayor probabilidad a valores moderados de la desviación estándar, evitando una regularización excesivamente fuerte hacia modelos con variabilidad prácticamente nula.

Figura 13
Posibles distribuciones a priori del hiperparámetro σ_u^2



Cabe resaltar también que, si bien la utilización de modelos jerárquicos para incorporar el efecto del jugador no es una práctica exclusiva de la inferencia bayesiana, bajo este enfoque dicha estructura se integra de manera natural, dado que todos los parámetros del modelo son tratados como variables aleatorias. En este marco, los modelos mixtos –que combinan parámetros comunes a toda la población con componentes específicos por grupo o individuo– surgen como una extensión directa del modelo, sin requerir cambios conceptuales sustantivos. En cambio, bajo el enfoque clásico, el pasaje entre modelos con parámetros comunes y modelos que incorporan variabilidad entre unidades mediante efectos aleatorios implica un cambio de formulación, ya que se trata de esquemas distintos y con procedimientos de estimación específicos en cada caso. Estos aspectos, junto con la posibilidad de incorporar información previa mediante distribuciones *a priori* para los parámetros, terminan de justificar la utilización del enfoque presentado en estas secciones.

Figura 14
Estructura general para un modelo con pooling parcial



Nota. Figura de elaboración propia a partir de *Bayes Rules! An Introduction to Applied Bayesian Modeling, por A.A. Johnson*, M. Q. Ott & M. Dogucu, 2021.

Tabla 1
Principales aspectos de los tres enfoques presentados

Aspecto	***Pooling* completo**	**No *pooling***	***Pooling* parcial**
Supuesto sobre los disparos	Todos los disparos provienen de una misma población, sin distinguir entre jugadores	Los disparos provienen de poblaciones específicas de cada jugador, independientes entre sí	Los disparos provienen de distribuciones específicas de cada jugador, y se asume que estas poblaciones provienen de una población común
Uso de la información	Se utilizan todos los disparos, ignorando quién los realiza	Las estimaciones para cada jugador se nutren solo de sus propios disparos	Las estimaciones para cada jugador se nutren solo de sus propios disparos y, en cierta medida, de los del resto
Estructura del modelo	Un único intercepto y una única pendiente para todos	Interceptos y/o pendientes específicos por jugador, independientes entre sí	Interceptos y/o pendientes específicos por jugador que provienen de una distribución común

Aspecto	*Pooling* completo	No *pooling*	*Pooling* parcial
Sensibilidad al tamaño muestral por jugador	Nula	Alta (estimaciones inestables para jugadores con pocos disparos)	Moderada (el modelo se adapta al tamaño muestral de cada jugador)
Desventajas	Sobrestimar a algunos jugadores y subestimar a otros	Sobreajuste y alta variabilidad en las estimaciones	Mayor complejidad y necesidad de especificar correctamente las jerarquías
Ventajas	Simplicidad	Flexibilidad individual	Balance entre sesgo y varianza

3.6. Herramientas para la comparación de modelos

Para evaluar y comparar los modelos que se proponen, resulta necesario analizar tanto el comportamiento de sus estimaciones como su concordancia con referencias externas. Una de las formas para determinar el desempeño de cada modelo es a través de examinar la distribución de la probabilidad de gol estimada en diferentes situaciones, reales o ficticias, comunes o poco usuales, nuevas o conocidas en el entrenamiento. También es necesario cotejar las estimaciones con valores de xG reportados por empresas proveedoras, de manera que pueda determinarse si el rendimiento es efectivamente cercano al que se usa en la práctica, tal y como se plantea en uno de los objetivos de este trabajo. Mientras que los modelos de regresión logística tradicionales utilizados por dichas empresas resultan en valores de xG puntuales, el enfoque bayesiano provoca que los resultados sean distribuciones de probabilidad y, por ende, los modelos que en esta tesina se construyen deben ser comparados mediante elementos que permitan contrastar toda la información comprendida en los *posteriors* a los que se arribe. El fin de esta subsección es el de presentar gráficos y métricas que permitan determinar la calidad de los resultados alcanzados por cada uno de los modelos.

Una de las herramientas más tradicionales para dimensionar la calidad de las estimaciones obtenidas son las distribuciones predictivas *a posteriori* para la cantidad de goles totales convertidos por un jugador. Es decir, distribuciones que reflejan la probabilidad de que un futbolista en específico convierta un determinado número de goles, en base a todos sus disparos, al modelo y a los *priors* elegidos.

Luego de ajustar los modelos, para cada disparo en particular se contará con un total de S muestras de la distribución *a posteriori* de π_i. Para la construcción de la distribución predictiva *a posteriori* de un jugador, digamos j, se traduce cada valor de probabilidad en un resultado real: disparo convertido o disparo errado.

$$Y_i^{(s)} \sim \text{Bernoulli}\left[\pi_i^{(s)}\right] \text{ con } i = 1, ..., n_j \text{ y } s = 1, ..., S \tag{44}$$

siendo n_j la cantidad total de disparos realizados por el j-ésimo jugador en todos los torneos considerados. De este modo, para cada muestra del *posterior* s se obtiene un vector de resultados simulados $\left[Y_1^{(s)}, Y_2^{(s)}, ..., Y_{n_j}^{(s)}\right]$ donde cada componente indica si el disparo correspondiente terminó en gol o no bajo esa realización del modelo. A partir de estos valores,

se define la cantidad total de goles simulados para el jugador j en la muestra s como $G^{(s)} = \sum_{i=1}^{n_j} Y_i^{(s)}$. Finalmente, la distribución buscada se obtiene a partir de la distribución empírica de G, estimando las probabilidades de cada posible cantidad de goles mediante sus frecuencias relativas. Este procedimiento también puede realizarse en conjunto para todos los jugadores en estudio, a través de la totalidad de los remates de la base. Asimismo, puede calcularse utilizando los xG informados por las empresas proveedores, caso en el que se contará con un único valor de π_i para cada disparo y, consecuentemente, con un fuente menos de incertidumbre. En todos los casos, las distribuciones obtenidas se comparan entre sí y con la cantidad real de goles observada.

Tanto al comparar las distribuciones del xG con las estimaciones de las empresas, o las distribuciones predictivas *a posteriori* con la cantidad de goles convertidos, siempre se busca evaluar si estos valores puntuales son cubiertos por los intervalos de credibilidad que se obtienen a partir de dichas distribuciones y, también, cuán estrechos son esos intervalos. Una herramienta que suele utilizarse con este fin, pero que permite aprovechar toda la información contenida en los *posteriors*, es el *Continuous Ranked Probability Score* (CRPS). Para introducirlo resulta útil partir del error absoluto medio (MAE), la métrica habitual para cuantificar el promedio de las diferencias absolutas entre dos conjuntos de valores puntuales x_i y x_i^*:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|x_i - x_i^*| \tag{45}$$

El CRPS extiende esta misma idea de distancia al caso en que uno de los dos términos sea una distribución de probabilidad completa.

Sea F la función de distribución acumulada correspondiente a una distribución *a posteriori* y sea x^* un valor puntual con el que se pretende compararla. El CRPS se define como:

$$\text{CRPS}(F, x^*) = \int_{-\infty}^{\infty} \left[F(y) - \mathbb{1}(y - x^*)\right]^2 \mathrm{d}y \tag{46}$$

donde $\mathbb{1}$ es la función escalón unitario que toma el valor 1 cuando el argumento es positivo o cero y el valor 0 en cualquier otro caso. Gneiting y Raftery (2007) demostraron que la expresión presentada en (46) es equivalente a:

$$\text{CRPS}(F, x^*) = \mathbb{E}|X - x^*| - \frac{1}{2}\mathbb{E}|X - X'| \tag{47}$$

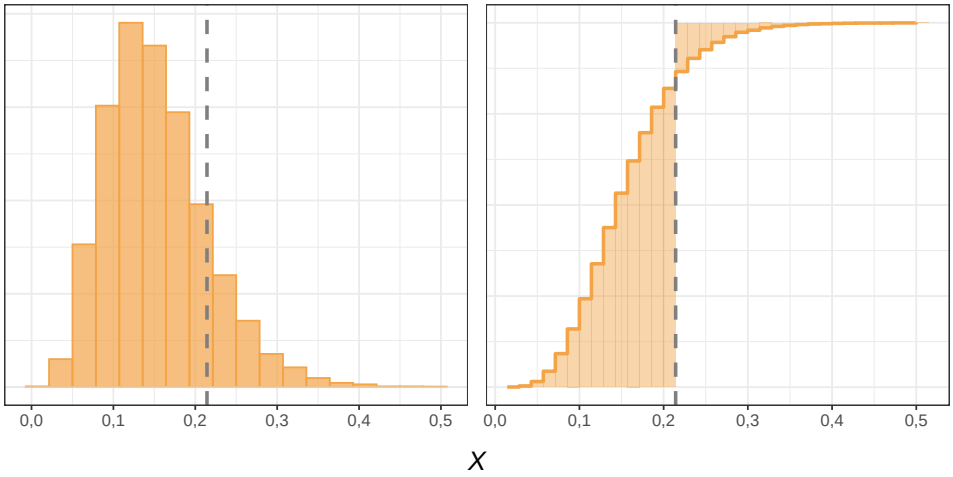
siendo X y X' dos variables aleatorias independientes e idénticamente distribuidas según la función F. En la práctica, cuando se cuenta con una distribución F empírica construida con S muestras del *posterior*, el CRPS puede aproximarse mediante sumatorias siguiendo la descomposición en cuantiles propuesta por Laio y Tamea (2007) y adoptada en el paquete `{scoringRules}` de R (Jordan et al., 2019):

$$\text{CRPS}\left[x^{(1:S)}, x^*\right] = \frac{1}{S}\sum_{s=1}^{S}\left|x^{(s)} - x^*\right| - \frac{1}{S^2}\sum_{s=1}^{S}(2s - S - 1)x_{(s)} \tag{48}$$

donde $x^{(s)}$ es el s-ésimo valor de la muestra y $x_{(s)}$ es el s-ésimo valor de la muestra ordenada de menor a mayor. Bajo una perspectiva gráfica, el CRPS se incrementa conforme las áreas pintadas del segundo panel de la Figura 15 son más grandes. Esta medida representa un error de estimación y, por ende, se buscará obtener valores cercanos a cero en todos los casos.

Otra herramienta de gran utilidad para la comparación de resultados con la realidad son los gráficos de calibración. Estos permiten contraponer en un mismo panel las probabili-

Figura 15
Distribuciones ficticias para ilustrar el cálculo del CRPS



Nota. En el panel izquierdo se presenta una distribución ficticia *a posteriori* y en el derecho su correspondiente función de distribución acumulada. La línea punteada representa el valor puntual con el que se pretende realizar la comparación.

dades estimadas por los modelos con las proporciones reales de goles observadas en dichas situaciones. De este modo, es posible evaluar si los casos a los que el modelo asigna una determinada probabilidad de finalizar en gol efectivamente son concretados con una frecuencia similar a la estimada. Estos gráficos sí se construyen a partir de estimaciones puntuales y no de distribuciones de probabilidad, motivo por el cual se decide resumir los *posteriors* de cada disparo mediante sus valores medios. Los registros se ordenan según sus estimaciones de xG y se agrupan en intervalos de igual tamaño, para luego calcular la proporción de goles observada y un intervalo empírico, obtenido a partir del promedio de las estimaciones del intervalo y de sus percentiles 5 y 95. Si el modelo resulta calibrado, los intervalos que se grafican deberían alinearse a la recta identidad.

Debe resaltarse que en este trabajo los gráficos de calibración no se construyen de la manera tradicional. El procedimiento aquí descripto considera invertidas las variables de los ejes respecto de su representación convencional, donde los intervalos se construyen de manera paramétrica y donde es necesario asumir que los disparos son independientes e idénticamente distribuidos. Si bien podría considerarse que el supuesto de independencia se cumple, puede no resultar correcto asumir que todos los remates de cada uno de los grupos formados tengan la misma probabilidad de conversión. El mero hecho de incluir la distancia o el ángulo de tiro como variables explicativas de los modelos contradice la idea de distribuciones idénticas. Al intercambiar las variables de los ejes, no es necesario realizar ningún supuesto adicional y sigue siendo posible estudiar qué tan calibrados se encuentran los modelos.

Será necesario complementar todas las comparaciones gráficas hasta aquí presentadas con ciertas métricas que permitan cuantificar el grado de ajuste de los modelos a la realidad. Con ese objetivo, se propone utilizar dos medidas. En primer lugar, la puntuación de Brier (Brier, 1950), que se obtiene de la siguiente manera:

$$BS = \frac{1}{n}\sum_{i=1}^{n}(\hat{\pi}_i - y_i)^2 \tag{49}$$

donde $\hat{\pi}_i$ es el valor de xG estimado por el modelo para el i-ésimo disparo e y_i es su resultado final observado, si terminó en gol o no. Y, por otro lado, la pérdida logarítmica:

$$L = -\frac{1}{n}\sum_{i=1}^{n}[y_i \ln(\hat{\pi}_i) + (1 - y_i)\ln(1 - \hat{\pi}_i)] \tag{50}$$

que penaliza de manera más severa aquellas probabilidades más alejadas del resultado observado. En ambos casos, si se quiere tener en cuenta toda la información contenida en las distribuciones, el procedimiento consiste en calcular las métricas para cada una de las S muestras del *posterior* de cada disparo y luego resumirlas en una única medida del error por disparo a través de su valor medio. Por otro lado, si el objetivo es comparar el desempeño de alguno de los modelos construidos con el brindado por Stats Perform, este procedimiento debe invertirse, ya que, de lo contrario, los modelos bayesianos se encontrarían en desventaja. En dicho caso, resulta adecuado primero resumir el *posterior* de cada disparo en un único valor y, posteriormente, calcular las métricas a partir de ellos.

4. Materiales

4.1. Fuentes de datos

Desde planillas en las que se dibujaban los disparos al arco hasta cámaras con detección de movimiento instaladas en los estadios, la forma de recolección de datos de los partidos ha ido evolucionando con el paso de los años. Con ella también ha cambiado la manera en la que se analizan y, consecuentemente, los resultados a los que con ellos es posible arribar.

Dentro del análisis del fútbol moderno se pueden distinguir principalmente cuatro tipos de datos (Anzer et al., 2024). En primer lugar, los generales o de planilla (*match sheet data*) que recogen la información descriptiva de los partidos. Los nombres de los equipos participantes, la cantidad de goles, las sustituciones o la cantidad de tarjetas son ejemplos de situaciones habituales que quedan registradas con el objetivo de obtener una constancia simple y acotada de los encuentros, ya sea para el público general como para las ligas en sí mismas. Se trata de valores muy importantes para el desarrollo de los partidos y para el control de los torneos, que muchas veces son captados directamente por los árbitros que dirigen los enfrentamientos. Por otro lado, existen los llamados datos de eventos (*event data* o *play-by-play data*), que refieren a cada una de las acciones que se producen durante los noventa minutos que duran los partidos. Dentro de este tipo de información no solo se tiene en cuenta las acciones vinculadas al balón –como pases, disparos al arco o regates–, sino también otras como infracciones o posiciones adelantadas. Aquí intervienen empresas recolectoras y proveedoras de datos como Stats Perform, Wyscout o StatsBomb que cuentan con *software* propios y establecen sus propios procesos de recolección; aunque, en general, recurren a operadores que ingresan manualmente cada una de las situaciones en directo o a partir de videos de los partidos. El tercer tipo de registro con el que se suele trabajar es el de los datos de seguimiento (*tracking data*), asociado a las posiciones y movimientos de los jugadores y de la pelota dentro de la cancha. Cámaras de filmación y dispositivos utilizados por los propios futbolistas son algunas de las formas en las que se recolecta este tipo de información. Finalmente, puede considerarse un cuarto tipo de datos, relativo a la información física de los jugadores (*player physical data*). Estos incluyen métricas como la velocidad o la distancia recorrida, o bien parámetros fisiológicos tales como la frecuencia cardíaca o los niveles de fatiga. Suelen obtenerse a partir de dispositivos portátiles –como GPS o chalecos con sensores–, y resultan fundamentales tanto para el análisis del rendimiento individual como para la prevención de lesiones. También forman parte de esta categoría los datos biométricos de los futbolistas, como su altura, peso o perfil de pierna hábil. A diferencia de los datos de seguimiento, aquí el foco está en la condición física y la carga de trabajo del jugador, más que en su posición exacta dentro del terreno de juego.

A su vez, es posible considerar un subgrupo de datos intermedio entre los de eventos y los de seguimiento, los denominados datos 360°, que intentan brindar información sobre el contexto en el que se desarrollan las acciones registradas en los datos de eventos. Son comercializados principalmente por la empresa StatsBomb y también reciben el nombre de *freeze-frame data* ya que muestran la posición dentro de la cancha, en formato de coordenadas, de todos los jugadores participantes y del balón en cada una de las situaciones del juego. Para su medición es posible emplear cámaras con capacidad de ofrecer una visión integral del campo de juego en todo momento –llevado a cabo por empresas privadas, de elevado costo y cuya instalación debe realizarse en el estadio donde se disputa el encuentro–, o bien extraer información posicional de las cámaras empleadas en las transmisiones televisivas, que no siempre abarcan la totalidad del escenario pero permiten observar con detalle la zona principal donde se desarrolla la acción (Umemoto & Fujii, 2023). A partir de las filmaciones obtenidas, una persona realiza de manera manual la carga y sistematización de la información

correspondiente. Sin embargo, los desarrollos recientes basados en inteligencia artificial y visión por computadora permiten automatizar este proceso mediante el uso de modelos avanzados –incluyendo redes temporales y arquitecturas basadas en grafos– que posibilitan mapear con precisión el posicionamiento de los veintidós jugadores, incluso cuando algunos de ellos se encuentran fuera del encuadre, gracias a técnicas de extrapolación inteligente del movimiento (SkillCorner, s. f.).

4.1.1. Diferencias de criterios entre empresas proveedoras de datos de eventos

Al existir tantas empresas diferentes que se dedican a recolectar y distribuir los datos de las grandes ligas de este deporte, a la hora de realizar cualquier análisis se generan distintos desafíos asociados a las diferencias de criterios utilizados por ellas. Estos desafíos pueden agruparse en tres grandes grupos.

El primer punto a tener en cuenta es la discrepancia en las especificaciones que cada empresa utiliza para cada tipo de evento. De esta manera, cada una de ellas cuenta con pautas específicas para determinar dentro de qué clase de evento se incluyen las jugadas que se van desarrollando. Un claro ejemplo de este problema se presenta cuando un jugador desde una zona lateral de la cancha da un pase a un compañero que se encuentra dentro del área rival. Para un proveedor esa situación puede considerarse simplemente como un pase más, pero otro la puede incluir dentro de la categoría de "centro al área" con una elevación del balón nula. Este problema se produce por la necesidad de dividir un juego tan complejo en eventos independientes para su posterior estudio. Si bien la International Football Association Board (IFAB, 2023) define en su sección de Reglas de Juego algunos de los eventos vitales para el desarrollo de los duelos, este conjunto limitado no alcanza para estudiar completamente lo que en ellos sucede.

Otro problema con el que se encuentran los analistas al estudiar datos provenientes de distintas empresas es el asociado a las alteraciones para representar cada registro. Diferencias en el sistema de coordenadas utilizado, en la orientación de la cancha o en los identificadores únicos de jugadores y equipos, provocan que no sea directo el solapamiento de dos bases de datos incluso cuando se trabaja con el mismo partido y con idénticos eventos considerados.

Por último, es importante tener en cuenta la calidad de los datos disponibles. Al ser una tarea con un gran componente manual el relevar la información de los eventos, es común que se presenten diversos errores, principalmente con respecto a los minutos del partido en los que ocurre cada acción, a las ubicaciones de los disparos o incluso a los nombres de los jugadores protagonistas. Es tarea de cada empresa proveedora el intentar reducir estos problemas generando procesos para confirmar a grandes rasgos la veracidad de las bases de datos otorgadas. Resulta prácticamente imposible por parte de los clientes y analistas el controlar que todos los registros con los que trabajan sean un reflejo exacto de lo que realmente sucedió en los enfrentamientos, más si se cuenta con un gran volumen de datos como los que se utilizan para ajustar modelos de probabilidad de gol; sin embargo, es importante destacar la importancia de controlar y preprocesar las bases de datos que se obtienen de estas empresas y no confiar ciegamente en lo que en ellas se muestra.

4.1.2. Convenios de las empresas proveedoras

Como es esperable, a medida que se incrementa la cantidad de información registrada sobre las jugadas de los partidos, las empresas proveedoras requieren una mayor inversión de recursos para su medición, tanto materiales como humanos. En consecuencia, la disponibilidad de datos tiende a disminuir conforme aumenta su nivel de granularidad, dificultando su obtención. No obstante, estas empresas no solo establecen convenios con ligas y clubes de distintas partes del mundo para venderles los datos que recolectan, sino también con canales

de televisión, casas de apuestas y plataformas de estadísticas deportivas, como FotMob, FBRef o Sofascore, entre otras. De este modo, existen bases de datos públicas que permiten a investigadores y aficionados calcular métricas, resumir lo sucedido en los partidos, crear visualizaciones y ajustar sus propios modelos estadísticos, aunque siempre con ciertas limitaciones. En principio los datos que ofrecen estos sitios son suficientes para realizar análisis básicos o ajustar modelos de xG simples, aunque pueden presentar algunas dificultades si se quiere replicar exactamente los utilizados por las grandes empresas proveedoras.

En este sentido, es fundamental considerar qué partidos y qué torneos se quieren incluir para la construcción de los modelos, dado que la disponibilidad de datos varía según la competición. Por ejemplo, la cantidad y calidad de información existente sobre las cinco grandes ligas europeas es considerablemente mayor que la disponible para la mayoría de las competiciones latinoamericanas, lo que impone restricciones adicionales a este tipo de estudios.

4.2. Recolección de datos

Aunque con ciertas restricciones, las páginas *web* constituyen una fuente de información de gran valor para la construcción de bases de datos propias sobre diversos eventos deportivos. Se puede encontrar una gran variedad de sitios que presentan datos acerca de los torneos del fútbol argentino, pero no todos poseen los necesarios para la construcción de modelos de probabilidad de gol, como los que se busca construir en esta tesina. Muchas de estas plataformas cuentan con tablas que intentan resumir lo ocurrido durante los encuentros (o durante los torneos en su totalidad), generando una base de registros para llevar a cabo un análisis general de la liga en su conjunto. Sin embargo, la construcción de los ya mencionados modelos requiere de información específica sobre cada uno de los disparos al arco que ocurrieron en una extensa cantidad de partidos.

En el presente trabajo, la recolección de información se realizó mediante técnicas de *web scraping*. Este término refiere al procedimiento de extraer de manera sistemática los datos publicados en páginas de internet a través de programas que simulan la navegación humana, para luego almacenarlos en un formato estructurado que facilite su posterior procesamiento y análisis (Khder, 2021). Se hizo uso de la librería `{LanusStats}` de Python (Rábanos, 2024) que permite acceder a los datos presentados en tablas de diferentes sitios *web* mediante técnicas de este tipo.

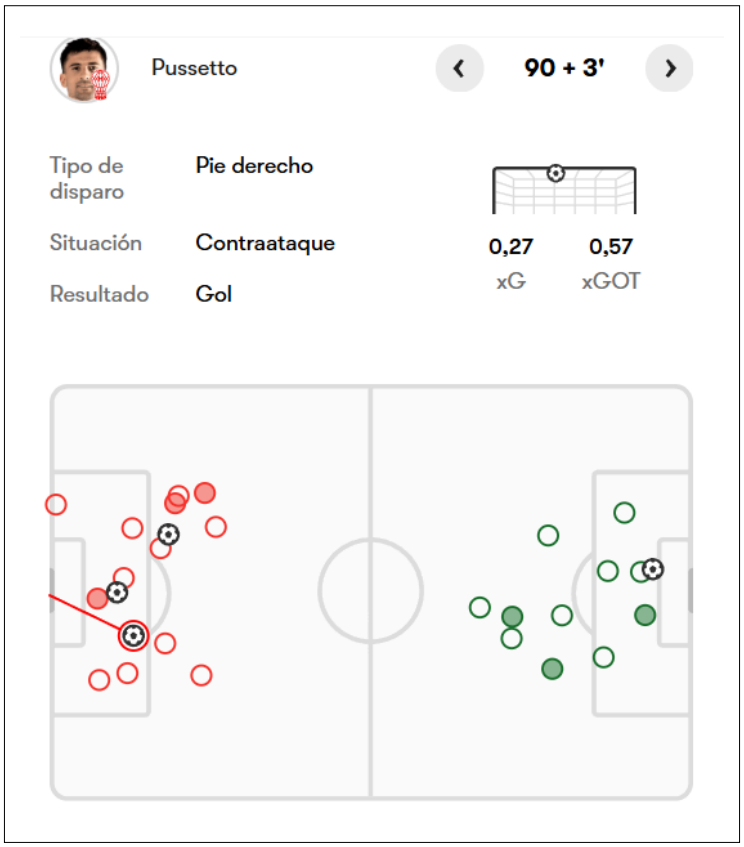
Las páginas *web* elegidas como fuentes de información fueron FotMob y FBRef, ambas provistas de datos por la empresa Stats Perform. Para su elección se tuvieron en cuenta dos aspectos que resulta pertinente destacar. En primer lugar, y como ya se mencionó anteriormente, para el entrenamiento de los modelos de xG se requiere de información detallada de cada disparo al arco, siendo que una variable de suma importancia para su ajuste es la ubicación dentro la cancha desde la que este se realiza. Entonces, la elección de la página *web* debía estar sujeta a que permitiera obtener las coordenadas X e Y de los tiros al arco, con las que posteriormente se obtendría la distancia y el ángulo de estos. Por otro lado, y en vista de que el objetivo de esta tesina se encuentra enfocado al fútbol argentino, los disparos se debían corresponder con torneos actuales de la Liga Profesional.

Estos dos puntos acotan en cierta medida el número de sitios de los que se debe recabar información. La plataforma FotMob cuenta con secciones apartadas para torneos de diversos países del mundo, abarcando ligas nacionales y torneos de selecciones, e incluyendo no solo las principales competiciones de primera división, sino también aquellas correspondientes a categorías juveniles. Dentro de la sección específica de Argentina es posible encontrar, entre muchas otras, una subsección que refiere a las competiciones con formato de liga y otra para las que terminan con cruces de eliminación directa. Esta división de los torneos facilita

encontrar las competiciones específicas que se busquen y tiene su justificación en que, en los últimos años, la estructura del principal torneo nacional ha sufrido muchas alteraciones. Se han modificado en varias ocasiones el número de equipos participantes, la cantidad de torneos que se juegan en un año calendario y el formato de estos últimos, pasando de jugar torneos estructurados en modalidad de liga (donde cada equipo se enfrenta a todos los demás) a jugar ligas que terminan con sistemas de *playoff*, nombrados como Copa de la Liga. En la Figura 16 se muestra la forma en la que el mencionado sitio *web* presenta la información de cada disparo al arco que se realizó.

Figura 16

Mapa de remates del partido entre Huracán y Defensa y Justicia por la primera fecha de la Liga Profesional Temporada 2024



Nota. Figura tomada de FotMob, 2025. El disparo que aparece destacado corresponde al segundo gol marcado por Ignacio Pussetto.

Con respecto al período en el tiempo, si bien la plataforma tiene datos sobre el fútbol argentino de los últimos quince años, para no todos los partidos cuenta con el registro de los disparos al arco en particular, hecho que limitó la elección a los disputados a partir del año 2023. Luego, como al momento del *scrapeo* de los datos, el torneo del primer semestre del 2025 se estaba llevando a cabo, el límite superior se estableció en la última competición previa a este. De esta manera se obtuvo una base compuesta por un total de 28.298 registros que refieren a todos los disparos realizados durante los torneos comprendidos entre 2023 y 2024 detallados en la Tabla 2. Se destaca que todos los torneos contaron con la participación de 28 equipos.

Tabla 2
Características de cada uno de los torneos considerados

Nombre del torneo	Formato	Fecha de inicio	Fecha de finalización	Cantidad de partidos disputados	Cantidad de disparos al arco realizados[a]
Torneo Binance 2023	Todos contra todos	27/01/23	30/07/23	378	9.164
Copa Sur Finanzas 2023	Dos zonas y una instancia de eliminación directa[b]	17/08/23	16/12/23	204[c]	4.870
Copa Sur Finanzas 2024	Dos zonas y una instancia de eliminación directa	25/01/24	05/05/24	203	5.196
Torneo Betano 2024	Todos contra todos	10/05/24	16/12/24	378	9.068

Nota. [a]Contando los realizados en instancias de penales en las eliminaciones directas. [b]El torneo se organiza en dos zonas de 14 equipos cada una, en las que se enfrentan todos contra todos dentro de su zona, sumado a un partido interzonal. Luego, los cuatro mejores de cada grupo clasifican a instancias de eliminación directa (cuartos de final, semifinales y una final en estadio neutral). [c]203 partidos del torneo más un partido de desempate por la permanencia en Primera División.

Stats Perform, en su sitio *web*, reporta que considera todo intento deliberado de marcar como un disparo, diferenciando aquellos dirigidos estrictamente hacia los tres palos (*shot on target*) de los que no lo fueron (*shot off target*) (Stats Perform, s. f.-b). Esto significa que la base de datos aquí utilizada cuenta tanto con disparos concretados como desviados, atajados o bloqueados por rivales o compañeros ya que, según Herranz Martínez (2026, p. 44), "el bloqueo es un evento posterior a la decisión de tirar y excluir estos remates sesgaría a la baja la representación de las ocasiones realmente generadas".

Resulta importante hacer hincapié en que, para ajustar modelos de esta clase, la cantidad de registros debe ser considerablemente grande. Dentro de la industria no hay un estándar fijado sobre la cantidad mínima de disparos que se necesitan para que los resultados obtenidos sean confiables, pero se debe contar con todos los que sea posible debido a la ya mencionada baja frecuencia de goles que ocurre. Si bien estos son los sucesos más importantes de los partidos y determinan en gran medida la calidad de estos, su tasa de aparición es relativamente baja si se los compara con la cantidad de disparos que en ellos se presentan o con la cantidad de conversiones que ocurren en otros deportes. Para dimensionar este fenómeno,

simplemente basta con elegir cualquier torneo y observar la proporción de goles en relación a la cantidad de tiros al arco. En la Liga Profesional de Fútbol Argentino disputada en el año 2024 se pateó un total de 9.068 veces al arco de los que solamente 769 fueron convertidos, esto es, un 8,48%. En el caso particular de esta tesina, la cantidad de datos debía de ser particularmente grande por el objetivo adicional de incorporar el efecto específico del jugador. Si ya de por sí la cantidad de goles por partido es baja, la cantidad de goles de cada jugador por partido lo es aún más.

Por otra parte, y en línea con uno de los objetivos específicos establecidos, resulta imprescindible disponer de información detallada sobre los jugadores que realizan los disparos, en particular respecto a la posición en la que se desempeñan. Dado que FotMob no provee este tipo de registros, se optó por realizar el proceso de *scraping* en la plataforma FBRef, a partir de la cual se obtuvo un listado de todos los jugadores que participaron de los cuatro torneos considerados, con información específica de cada uno de ellos.

4.3. Limpieza de la base de datos

4.3.1. Depuración y construcción de variables adicionales

Antes de avanzar con el análisis, fue necesario realizar un proceso de limpieza y transformación de la base de datos, orientado a depurar inconsistencias y estandarizar los registros. En primer lugar, resultó pertinente elaborar un listado de los equipos participantes en los torneos seleccionados que funcionara como diccionario y que permitiera reemplazar los IDs utilizados por FotMob por los nombres reales de los clubes correspondiente a cada registro.

Por otro lado, dado el papel central que ocupa el jugador que realiza el disparo en este estudio, y considerando que –como se señaló en secciones anteriores– el relevamiento de cada dato puede presentar diversos errores, se llevó a cabo un control destinado a evitar repeticiones en los nombres de los futbolistas y a corregir posibles inconsistencias en sus identificadores únicos, situación frecuente al trabajar con datos de diferentes años. Esta tarea se realizó porque, si bien FotMob genera un ID que se repite en cada acción realizada por un mismo jugador, este no necesariamente coincide con el utilizado por la plataforma FBRef, o por cualquier otro sitio diferente. De este modo, para poder combinar la información de ambas bases de datos, el identificador único de cada disparo resulta ser el nombre y apellido del futbolista. Nombres escritos de manera errónea o falta de incorporación de un segundo nombre para distinguir personas con mismo primer nombre y apellido, fueron algunos de los problemas que se presentaron al buscar unificar las bases de datos. Los cambios realizados se encuentran detallados en el Anexo.

Una vez homogeneizados los nombres de los futbolistas, fue posible integrar la información de ambas bases de datos. Esto es, incorporar la posición en la que se desempeñan los jugadores, registrada en la base de FBRef, a los datos de cada disparo provenientes de FotMob. Esta nueva variable dividía a los jugadores en cuatro grandes categorías:

- GK: Arqueros (*goalkeepers*).
- DF: Defensores (*defenders*).
- MF: Mediocampistas (*midfielders*).
- FW: Delanteros (*forwards*).

Sin embargo, es sabido que muchos futbolistas se desempeñan en más de una posición, por lo que en esos casos el sitio informa sobre las dos posiciones principales de ellos, ordenadas según la cantidad de partidos disputados en cada una. Por ejemplo, Kevin Zenón

ha jugado algunos partidos como mediocampista y otros como delantero, dependiendo del esquema táctico. Dicho jugador recibe, para FBRef, un valor de posición igual a "MF, FW", ya que disputó más partidos en la primera de esas posiciones que en la segunda. Esto permite que sea posible recategorizar las posiciones genéricas otorgadas, en otras que reflejen un poco más la realidad de los equipos. Un jugador que ha disputado partidos tanto de mediocampista como de defensor, seguramente se destaque más por su faceta defensiva que ofensiva, a diferencia de alguien que ha jugado encuentros como mediocampista y delantero, cuyas cualidades normalmente favorecen el ataque de su equipo. También existen casos en los que, por decisiones tácticas, lesiones o expulsiones, algunos delanteros han tenido que jugar como defensores y viceversa. Estos casos no son tenidos en cuenta en la recategorización debido a su baja frecuencia dentro de la base y a que se consideran situaciones excepcionales. La recategorización aquí descripta se presenta en la Tabla 3.

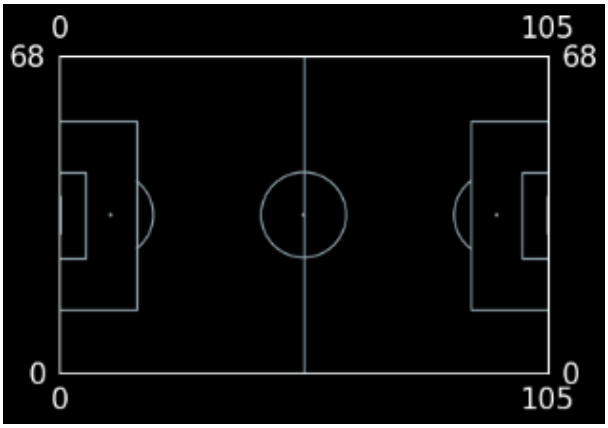
Tabla 3
Recategorización de las posiciones brindadas por FBRef

Posiciones generadas por FBRef	Posiciones recategorizadas	Cantidad de jugadores
GK	Arquero	12
DF	Defensor	365
DF, MF	Defensor	91
DF, FW	Defensor	28
MF	Mediocampista no ofensivo	319
MF, DF	Mediocampista no ofensivo	56
MF, FW	Mediocampista ofensivo	238
FW	Delantero	209
FW, DF	Delantero	24
FW, MF	Delantero	249

Otra parte de la depuración de la base de datos consistió en convertir las coordenadas X e Y registradas en cada disparo en variables derivadas de mayor utilidad analítica, como la distancia y el ángulo de tiro. Para esto, fue necesario dimensionar la cancha en términos de las mencionadas coordenadas. Se compararon los valores mínimos y máximos de cada una de las dos variables, para luego buscar los disparos específicos realizados desde esos valores extremos de ubicación. De esta manera, los límites del campo de juego expresados en términos de X e Y resultaron ser los que se muestran en la Figura 17. Estos valores encuentran su justificación en que la Fédération Internationale de Football Association (FIFA, s.f.) recomienda que las canchas midan 105×68 metros. Se debe tener en cuenta que, para homogeneizar

la información brindada, Stats Perform (y en consecuencia FotMob) considera que todos los disparos se generan hacia el arco ubicado en la línea de fondo con coordenada X igual a 105.

Figura 17
Sistema de coordenadas utilizado por Stats Perform



Nota. Figura adaptada de la documentación de la librería `{mplsoccer}`, por A. Durgapal & A. Rowlinson (2025).

A partir de las medidas presentadas en la Figura 17, es posible obtener la ubicación exacta de los postes y del punto medio de los arcos, parámetros necesarios para la construcción de las variables antes nombradas. Para esto se debe tener en cuenta que el arco tiene una longitud igual a 7,32 metros. En la Tabla 4 se presentan dichas ubicaciones expresadas en términos de coordenadas.

Tabla 4
Coordenadas de puntos clave del campo de juego

Punto del campo de juego	Coordenadas
Punto medio del arco al que se dispara	$(105; 34)$
Poste inferior del arco[a]	$(105; 30{,}34)$
Poste superior del arco[a]	$(105; 37{,}66)$

Nota. [a]En relación a la Figura 17.

De esta manera, es posible calcular la distancia desde una determinada ubicación $(x; y)$ hasta el centro del arco con coordenadas $(105; 34)$ utilizando la fórmula de la distancia euclídea:

$$d_{(x;y)} = \|(105; 34) - (x; y)\| = \sqrt{(105 - x)^2 + (34 - y)^2} \tag{51}$$

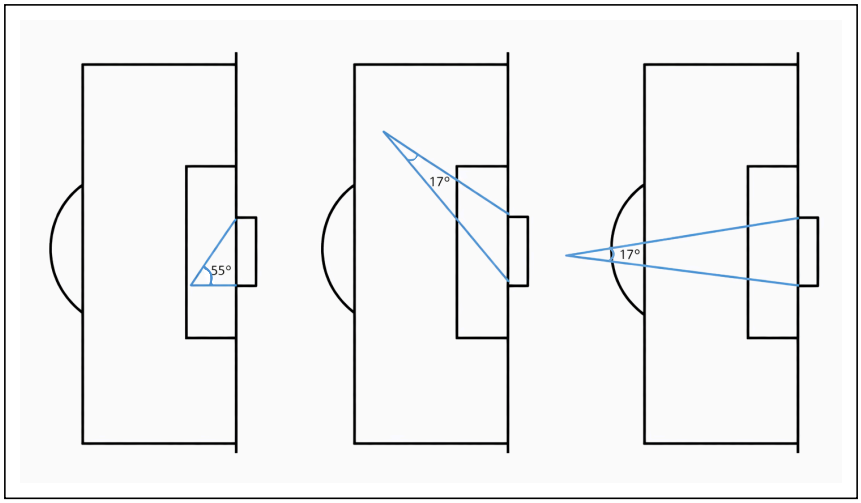
La segunda variable derivada de las coordenadas y que también es de suma importancia en este tipo de modelos es el ángulo de tiro. Para obtener el ángulo con respecto a ambos palos del arco de un disparo realizado desde la ubicación $(x; y)$ se hace uso del Teorema del Coseno. Esto es:

$$\varphi_{(x;y)} = \cos^{-1}\left(\frac{a^2 - b^2 - c^2}{-2bc}\right) \times \frac{180}{\pi} \tag{52}$$

siendo:

- $a = 7{,}32$ la longitud del arco,
- $b = \sqrt{(105 - x)^2 + (30{,}34 - y)^2}$ la distancia hasta uno de los palos del arco,
- $c = \sqrt{(105 - x)^2 + (37{,}66 - y)^2}$ la distancia hasta el otro palo del arco.

Figura 18
Ilustración de distintos ángulos de tiro posibles



Nota. Figura tomada de *Soccermatics*, por D. Sumpter, 2022.

Ya con la distancia y el ángulo de tiro calculados, fue posible tener una visión general de cada uno de los disparos relevados. Este análisis permitió identificar inconsistencias en algunos valores de las coordenadas, que evidenciaban errores en la ubicación: ciertos disparos aparecían con distancias de más de cien metros, cuando en realidad no lo habían sido. Dichas inconsistencias se originaron en partidos que, por motivos extra futbolísticos, debieron ser interrumpidos y reanudados en otra fecha, lo que ocasionó que en algunos casos la cancha apareciera registrada en sentido inverso. Los datos que presentaron este tipo de error fueron corregidos.

Los torneos de la Liga Profesional de Fútbol se rigen bajo el reglamento establecido por la IFAB y, en consecuencia, las dimensiones de los terrenos de juego pueden variar dentro de los límites establecidos por dicho organismo: entre 90 y 120 metros de longitud y entre 45 y 90 metros de ancho (International Football Association Board, 2023; Liga Profesional de Fútbol, 2023), mientras que las medidas de las restantes partes de la cancha, tales como las áreas de meta, las áreas penales o el círculo central, deben permanecer inalteradas. El que los partidos puedan disputarse en canchas de diversas dimensiones podría generar un sesgo en los valores de xG que se obtengan, debido a que la distancia y el ángulo desde los que se realizan los disparos no necesariamente deberían ser calculados de igual manera en todos los encuentros. Teniendo en cuenta la forma en la que son capturados los registros, el problema se presentaría únicamente en aquellos remates que se realicen desde fuera del área penal, los cuales representan aproximadamente un 28% del conjunto final considerado.

Transfermarkt, uno de los sitios *web* más populares dentro de esta industria, reporta las medidas exactas de cada una de las canchas del fútbol argentino. Entre los campos de juego estudiados en este trabajo, el de mayor tamaño corresponde al de San Lorenzo de Almagro, con 110 metros de largo y 70 metros de ancho. Por el contrario, el estadio de Deportivo Riestra, con dimensiones de 100×60 metros, presenta el menor tamaño. Teniendo en cuenta que la máxima diferencia de tamaños entre canchas no es excesiva, que no se ve afectada la totalidad de disparos de la base y en pos de ajustar modelos que permitan obtener probabilidades de gol en situaciones nuevas, muchas veces sin contar con información adicional sobre los campos de juego, en esta tesina se calcula la distancia y el ángulo de igual manera para todos los registros, es decir, mediante las fórmulas presentadas en (51) y (52). Queda propuesto como trabajo futuro determinar si esta variabilidad en los tamaños de las canchas puede sesgar los valores de xG de determinados jugadores o equipos que juegan sistemáticamente en canchas más grandes o más chicas que el resto.

4.3.2. Filtrado de datos

Con la base de datos ya depurada fue posible avanzar al filtrado de estos. No necesariamente todos los registros resultaban útiles para el ajuste de los modelos de probabilidad de gol, por lo que, en esta etapa, se descartaron un subconjunto de filas de la base construida. Como primer punto, se dejaron de lado los disparos asociados a las tandas de penales que servían como método de desempate en los partidos de eliminación directa de los torneos que contaban con *playoff*. Se descartaron así 98 registros. Adicionalmente, se debe considerar que en los modelos de xG no son tenidos en cuenta los autogoles, es decir, los goles convertidos por jugadores en su propio arco. El número de disparos excluidos en este punto fue de 65. Por último, como el objetivo de este trabajo estaba puesto en comparar modelos que evalúen la probabilidad de convertir en situaciones de jugadas, se descartaron los disparos generados a partir de pelotas paradas. Así, fueron excluidos 1.310 tiros libres directos, 2.162 disparos generados a partir de un tiro libre (ya sea directo o indirecto), 4.522 disparos que se produjeron luego de un córner y 287 penales pateados durante el desarrollo de los partidos. Asimismo, se descartaron los 29 disparos realizados con partes del cuerpo distintas de la pierna o la cabeza, dado que este tipo de acciones no representan situaciones habituales dentro del desarrollo normal de los partidos y, por lo tanto, no resultan pertinentes para el análisis de la probabilidad de gol en contextos de juego estándar. La base final contó entonces con un total de 19.460 disparos al arco y su desagregación por competencia se presenta en la Tabla 5. Se destaca también que, al llevar adelante este filtrado de datos, quedaron descartados todos los disparos realizados por arqueros.

Tabla 5
Cantidad de disparos por torneo utilizados para el entrenamiento de los modelos

Nombre del torneo	Cantidad de disparos al arco considerados
Torneo Binance 2023	6.309
Copa Sur Finanzas 2023	3.317
Copa Sur Finanzas 2024	3.685
Torneo Betano 2024	6.149

5. Aplicación

Para presentar los resultados obtenidos a partir del entrenamiento de los modelos, la presente sección se organiza en cuatro subsecciones. En primer lugar, se incluye una subsección dedicada a cada uno de los modelos construidos, en la que se los expresa formalmente desde un punto de vista matemático y que tiene como objetivo facilitar la interpretación de los valores a los que con ellos se arriba. Luego, se presenta una subsección destinada a la comparación de los resultados obtenidos con ellos.

Con base en lo postulado en la Sección 4, los modelos que se explicitan a continuación se construyeron a partir de un conjunto de datos que reunía un total de 19.460 disparos al arco realizados por 1.052 jugadores diferentes. Con la finalidad de expresar matemáticamente los modelos construidos, se define:

$$Y_i = \begin{cases} 1 \text{ si el } i\text{-ésimo disparo termina en gol} \\ 0 \text{ en caso contrario} \end{cases} \tag{53}$$

con $i = 1, ..., 19.460$ y siendo $\pi_i = P(Y_i = 1)$. Además, resulta pertinente destacar que, con el objetivo de facilitar la obtención de muestras del *posterior*, se optó por estandarizar las variables numéricas utilizadas. Esta aclaración es importante para que los valores elegidos para los hiperparámetros de los *priors* resulten coherentes.

Para la obtención de las muestras del *posterior* se utilizaron cuatro cadenas de 4.000 muestras cada una. Todas las distribuciones que se ilustren en la presente sección se acompañan de su valor medio y de un intervalo de credibilidad del 90%. Los diagnósticos asociados a la representatividad de las muestras se encuentran detallados en el Anexo. En todos los casos se observó una adecuada mezcla de las cadenas en los gráficos de trazas, junto con valores aceptables de $\hat{R}$ (menores a 1,01) y de N_{eff} (mayores a 1.250).

5.1. Modelo 1

Para la construcción del primer modelo se consideran únicamente la distancia y el ángulo de tiro, además de su interacción. El considerar el efecto conjunto de estas variables ve su justificación en lo presentado en la Figura 19, donde se observa que la tasa de conversión no depende de manera independiente de cada una de ellas, sino de su combinación. Tiros ejecutados desde distancias similares pueden presentar probabilidades de gol sustancialmente distintas en función del ángulo disponible hacia el arco, y viceversa. La inclusión del término de interacción permite representar de forma más realista la geometría del tiro y su influencia conjunta en el cálculo del xG.

En lo que refiere a la elección de *priors*, y en línea con lo expuesto en la Sección 3.4.1, se optó por utilizar distribuciones normales para cada uno de los parámetros del modelo, considerando desvíos estándares moderados en valor absoluto. En el caso de los coeficientes asociados a las variables explicativas, estas distribuciones se centraron en cero para no otorgar un peso mayor *a priori* hacia ninguna dirección. Para el intercepto, en cambio, debido a la baja proporción de goles que existe en relación con la cantidad de disparos, la distribución fue centrada en -2, lo que favorece probabilidades de gol de entre 0,029 y 0,378 para disparos a distancias y ángulos promedios, como se observa en la Figura 20. Estos valores se toman como aceptables en base al conocimiento que se tiene sobre este deporte.

Figura 19
Tasa de gol para distintos valores de distancia y ángulo de tiro

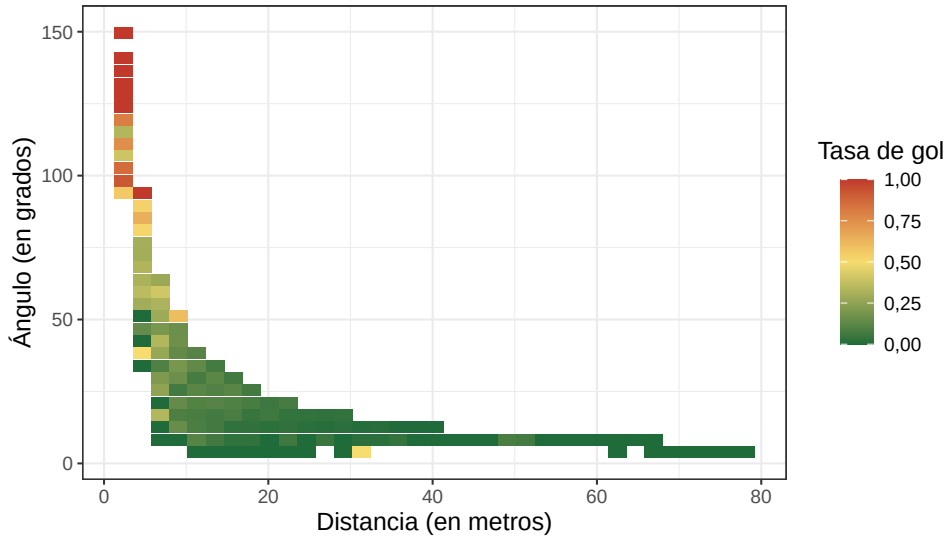
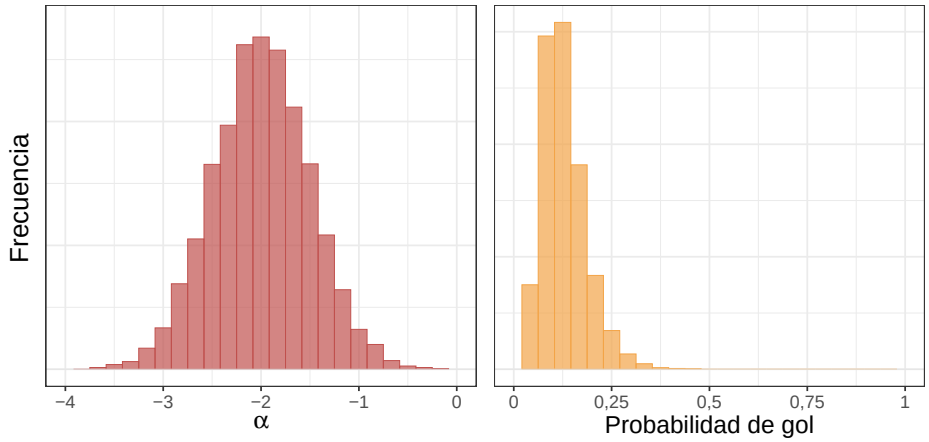


Figura 20
Distribución a priori para el intercepto α y distribución a priori de la probabilidad de gol para disparos desde una distancia y ángulo promedios inducida por el prior sobre α



El modelo construido se explicita a continuación.

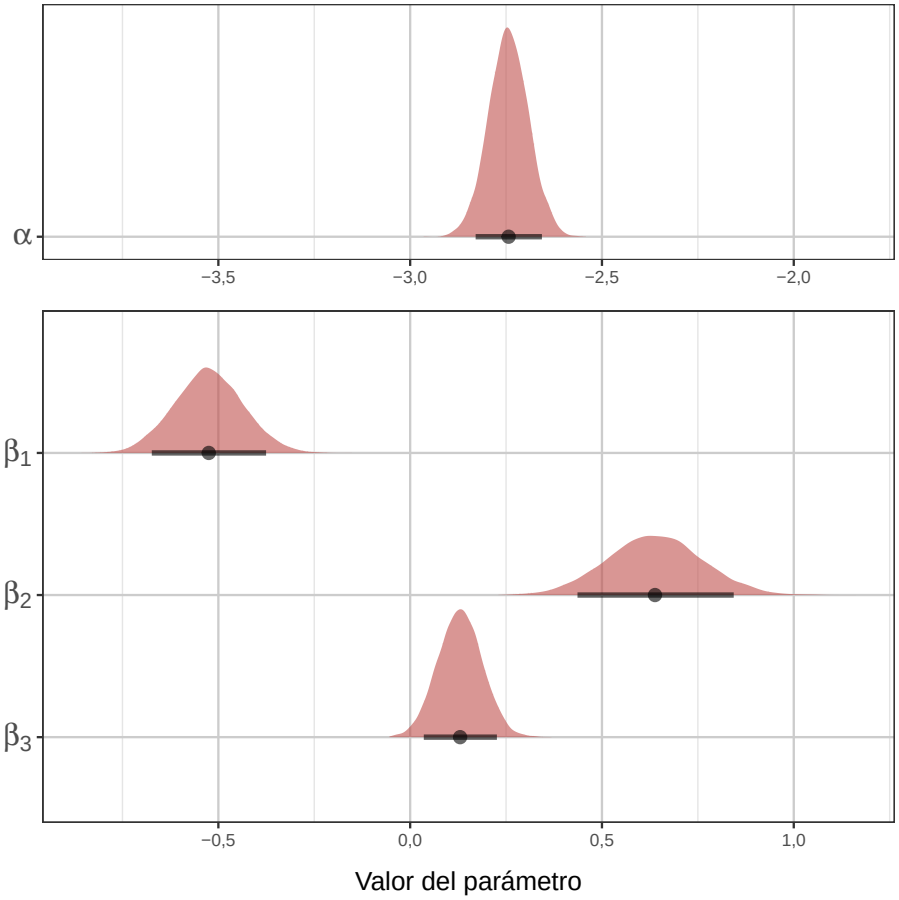
$$
\begin{aligned}
Y_i \mid \pi_i &\sim \text{Bernoulli}(\pi_i) \\
\text{logit}(\pi_i) &= \alpha + \beta_1 \text{ distancia}_i + \beta_2 \text{ ángulo}_i + \beta_3(\text{distancia}_i \times \text{ángulo}_i) \\
\alpha &\sim \mathcal{N}(-2, 0{,}5^2) \\
\beta_1 &\sim \mathcal{N}(0, 0{,}5^2) \\
\beta_2 &\sim \mathcal{N}(0, 0{,}5^2) \\
\beta_3 &\sim \mathcal{N}(0, 0{,}5^2)
\end{aligned}
$$

Las distribuciones marginales *a posteriori* para los parámetros del modelo se exponen en la Figura 21. Adicionalmente, en la Tabla 6 se presenta un resumen numérico de dichas distribuciones.

Tabla 6
Resumen de las distribuciones marginales a posteriori de los parámetros del Modelo 1

Parámetro	Media	Desvío estándar	$LI_{90\%}$	$LS_{90\%}$
α	$-2{,}743$	$0{,}052$	$-2{,}829$	$-2{,}657$
β_1	$-0{,}525$	$0{,}089$	$-0{,}674$	$-0{,}376$
β_2	$0{,}638$	$0{,}123$	$0{,}436$	$0{,}844$
β_3	$0{,}130$	$0{,}058$	$0{,}036$	$0{,}226$

Figura 21
Distribuciones marginales a posteriori de los parámetros del Modelo 1



5.2. Modelo 2

Para el segundo modelo, además de las dos variables incluidas en el primero, se incorpora la posición del futbolista que realiza el disparo. Esta variable se introduce como un efecto fijo que modifica el intercepto del modelo, es decir, se consideran cuatro interceptos diferentes, uno para cada posición de juego. El segundo modelo resulta:

$$
\begin{aligned}
Y_i \mid \pi_i &\sim \text{Bernoulli}(\pi_i) \\
\text{logit}(\pi_i) &= \alpha_{k[i]} + \beta_1 \text{ distancia}_i + \beta_2 \text{ ángulo}_i + \beta_3(\text{distancia}_i \times \text{ángulo}_i) \\
\alpha_k &\sim \mathcal{N}(-2, 0{,}5^2) \text{ para } k = 1, ..., 4 \\
\beta_1 &\sim \mathcal{N}(0, 0{,}5^2) \\
\beta_2 &\sim \mathcal{N}(0, 0{,}5^2) \\
\beta_3 &\sim \mathcal{N}(0, 0{,}5^2)
\end{aligned}
$$

Se utilizaron los mismos *priors* presentados en la subsección previa. Como se detalla en la Tabla 7, la tasa de gol correspondiente a los jugadores de cada posición es relativamente baja y parece diferir para cada una de ellas; sin embargo, en este trabajo se considera el mismo *prior* sobre el intercepto de todas las posiciones de juego. Esta decisión conservadora se toma porque utilizar los datos para modificar las distribuciones *a priori* de cada posición implicaría hacer un doble uso de ellos. Si bien podría inferirse de antemano que las cuatro posiciones tienen diferentes tasas de gol, resulta dificultoso determinar qué tan distintos o iguales deben ser dichos *priors*. Como punto adicional, debido al buen número de disparos estudiados de cada posición, es de esperar que pequeños cambios en las distribuciones no influyan considerablemente en el *posterior*.

Las distribuciones marginales *a posteriori* para los parámetros del modelo se exponen en la Figura 22, junto con un resumen numérico presentado en la Tabla 8.

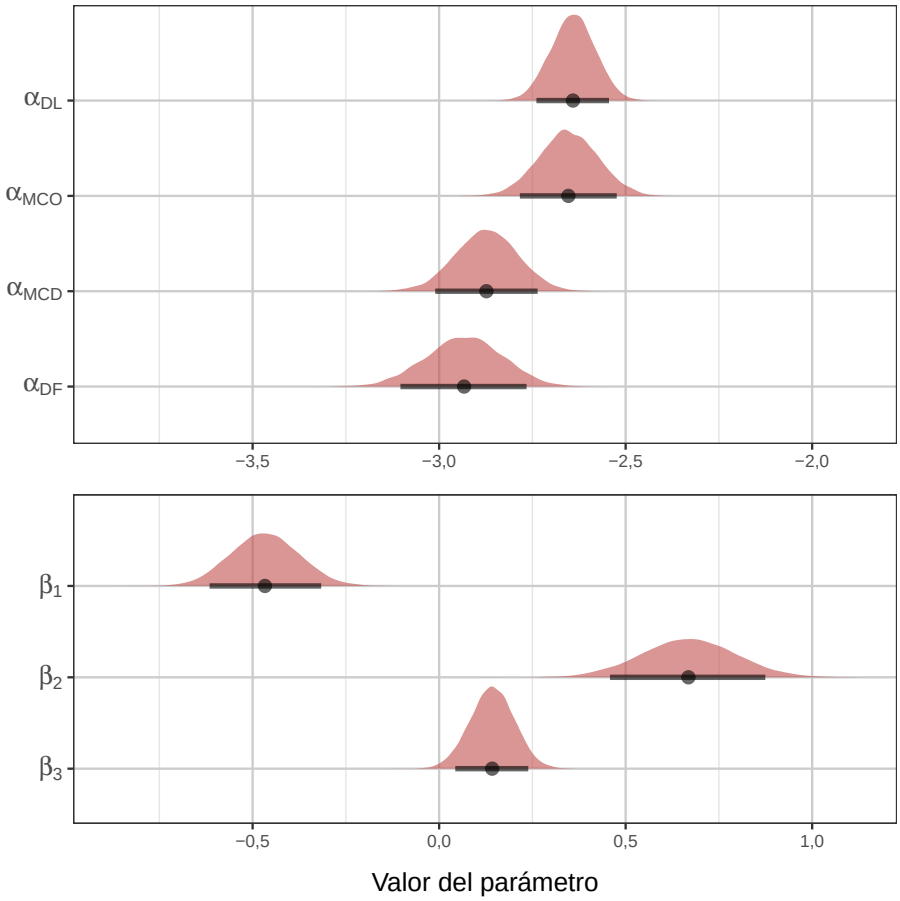
Tabla 7
Cantidad de disparos y tasa de gol por posición

Posición	Cantidad de disparos al arco	Tasa de gol
Defensores (DF)	2.750	0,045
Mediocampistas no ofensivos (MCD)	3.816	0,051
Mediocampistas ofensivos (MCO)	3.478	0,071
Delanteros (DL)	9.416	0,106

Tabla 8
Resumen de las distribuciones marginales a posteriori de los parámetros del Modelo 2

Parámetro	Media	Desvío estándar	$LI_{90\%}$	$LS_{90\%}$
α_{DF}	−2,933	0,102	−3,104	−2,766
α_{MCD}	−2,873	0,084	−3,010	−2,736
α_{MCO}	−2,653	0,079	−2,784	−2,524
α_{DL}	−2,641	0,059	−2,739	−2,545
β_1	−0,467	0,092	−0,615	−0,316
β_2	0,668	0,127	0,458	0,874
β_3	0,142	0,060	0,043	0,239

Figura 22
Distribuciones marginales a posteriori de los parámetros del Modelo 2



5.3. Modelo 3

El último de los modelos estudiados incorpora a lo ya presentado un término asociado al jugador que realiza el disparo. Al explicitar el modelo, dicho término se expresa con la letra u para diferenciarlo de los restantes parámetros que se corresponden a efectos fijos, y representa la desviación específica de un jugador respecto del intercepto general de su posición. Para el ajuste de este modelo se recurrió a la utilización del *pooling* parcial, es decir, a un modelo jerárquico: si bien se cuenta con un parámetro u para cada jugador posible, todos ellos comparten el hiperparámetro de variabilidad σ_u y, por ende, comparten información.

El tercero de los modelos considerados se explicita a continuación.

$$
\begin{aligned}
Y_i \mid \pi_i &\sim \text{Bernoulli}(\pi_i) \\
\text{logit}(\pi_i) &= \alpha_{k[i]} + u_{j[i]} + \beta_1 \text{ distancia}_i + \beta_2 \text{ ángulo}_i + \beta_3(\text{distancia}_i \times \text{ángulo}_i) \\
\alpha_k &\sim \mathcal{N}(-2, 0{,}5^2) \text{ para } k = 1, ..., 4 \\
u_j \mid \sigma_u &\sim \mathcal{N}(0, \sigma_u^2) \text{ para } j = 1, ..., 1.052 \\
\sigma_u^2 &\sim \text{Inv-Gamma}(5, 3) \\
\beta_1 &\sim \mathcal{N}(0, 0{,}5^2)
\end{aligned}
$$

$$\beta_2 \sim \mathcal{N}(0,0{,}5^2)$$
$$\beta_3 \sim \mathcal{N}(0,0{,}5^2)$$

Las distribuciones marginales *a posteriori* para los parámetros del modelo se exponen en las Figuras 23, 24 y 25. Nuevamente, en la Tabla 9 se presenta un resumen numérico de dichas distribuciones. En la última de las figuras se presentan resúmenes de las distribuciones marginales del parámetro u para 40 deportistas de la base, habiéndose seleccionado aquellos con el menor y el mayor valor medio, junto con 38 jugadores adicionales cuyos valores medios están equiespaciados entre ambos extremos.

Tabla 9
Resumen de las distribuciones marginales a posteriori para los parámetros del Modelo 3

Parámetro	Media	Desvío estándar	$LI_{90\%}$	$LS_{90\%}$
α_{DF}	−3,006	0,110	−3,190	−2,825
α_{MCD}	−2,941	0,089	−3,093	−2,796
α_{MCO}	−2,729	0,086	−2,871	−2,586
α_{DL}	−2,731	0,067	−2,842	−2,621
β_1	−0,467	0,092	−0,617	−0,316
β_2	0,695	0,126	0,488	0,906
β_3	0,147	0,059	0,050	0,246
σ_u	0,164	0,026	0,125	0,210

Figura 23
Distribución marginal a posteriori del parámetro de variabilidad del Modelo 3

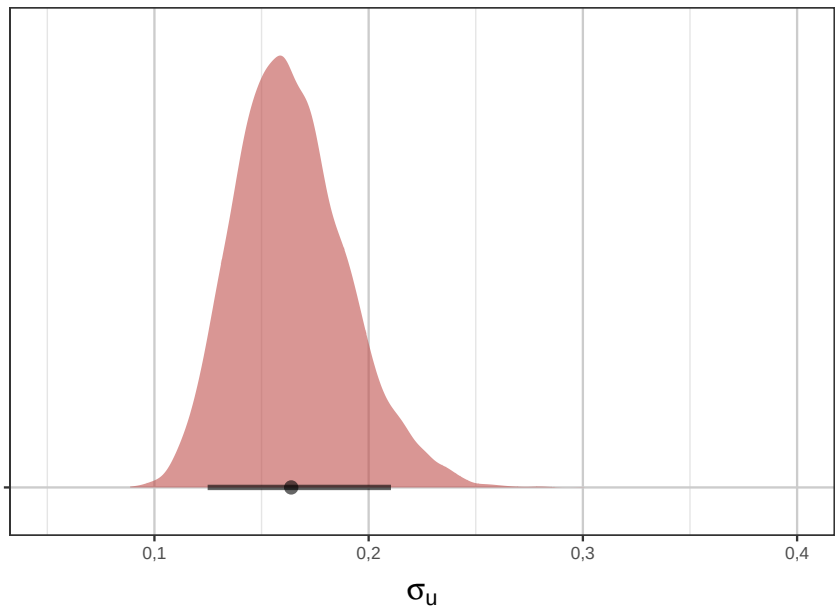


Figura 24
Distribuciones marginales a posteriori de los parámetros asociados a los efectos fijos del Modelo 3

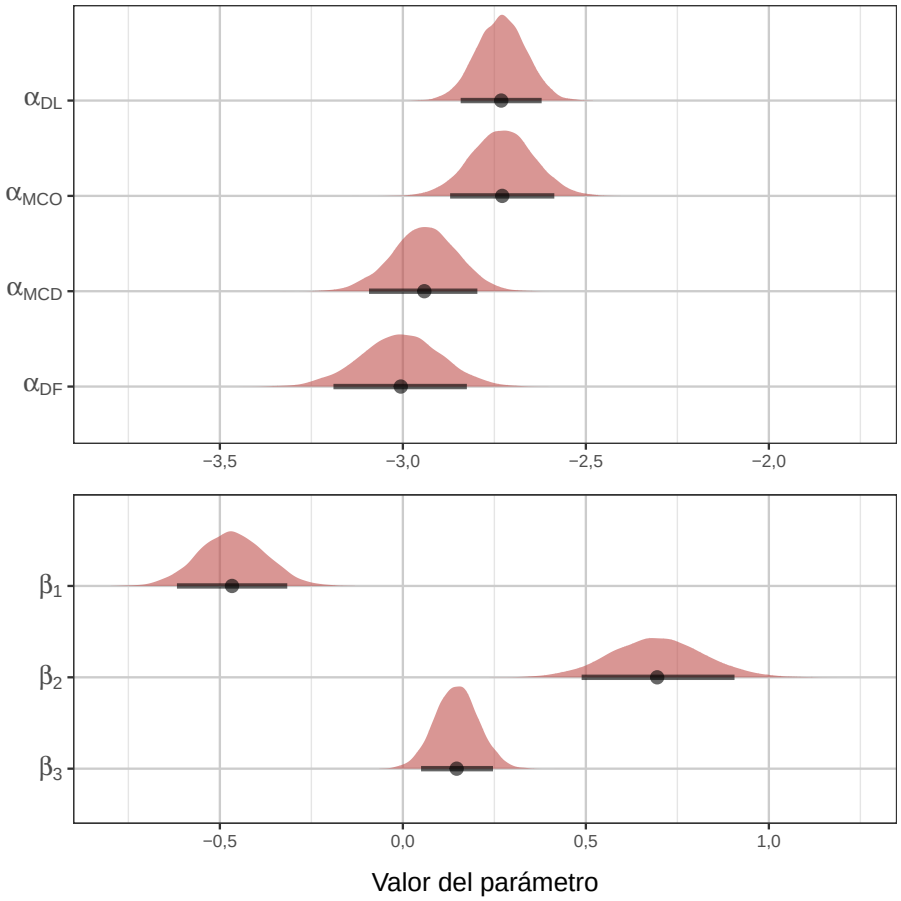
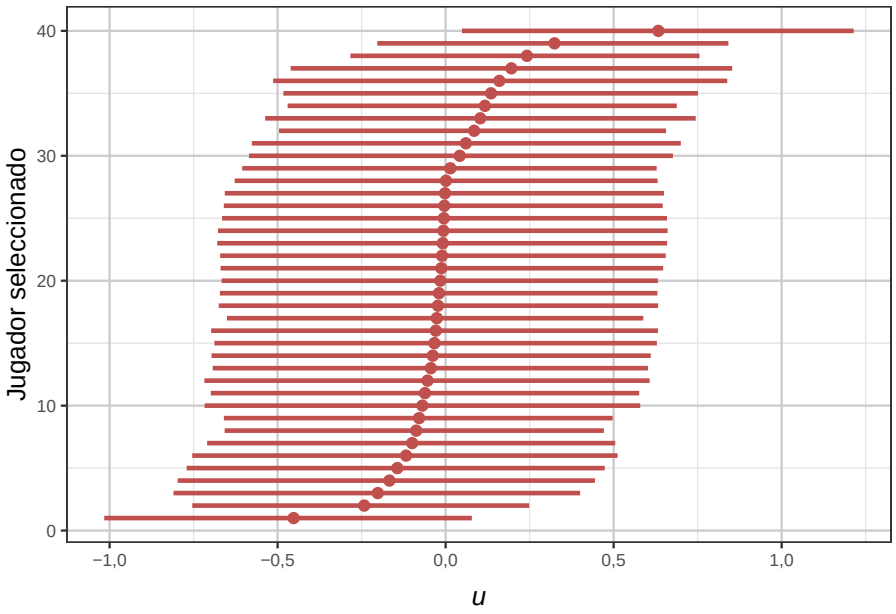


Figura 25
Resúmenes de las distribuciones marginales a posteriori del parámetro u para una selección de jugadores



5.4. Comparación de modelos

Para comparar el desempeño de los modelos construidos y, en vista de que la inclusión de las variables que refieren a la posición y al jugador que realiza el disparo forma parte del objetivo central de esta tesina, en primer lugar, se considera adecuado corroborar si su incorporación produce un cambio significativo en los resultados obtenidos por un modelo que cuenta tanto con la distancia y el ángulo de tiro como con su interacción. Los intervalos de credibilidad del 90% expuestos en las Tablas 6, 8 y 9 constituyen una primera idea sobre la relevancia de incorporar estos términos asociados a las características del disparo. En los tres modelos, los *posteriors* marginales de los coeficientes indican un efecto negativo de la distancia al arco sobre el logit de la probabilidad de gol, y un efecto positivo tanto del ángulo de tiro como de su interacción con la distancia. Estos signos coinciden con lo reportado en la literatura sobre el xG y con la lógica del juego: cuanto más lejos y más cerrado es el ángulo, menor es la probabilidad de convertir. Cabe destacar que el signo positivo del término de interacción debe interpretarse en conjunto con los efectos principales de distancia y ángulo, y no de forma aislada, ya que la relación geométrica entre ambas variables restringe la ocurrencia conjunta de valores extremos de las dos en los disparos observados. Por otra parte, dado que los goles son una fracción pequeña del total de disparos, los *posteriors* marginales de los interceptos se concentran en valores negativos. Conclusiones similares se obtienen respecto a la posición del jugador en el segundo y tercer modelo. En ambos casos se distinguen dos grandes grupos de jugadores: ofensivos (conformado por mediocampistas ofensivos y delanteros) y no ofensivos (conformado por el resto de los mediocampistas y los defensores).

La Figura 25 ya permite visualizar que, en el tercero de los modelos, la distinción de los disparos según quién es el jugador que los ejecuta puede generar variaciones en los valores de probabilidad de gol que se determinen. La probabilidad de que el valor de u asociado al jugador con mayor media supere al asociado al jugador con menor media resulta ser aproximadamente 0,98. Sin embargo, también es pertinente destacar que son pocos los jugadores que parecen distinguirse significativamente del resto, ya que una gran proporción de ellos presenta valores similares de u, debido, por un lado, a que muchos jugadores del fútbol local, al considerar el efecto de la distancia, el ángulo y su posición, exhiben rendimientos comparables y, por otro, al efecto de *shrinkage* hacia la media, comportamiento habitual en los modelos jerárquicos (Lambert, 2018).

Si bien las figuras y tablas mencionadas proporcionan una primera aproximación acerca de si es adecuado incorporar las variables en estudio en el cálculo del xG, lo verdaderamente importante es estudiarlas de manera conjunta, en relación a los valores de probabilidad de gol que generan. A continuación, la comparación de resultados se presenta desagregada en dos partes; una primera en la que se busca exponer el comportamiento de la probabilidad de gol estimada en algunas situaciones puntuales, y otra destinada a evaluar el desempeño conjunto de las estimaciones. En este marco, la evaluación no debe limitarse únicamente a comparar las estimaciones generadas por los modelos entre sí, sino que también debe contemplar su contraste con los valores de xG proporcionados por Stats Perform, disponibles en los sitios de los cuales fueron extraídos los datos. Si bien nada asegura que estos valores sean una representación fidedigna de la realidad, se considera en esta tesina que constituyen una referencia razonable ya que surgen de modelos desarrollados con grandes volúmenes de datos, con una amplia variedad de variables relevantes y empleando metodologías consolidadas en la industria.

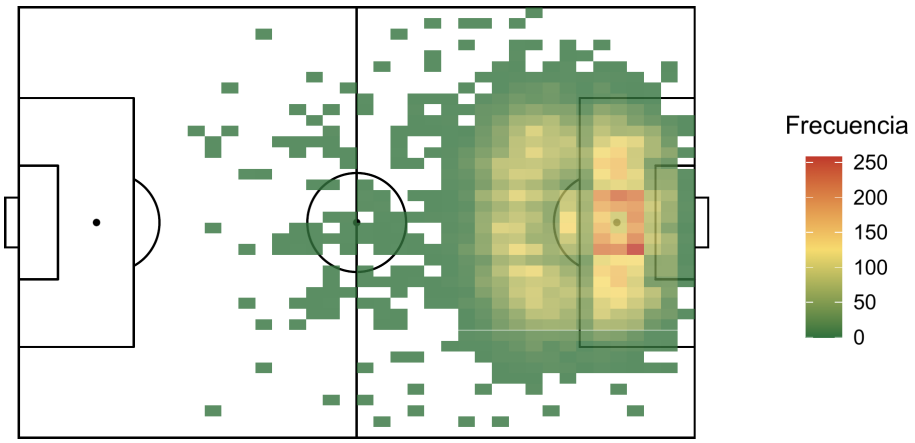
5.4.1. Comportamiento de las predicciones en situaciones puntuales

Esta primera parte de la comparación tiene como fin mostrar en detalle cómo se comportan los modelos en situaciones específicas, cuándo fallan y en qué casos su utilización resulta adecuada. Asimismo, se busca mostrar de manera visual, las diferencias entre un enfoque frecuentista, que estima valores puntuales de probabilidad, como lo es el utilizado por Stats Perform, y uno bayesiano, en el que dichos valores se representan mediante una distribución de probabilidad y donde la incertidumbre queda reflejada en su amplitud.

Toda estimación obtenida a partir de un modelo depende en gran medida del número de datos utilizado en su ajuste. Como primer punto de comparación entre los modelos aquí desarrollados se estudia cómo estos se desenvuelven en una situación "típica" dentro de la base de datos construida y ante una situación menos habitual en ella. Las Figuras 27, 28 y 29 ilustran la distribución *a posteriori* de la probabilidad de gol para cada uno de los modelos considerando una distancia y un ángulo típico. Para obtener la ubicación de dicho disparo, en primera instancia se determinó el cuadrante de la cancha desde el que mayormente se disparó durante los torneos considerados (ver Figura 26). Posteriormente, se calculó la ubicación central de dicho cuadrante en coordenadas X e Y, y estas se transformaron en valores reales de distancia y ángulo. Este procedimiento se realiza debido a que no cualquier combinación de dichas variables es realmente factible en la práctica. El disparo estudiado se corresponde a uno realizado desde aproximadamente 10 metros y con un ángulo de 37°. Como se cuenta con una gran cantidad de jugadores distintos, para el tercero de los modelos se optó por mostrar únicamente un resumen de las distribuciones *a posteriori* del xG de cuarenta futbolistas de la base. Se seleccionaron aquellos con el menor y el mayor valor medio de cada posición, junto con ocho jugadores adicionales cuyos valores medios están equiespaciados entre ambos extremos.

Figura 26

Mapa de calor de la distribución espacial de los disparos utilizados para el entrenamiento de los modelos



Particularmente, la Figura 28 permite observar nuevamente la división remarcada con anterioridad respecto a los dos grupos de jugadores, obteniéndose valores de probabilidad de gol sustancialmente distintos según si el disparo es realizado por futbolistas de carácter ofensivo o no ofensivo. Además, la diferencia en las estimaciones para algunos jugadores se mantiene en este tipo de gráficos, como se detalla en la Figura 29. Se observan valores de xG diferentes ante una misma situación de tiro, especialmente entre los delanteros. En cambio, los jugadores defensivos, y particularmente los defensores, no parecen diferenciarse tanto entre

sí, generando distribuciones centradas en valores relativamente más bajos. Asimismo, no debe dejarse de lado el incremento en la incertidumbre que se produce por realizar estimaciones con un menor volumen de información. Otro punto destacable es la similitud en las distribuciones de la probabilidad de gol de los mejores y peores jugadores de cada posición entre sí.

Figura 27

Distribución a posteriori generada por el Modelo 1 para la probabilidad de gol de un disparo desde una distancia y un ángulo típico

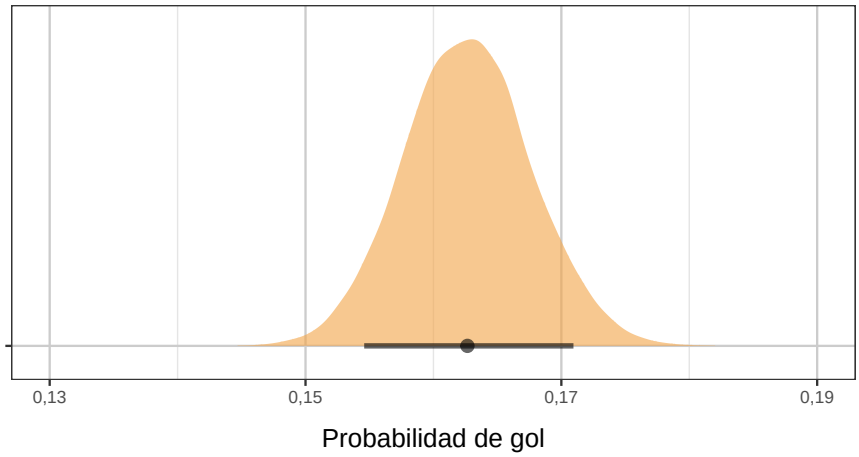


Figura 28

Distribución a posteriori generada por el Modelo 2 para la probabilidad de gol de un disparo desde una distancia y un ángulo típico según posición de quien dispara

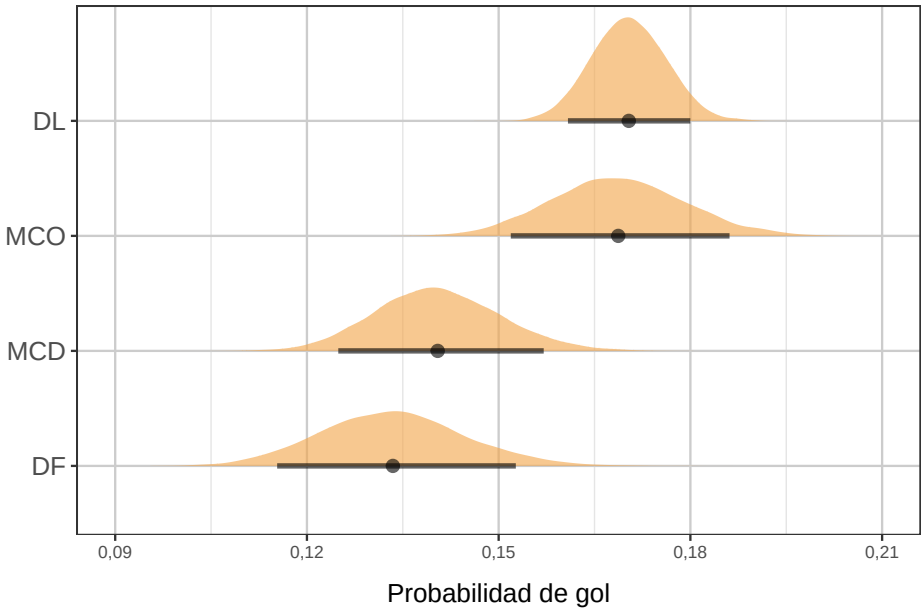
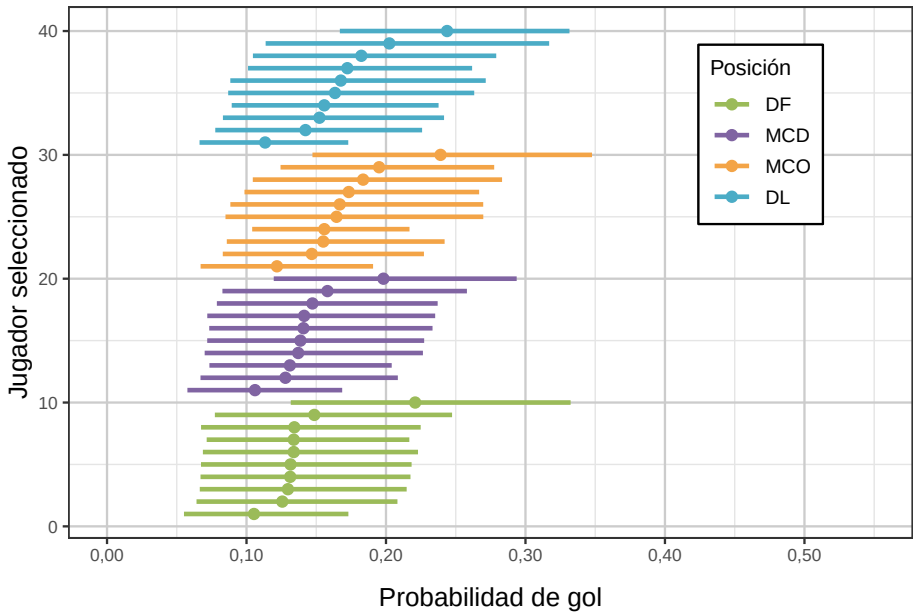


Figura 29

Distribución a posteriori generada por el Modelo 3 para la probabilidad de gol de un disparo desde una distancia y un ángulo típico para una selección de jugadores por posición



Como ya se mencionó, también interesa estudiar disparos realizados desde una ubicación que no sea la de mayor frecuencia, a fin de comprobar cómo se desenvuelven los modelos en situaciones para las que no se cuenta con un conjunto de datos de entrenamiento demasiado amplio. En las Figuras 30, 31 y 32 se presentan gráficos similares a los anteriores, pero para una distancia y un ángulo con moderada frecuencia de ocurrencia dentro de la base, esto es, desde aproximadamente 7 metros de distancia y con un ángulo de 45°. Puede observarse un comportamiento similar al ya analizado, enfatizando ahora más en el incremento de variabilidad presentado en la última de las figuras en relación a las restantes.

Figura 30

Distribución a posteriori generada por el Modelo 1 para la probabilidad de gol de un disparo desde una ubicación con moderada frecuencia de ocurrencia

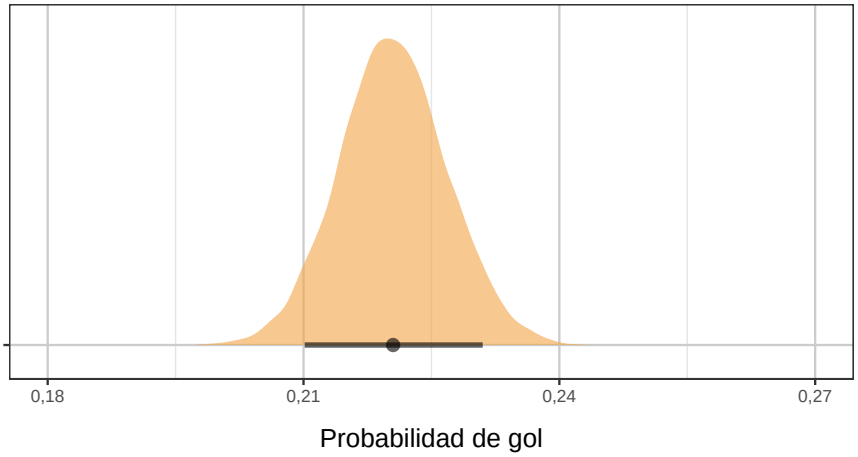


Figura 31

Distribución a posteriori generada por el Modelo 2 para la probabilidad de gol de un disparo desde una ubicación con moderada frecuencia de ocurrencia según posición de quien dispara

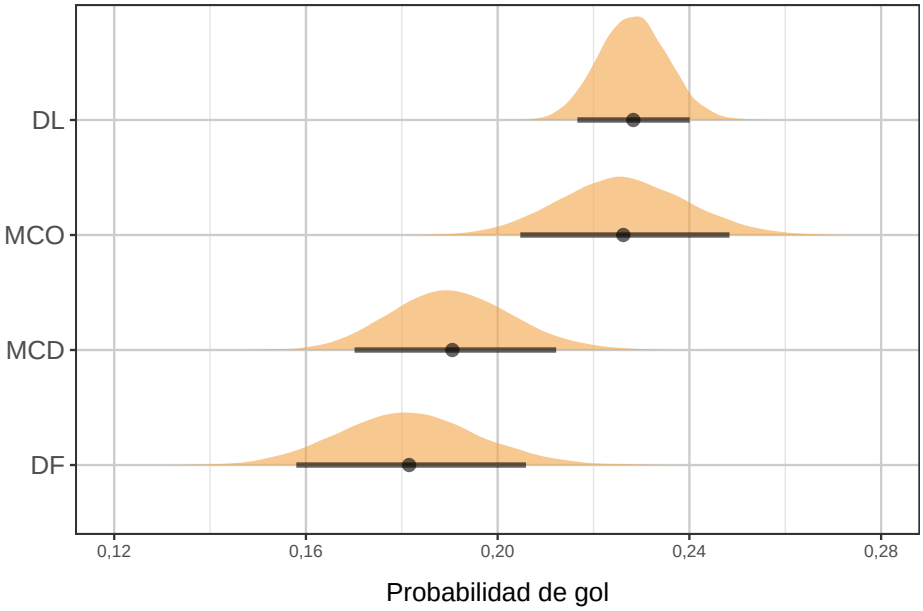
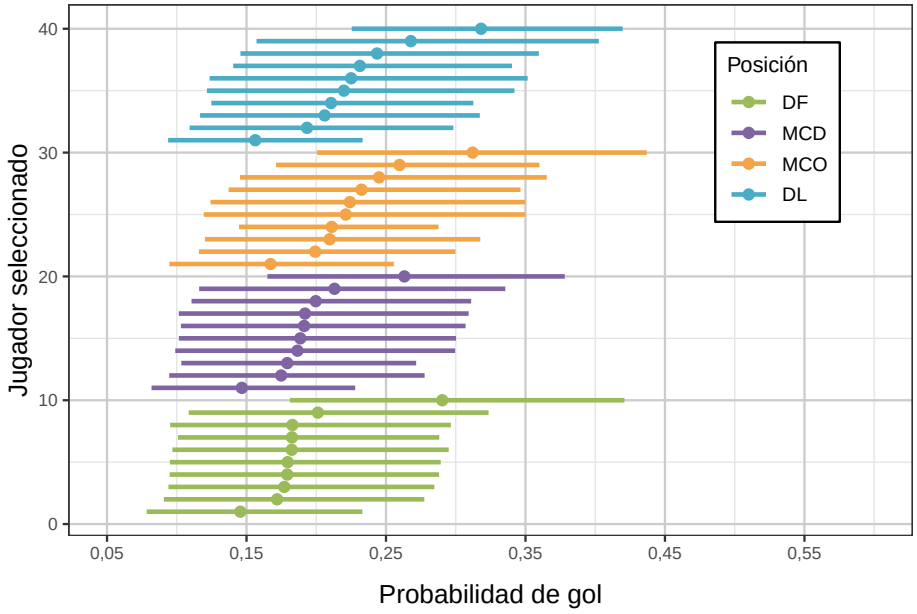


Figura 32

Distribución a posteriori generada por el Modelo 3 para la probabilidad de gol de un disparo desde una ubicación con moderada frecuencia de ocurrencia para una selección de jugadores por posición



Ya conociendo cómo se desenvuelven las distribuciones generadas por cada modelo en ciertas situaciones, uno de los posibles puntos a tener en cuenta para su comparación es cómo es se desempeñan en situaciones reales, es decir, en disparos que verdaderamente hayan ocurrido en partidos de la Liga Profesional. En las figuras que se presentan a continuación se utiliza como punto de comparación el valor de probabilidad de gol estimado por los modelos de Stats Perform y el resultado final de la jugada. Se busca que los disparos convertidos se correspondan con valores alto de probabilidad, alcanzando o, idealmente, superando los valores de Stats Perform. Por el contrario, aquellos disparos errados deberían corresponderse con valores iguales o menores que aquellos reportados por la empresa.

La Figura 33 se construye a partir de los valores de las variables correspondientes a un disparo al arco que no terminó en gol, realizado por uno de los jugadores con menor proporción de gol dentro de la base utilizada en el entrenamiento. Teniendo en cuenta el resultado final de la jugada, resulta coherente que el valor estimado por los modelos sea relativamente bajo. Los dos primeros gráficos muestran que el primer y segundo modelo se encuentran considerablemente alineados con lo reportado por Stats Perform, observándose un leve corrimiento de la distribución hacia la derecha cuando se incorpora el dato de que el jugador que disparó era un mediocampista ofensivo. Sin embargo, al utilizar la información específica del jugador que realizó el disparo, la distribución del xG se desplaza hacia valores bajos, acercándose más al "resultado real de la jugada".

La Figura 34, por otro lado, presenta una situación diferente: en este caso el disparo en cuestión fue realizado por uno de los mejores ejecutantes de la base y este efectivamente terminó en gol. Nuevamente, si bien se observa un desplazamiento de la distribución generada con el segundo modelo en relación a la del primero, los resultados son parecidos en ambos. En cambio, al incluir el dato del jugador ejecutante, la distribución se desplaza a valores mayores.

Figura 33

Distribución a posteriori de la probabilidad de gol estimada por cada modelo para el disparo de Brahian Alemán realizado en el minuto 16 del encuentro entre Racing y Tigre por la Copa Sur Finanzas 2024

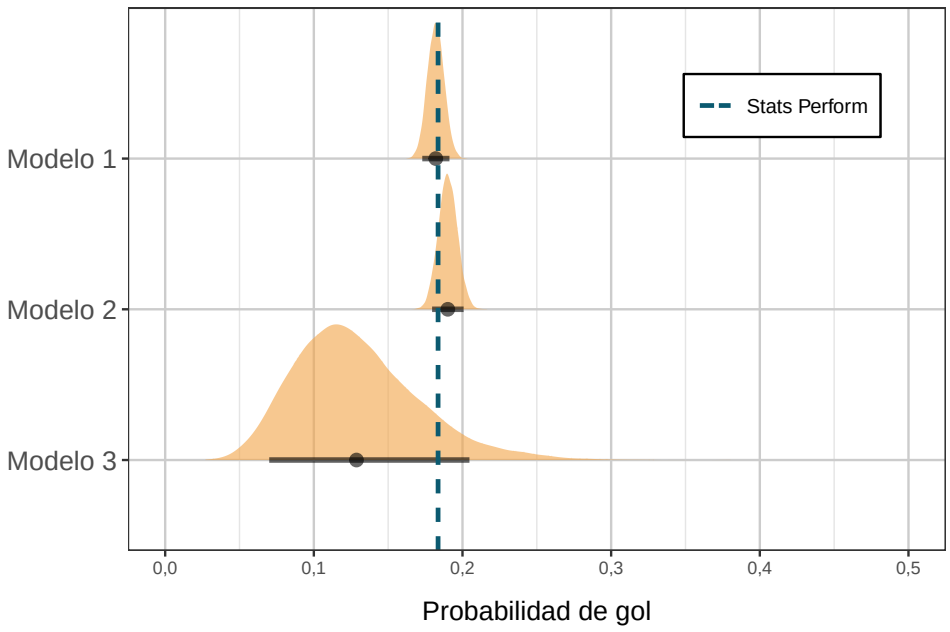
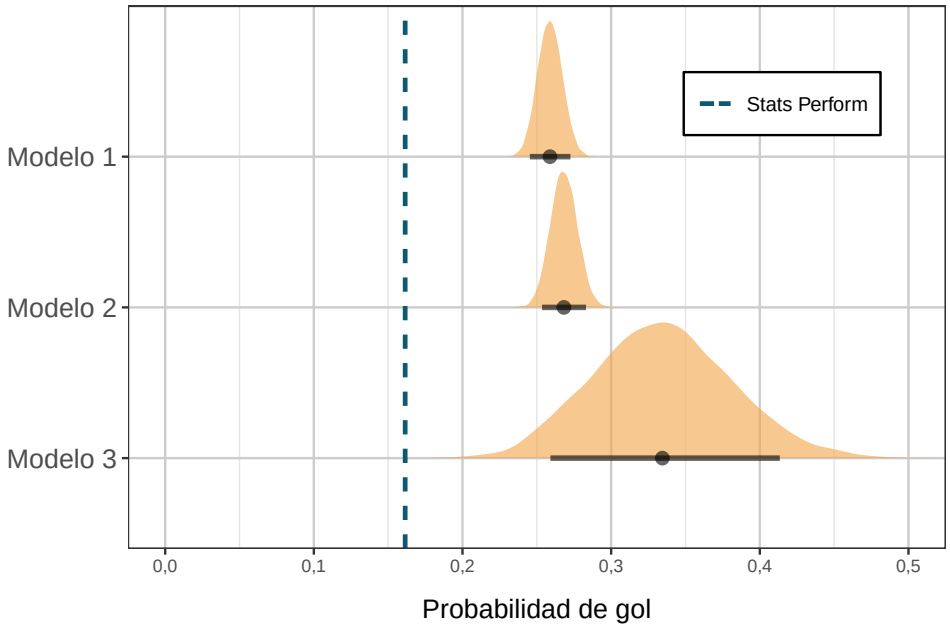


Figura 34

Distribución a posteriori de la probabilidad de gol estimada por cada modelo para el disparo de Adrián Martínez realizado en el minuto 45+2 del encuentro entre Tigre y Racing por el Torneo Betano 2024



Si bien estos gráficos sugieren que la inclusión del efecto jugador resulta razonable para obtener estimaciones adecuadas, no debe asumirse que esto garantice, en todos los casos, una mejora en la calidad de los resultados. La Figura 35 muestra el momento previo a un gol de contragolpe, convertido sobre el final del partido, mano a mano con el arquero y con ventaja en el marcador. Un disparo como este presenta características que no fueron incorporadas en los modelos desarrollados en esta tesina, aunque probablemente influyan en la probabilidad de gol. En consecuencia, ninguno de los modelos ajustados alcanza siquiera el valor reportado por la empresa para esta jugada, como puede observarse en la Figura 36.

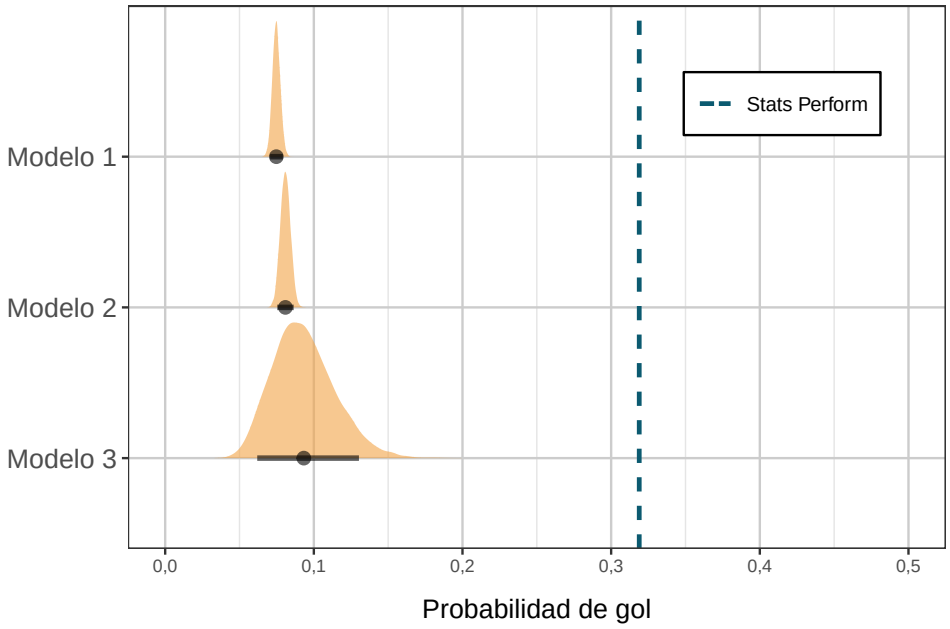
Figura 35

Imagen en el momento del disparo de Miguel Merentiel realizado en el minuto 90 del encuentro entre Boca Juniors y Racing por el Torneo Binance 2023



Figura 36

Distribución a posteriori de la probabilidad de gol estimada por cada modelo para el disparo de Miguel Merentiel realizado en el minuto 90 del encuentro entre Boca Juniors y Racing por el Torneo Binance 2023



Se debe mencionar el hecho de que los gráficos de las Figuras 33, 34 y 36 han sido construidos para datos asociados a disparos que fueron utilizados en el entrenamiento de los modelos. En casos así, es de esperar que el modelo genere predicciones optimistas, ya que ha sido ajustado específicamente para capturar los patrones presentes en dichos datos. Es posible, además, estudiar el comportamiento de los modelos al estimar valores de xG para nuevos disparos. Se estima entonces la probabilidad de gol para disparos correspondientes a los torneos del año 2025 y los resultados se presentan en las páginas siguientes. No obstante, antes de realizar estas interpretaciones, debe hacerse una aclaración asociada con el efecto específico del jugador en el tercero de los modelos.

Al estudiar un nuevo torneo, cada disparo puede corresponderse con una de dos situaciones: haber sido ejecutado por un futbolista para el cual se dispone de información previa o por un nuevo jugador, del que no se cuenta con datos anteriores. Para el primero de los casos, la metodología de cálculo del xG permanece inalterada, mas no así para el segundo, donde surgen alternativas de estimación.

Una primera opción consiste es considerar que el nuevo futbolista estudiado es un "jugador promedio", lo que, en términos del modelo, equivale a no tener en cuenta el efecto jugador en la estimación, imponiendo $u = 0$ y obteniendo resultados similares a los alcanzados al utilizar únicamente la información de la posición. Esta opción resulta optimista en relación a la incertidumbre, ya que se estaría excluyendo aquella introducida por el parámetro σ_u; sin embargo, no será tenida en cuenta en esta tesina porque, al omitir la información específica del jugador, no se ajusta a los objetivos planteados.

La otra posibilidad, adoptada en este trabajo, consiste en utilizar las distribuciones *a posteriori* obtenidas para generar muestras del parámetro u para un nuevo jugador de la población de jugadores. En este caso, el procedimiento se basaría en utilizar las muestras del parámetro de variabilidad para construir distribuciones normales de media 0 y desvío σ_u, a partir de las cuales se obtendrían posteriormente los valores específicos de u.

Las Figuras 37 y 38 se construyen con la información de dos disparos: uno de Adrián Martínez (jugador que cuenta con disparos realizados durante los torneos utilizados en el entrenamiento de los modelos) y uno de Julián Palacios (jugador cuyo efecto no ha sido estudiado previamente por los modelos). El disparo evaluado en la Figura 37 resultó en gol del jugador Martínez por lo que resulta adecuado que la distribución generada a partir del tercero de los modelos se encuentre centrada en valores relativamente altos. La Figura 38, por el contrario, retrata un disparo errado y, por ende, tiene sentido que las distribuciones se desplacen hacia valores bajos. No obstante, el principal fin de estas últimas figuras es el de dimensionar que modelos de esta clase pueden cuantificar el efecto específico del jugador que dispara más allá de si se cuenta o no con información previa de sus características.

Figura 37

Distribución a posteriori de la probabilidad de gol estimada por cada modelo para el disparo de Adrián Martínez realizado en el minuto 23 del encuentro entre Racing y Unión por el Torneo Clausura Betano 2025

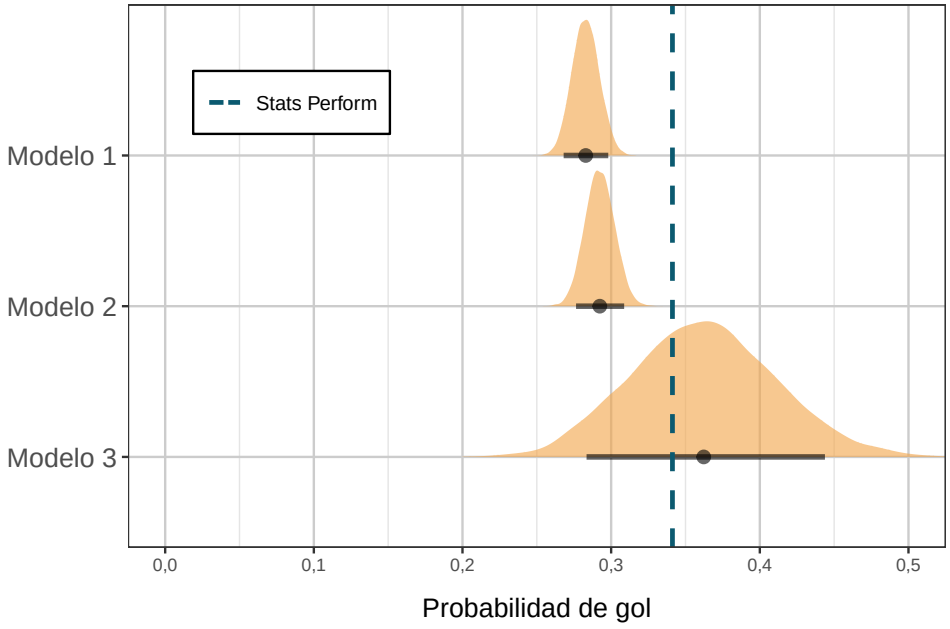
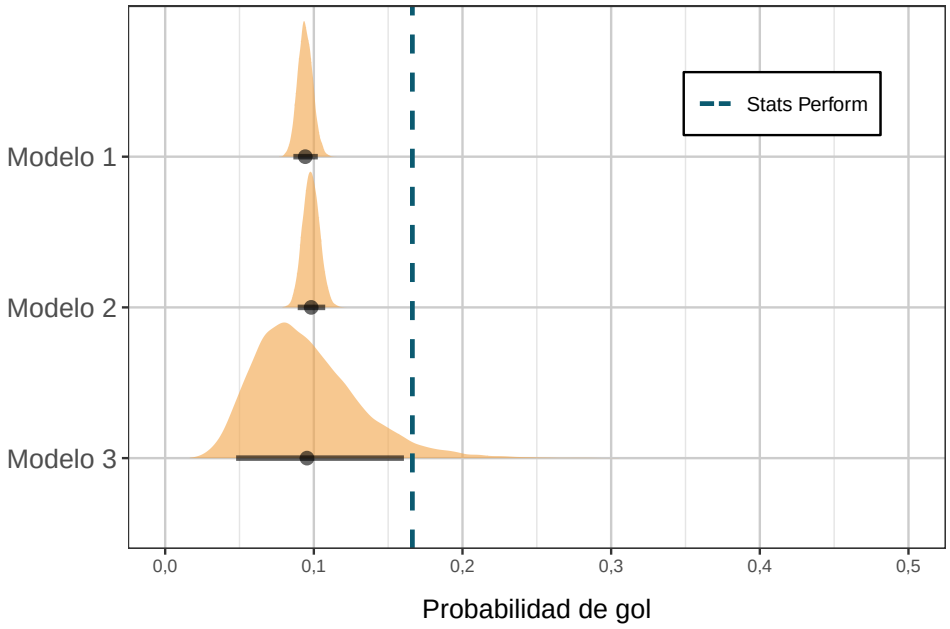


Figura 38

Distribución a posteriori de la probabilidad de gol estimada por cada modelo para el disparo de Julián Palacios realizado en el minuto 35 del encuentro entre Racing y Unión por el Torneo Clausura Betano 2025



5.4.2. Evaluación de las predicciones de manera conjunta

La segunda parte de las comparaciones consiste en el estudio de los modelos a través de todos los disparos de la base, con el objetivo de determinar su capacidad predictiva y evaluar si la incorporación de los efectos asociados a la posición y al jugador permite obtener mejoras significativas. Las Figuras 39, 40 y 41 muestran las distribuciones predictivas *a posteriori* generadas por cada uno de los tres modelos y por Stats Perform para tres jugadores en particular, acompañadas de la cantidad real de goles convertidos por cada uno de ellos. Esta comparación ayuda a visualizar la ya mencionada capacidad predictiva y constituye un criterio de referencia útil para evaluar los resultados obtenidos.

Es posible observar que, tanto en el caso de Adrián Martínez como en el de Miguel Merentiel, el tercero de los modelos genera distribuciones más cercanas a la cantidad real de goles y más concordantes con la obtenida al utilizar los valores reportados por Stats Perform, aunque con un leve aumento en la incertidumbre. Para los disparos de Benjamín Domínguez, si bien todos los modelos parecen generar distribuciones similares a la de la empresa, aquel que incluye el efecto jugador resulta ser el más exacto, en cuanto parece estar más centrado en el valor real de goles convertidos. Adicionalmente, cabe destacar que, si bien los *posteriors* de la probabilidad de gol estimados por el Modelo 3 y estudiados en las Figuras 29 y 32 muestran una variabilidad relativamente mayor que los estimados por los otros dos modelos, al transformarlos en distribuciones predictivas *a posteriori*, la variabilidad resulta bastante similar para todos ellos. Este comportamiento también se observa al comparar las distribuciones asociadas a los modelos de este trabajo y aquella que refiere al modelo de Stats Perform. El hecho de que sean construidas a partir de un único valor de xG por disparo no se traduce en distribuciones predictivas mucho más estrechas.

Figura 39

Distribución a posteriori para la cantidad de goles generada por cada modelo para Adrián Martínez

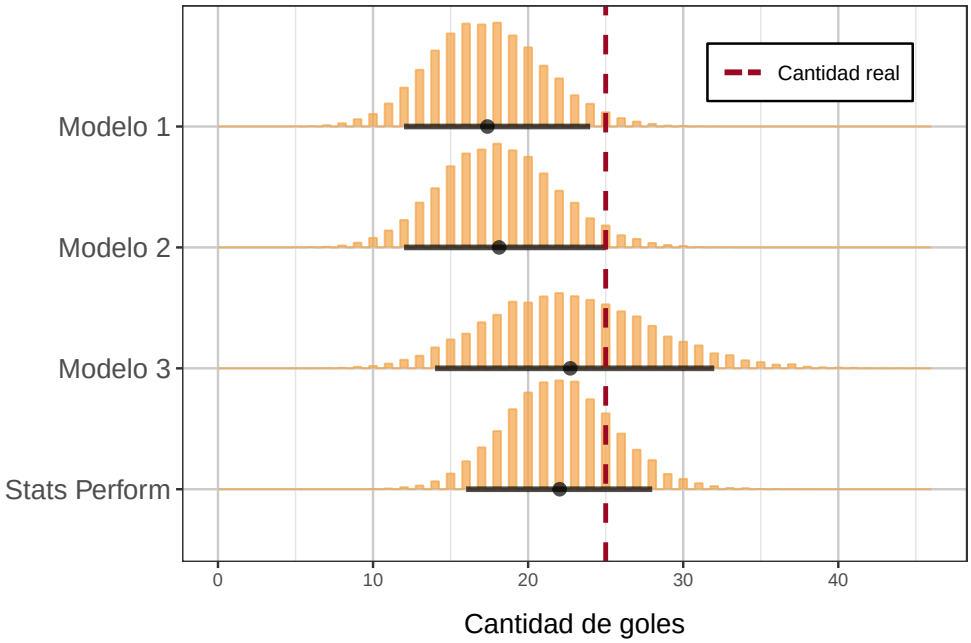


Figura 40

Distribución a posteriori para la cantidad de goles generada por cada modelo para Miguel Merentiel

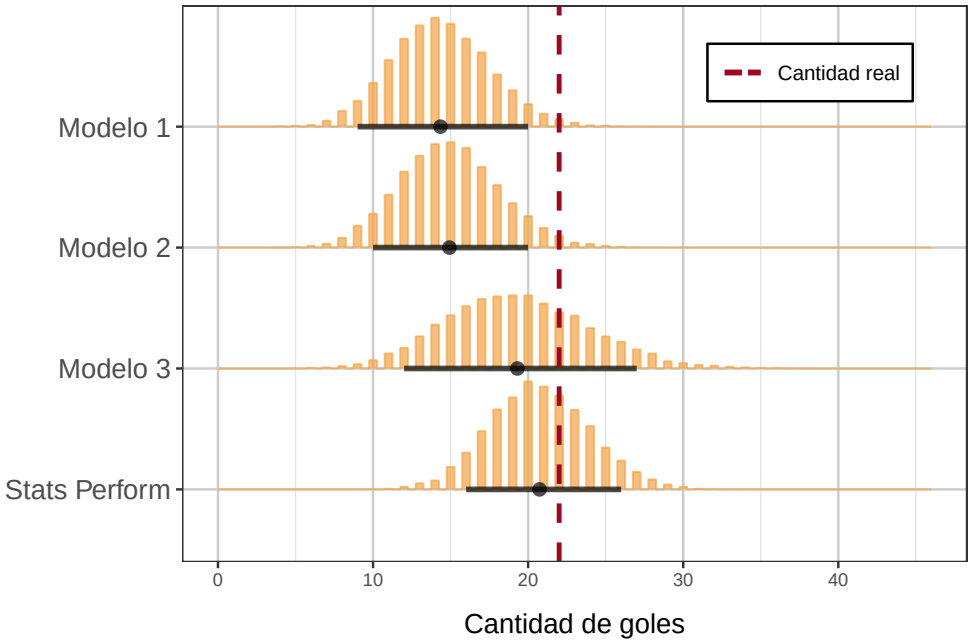
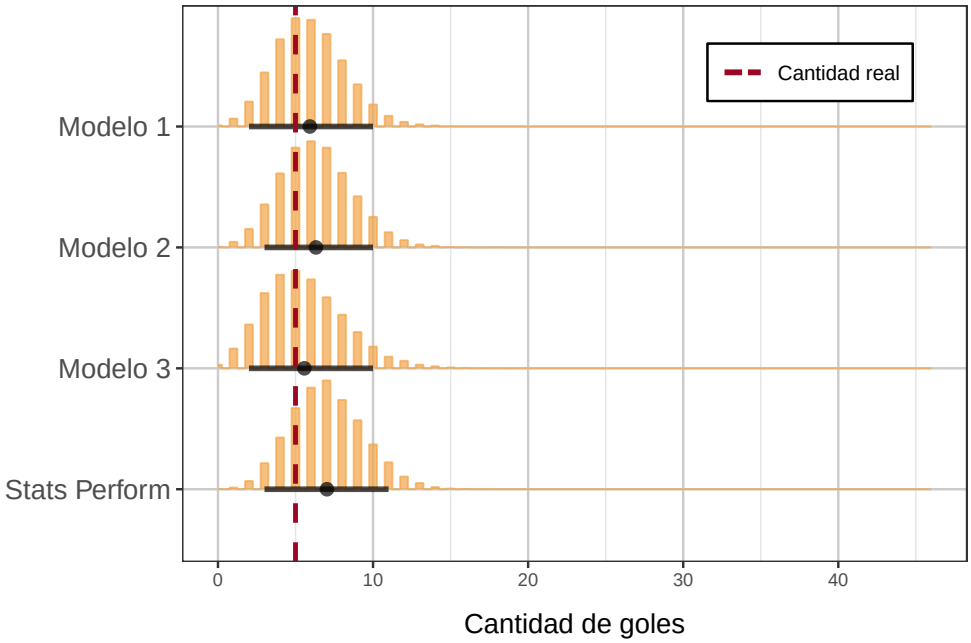


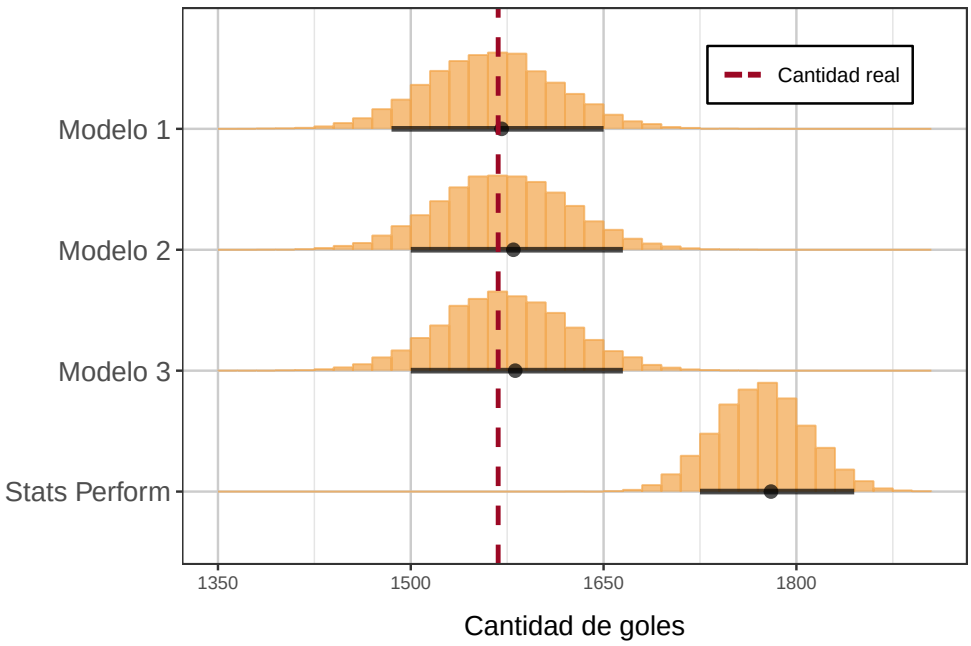
Figura 41

Distribución a posteriori para la cantidad de goles generada por cada modelo para Benjamín Domínguez



El mismo procedimiento es posible de aplicarse si se considera la totalidad de disparos al arco estudiados, a través de todos los jugadores, partidos y torneos. Estas nuevas distribuciones predictivas se muestran en la Figura 42, donde se observa un mejor desempeño de los tres modelos construidos con respecto a los resultados calculados con los datos de Stats Perform. Dicha mejora debe ser vista en consideración de que las estimaciones aquí obtenidas se realizaron sobre los datos de entrenamiento o *in-sample*, mientras que las de la mencionada empresa fueron realizadas *out-of-sample*; sin embargo, esta figura puede ser indicio de una sobreestimación de las probabilidades de gol en el fútbol argentino. Otro punto a destacar de esta figura es la concordancia entre los resultados obtenidos con los tres modelos de este trabajo, tanto en ubicación como en dispersión: el aumento en el número de disparos produce que los modelos se comporten de manera similar en lo que a distribuciones predictivas se refiere.

Figura 42
Distribución a posteriori para la cantidad de goles totales generada por cada modelo



Una manera de comparar qué tanto difieren las estimaciones de los modelos construidos con las de Stats Perform es utilizar el CRPS. Como cada disparo cuenta con un *posterior* para la probabilidad de gol y con su respectiva estimación generada por la empresa proveedora, es posible calcular dicha medida del error para todos ellos y contraponerlos en un gráfico, como se hace en la Figura 43. Dado que los gráficos construidos para los tres modelos presentan un patrón similar, se muestra aquí únicamente el asociado al tercero de ellos, incluyendo las restantes figuras en el Anexo.

En la Figura 43 se observa que, cuando los valores de Stats Perform son relativamente bajos, el CRPS en general no supera valores de 0,1. Además, solo un 4,5% del conjunto total de datos presentan un error mayor a 0,2. Sin embargo, conforme el xG estimado por la empresa aumenta, el desempeño del modelo comienza a ser un poco más irregular, diferenciándose de sus estimaciones en ciertas circunstancias: situaciones de alta peligrosidad para Stats Perform, en las que el modelo construido estima una baja probabilidad de conversión, quizá debido a factores adicionales (como los ya estudiados en el gol de Miguel Merentiel) o bien por la mencionada sobreestimación de la probabilidad de gol en el fútbol argentino.

A fin de obtener una visualización más sencilla del CRPS, es posible agrupar los disparos en intervalos de igual tamaño y graficar el promedio de la probabilidad de gol reportada por la empresa y el promedio de los CRPS dentro de cada uno de ellos. Esto es lo que se presenta en la Figura 44, junto con los valores del MAE calculados al resumir los *posteriors* de cada disparo con su valor medio. En este caso, los intervalos se construyen en base a la probabilidad de gol reportada. Puede observarse el aumento de ambos errores al incrementarse la probabilidad de gol de Stats Perform.

Otra forma de contrastar los resultados de los modelos con el de la empresa es a través de graficar la suma de los valores de xG de cada jugador contra la cantidad real de goles convertidos por ellos, buscando que los puntos se equilibren sobre la recta identidad (línea negra). El *posterior* de cada disparo se resume en un único valor a través de su valor medio. En la Figura 45 se observa que el Modelo 3 presenta un mejor desempeño que los restantes y que Stats Perform, teniendo esto especial sentido, debido a que allí se está modelando el efecto específico de los jugadores.

Figura 43

CRPS obtenido con el Modelo 3 para cada valor de probabilidad de gol reportado por Stats Perform

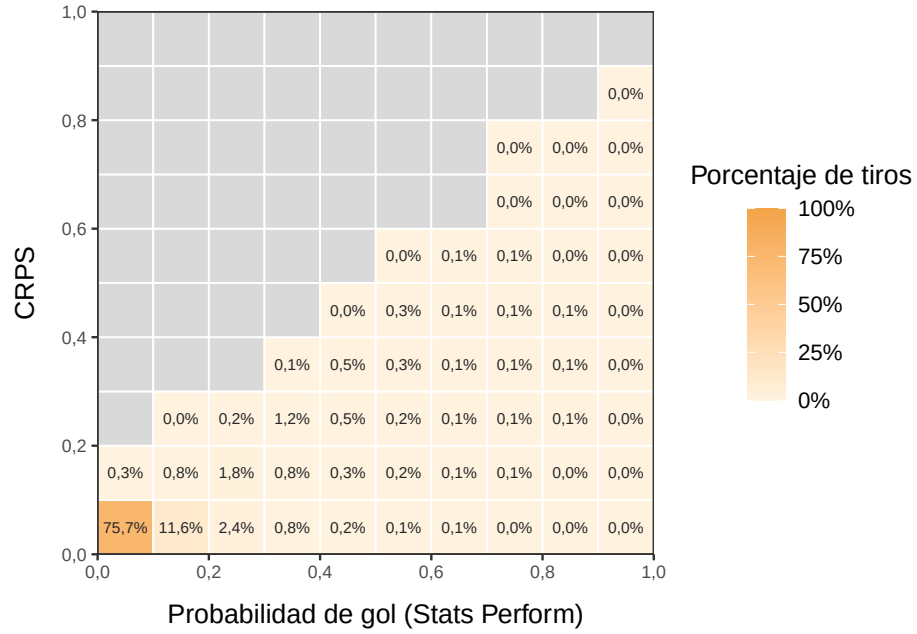


Figura 44

CRPS y Error Medio Absoluto obtenidos con el Modelo 3

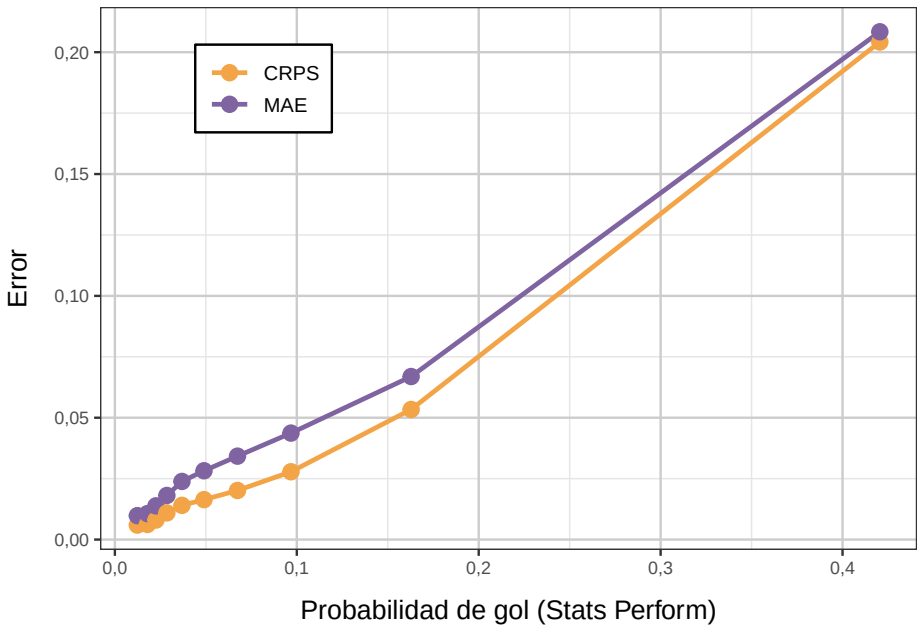
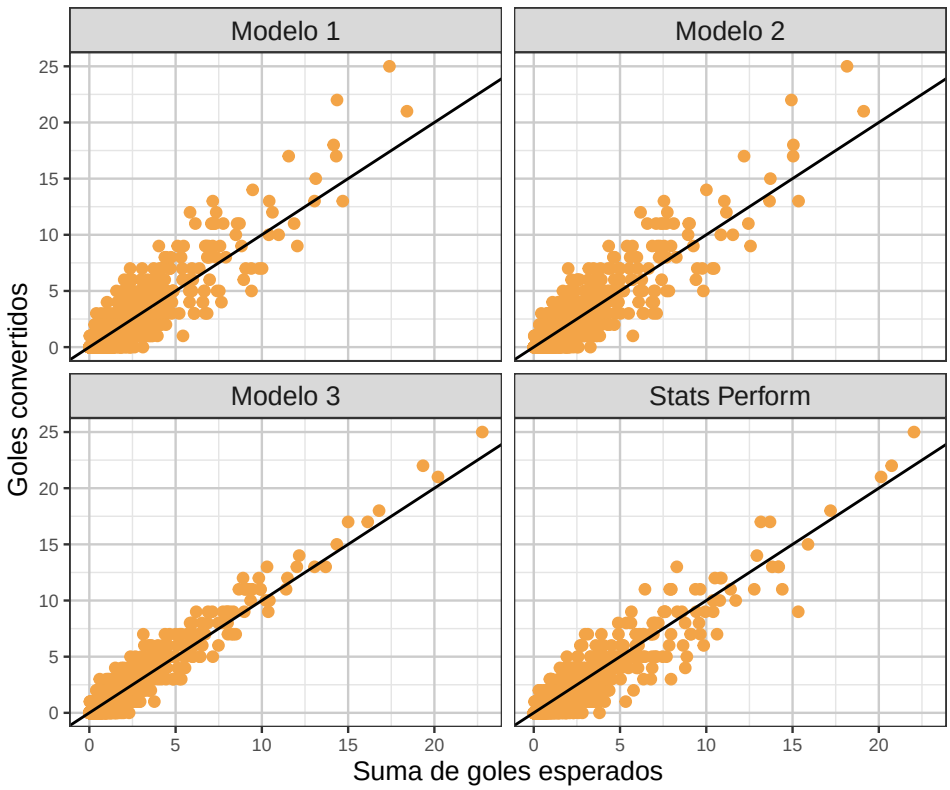


Figura 45
Suma de goles esperados y cantidad de goles convertidos por jugador según cada modelo



Por otro lado, en la Figura 46 se muestran los gráficos de calibración para los tres modelos construidos y para los valores de Stats Perform. Los cuatro modelos parecen estar calibrados con la proporción de gol real, aunque mostrando en todos los casos una gran amplitud en el último de los intervalos calculados, debido principalmente a la gran cantidad de disparos de la base a los que los modelos asignan una baja probabilidad de gol. El 10% de los disparos de la base con los mayores valores de xG estimados presenta una mayor heterogeneidad que los restantes deciles construidos. Que el intervalo se mantenga centrado sobre la recta identidad indica que esta mayor dispersión no implica necesariamente una pérdida de calibración, sino únicamente una mayor variabilidad de las predicciones dentro de dicho grupo. No debe perderse de vista que, tanto en la Figura 45 como en esta última, se está resumiendo las distribuciones en un único valor puntual y, por ende, se está perdiendo la información de la incertidumbre asociada a cada una de ellas.

Adicionalmente, se complementa todas estas comparaciones gráficas con métricas que permiten cuantificar el grado de ajuste de los modelos a la realidad. En la Tabla 10 se presentan los valores de las métricas ya presentadas en la Sección 3.6 y que se obtienen luego de resumir la distribución de probabilidad de cada disparo con su valor medio. El desempeño de los modelos parece ser levemente inferior al de Stats Perform, aunque se destaca que todos ellos superan el valor de referencia mínimo aceptable, es decir, el valor de la puntuación de Brier y de la pérdida logarítmica que se obtienen al considerar que todos los disparos tienen una probabilidad de gol igual a la proporción de conversión de la base.

Figura 46

Gráficos de calibración para los modelos construidos y para los valores reportados por Stats Perform

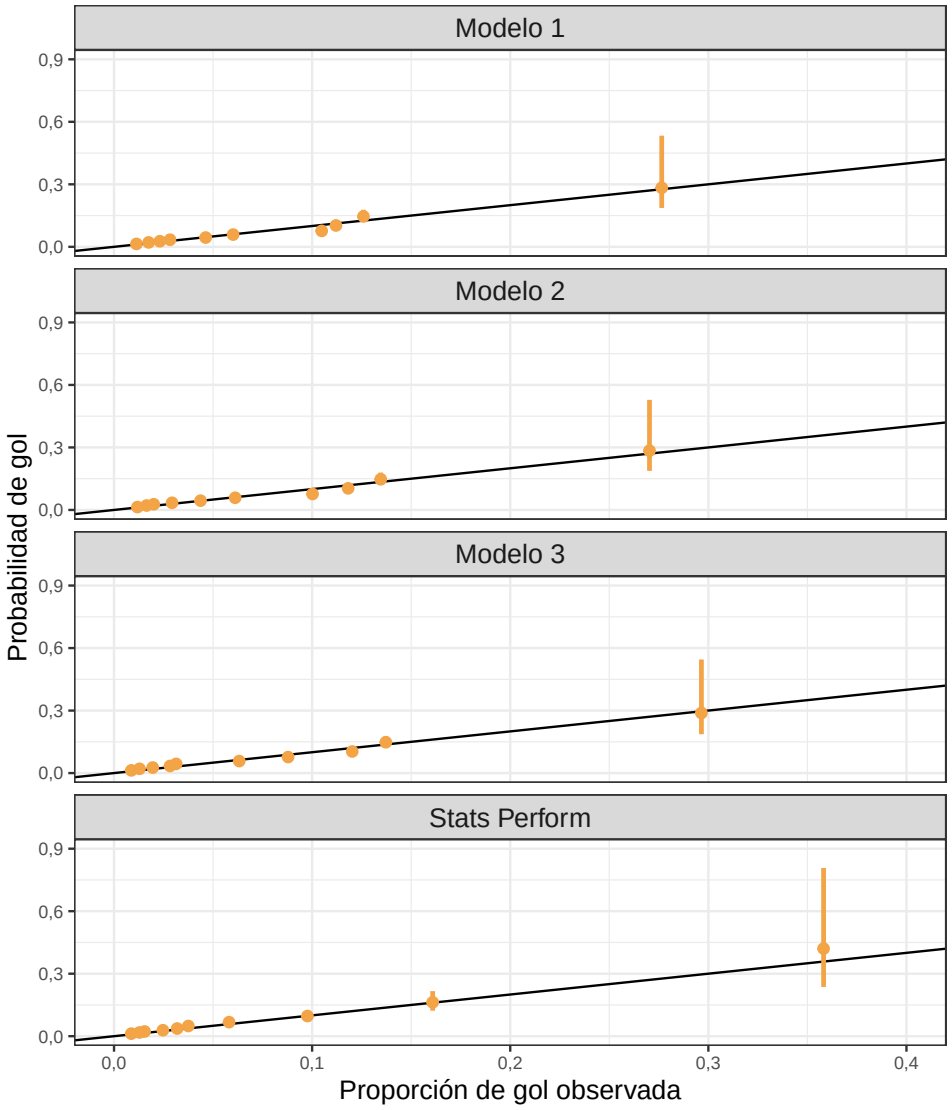


Tabla 10

Métricas de evaluación del desempeño de los modelos

Modelo	Puntuación de Brier	Pérdida Logarítmica
Modelo 1	0,067	0,243
Modelo 2	0,067	0,242
Modelo 3	0,065	0,236
Stats Perform	0,061	0,220

6. Conclusiones

El objetivo principal de esta tesina era el de estudiar, comprender el funcionamiento y construir modelos de goles esperados como los empleados por las grandes empresas proveedoras de datos en la industria del fútbol. Para ello, se abordaron distintos aspectos vinculados con su aplicación dentro de este mercado, su metodología de construcción y el relevamiento de la información utilizada en su ajuste. Se ha presentado en detalle una alternativa a la tradicional manera de obtención de los valores de probabilidad de gol: los modelos construidos bajo enfoque bayesiano. Los métodos de inferencia aproximada, las herramientas para comprobar el buen comportamiento de las muestras generadas y los distintos elementos empleados en la comparación de resultados han sido algunos de los aspectos abordados en este trabajo. En las distintas secciones se ha buscado, también, dimensionar las diferencias entre los resultados a los que se arriba utilizando modelos construidos bajo un enfoque frecuentista o clásico, y aquellos obtenidos bajo la mencionada metodología bayesiana.

El objetivo planteado postulaba, además, estudiar la posible incorporación de variables generalmente no consideradas por las empresas proveedoras: la posición de juego, incorporada como efecto fijo, y el efecto específico del jugador que ejecuta el disparo. Esta dimensión del objetivo central hizo necesaria la obtención de una base de datos referida a disparos realizados en diversos torneos de este deporte. El proceso de *web scraping* y depuración del conjunto de datos conformó otro aspecto fundamental de este trabajo, debido a que, por los métodos utilizados para el relevamiento de la información durante los partidos, no es sencillo encontrar bases de datos libres que puedan ser utilizadas para el entrenamiento de los modelos. Esta dificultad se acentúa en el caso del fútbol argentino, donde la disponibilidad de este tipo de información es más limitada que en otras competencias, particularmente en comparación con las principales ligas europeas.

La base de datos resultante permitió entrenar tres modelos: uno sencillo, con únicamente la distancia, el ángulo de tiro y su interacción como variables explicativas; otro que incorporaba la posición como un efecto fijo; y un tercero que incluía además el efecto específico del jugador ejecutante. La comparación entre ellos, a fin de determinar si hacer uso de estas variables adicionales genera cambios sustanciales en la probabilidad de gol, conformó la tercera gran parte de esta tesina y permitió obtener ciertos hallazgos que resulta pertinente destacar en la presente sección.

Lo primero a mencionar es el buen desempeño de los modelos ajustados, obteniendo, en general, resultados aceptables de probabilidad de gol. Incluso con pocas variables que capten la complejidad de las situaciones de juego, es posible obtener herramientas que reduzcan en parte la incertidumbre de los partidos. En la Sección 5.4 se presentaron situaciones puntuales, métricas y gráficos de evaluación global, en los que se observó un comportamiento adecuado de los modelos, no solo al contrastar sus estimaciones con la realidad, sino también al compararlas con las proporcionadas por Stats Perform.

Por su parte, los resultados asociados al segundo y tercer modelo permiten concluir que la posición de juego del futbolista que dispara genera cambios en los valores de xG estimados en las distintas situaciones. Se consideraron cuatro posiciones de juego en este trabajo, pero se descubrieron principalmente dos grandes grupos de futbolistas, jugadores defensivos y ofensivos. Nsolo et al. (2019) y Herranz Martínez (2026), en sus trabajos, presentan conclusiones similares: la precisión de sus predicciones sobre la valoración de los futbolistas es notablemente mayor para delanteros que para los restantes roles, sugiriendo que las estadísticas más populares de esta industria describen mejor el aporte ofensivo que defensivo. Por estos motivos, el ponderar los valores de xG según la posición del ejecutante, utilizando información fácil de relevar en los partidos de Primera División, podría disminuir la presencia de problemas de esta índole.

El tercer modelo incluía, como ya se mencionó, un efecto específico del jugador, con una estructura jerárquica que permite que se comparta información entre ellos (*pooling* parcial). En las distintas figuras de la Sección 5.4 se observó que algunos jugadores del fútbol local parecen diferenciarse del resto, algunos positiva y otros negativamente, aunque la gran mayoría de ellos presenta un desempeño similar. En el desarrollo de las comparaciones se ha demostrado que los modelos de esta clase permiten obtener valores de probabilidad aceptables aun cuando el jugador ejecutante era nuevo en el conjunto de datos de entrenamiento. Esto los convierte en una alternativa viable para estimar también los disparos realizados por refuerzos provenientes de otras ligas, jóvenes debutantes o jugadores que simplemente tienen pocos o ningún disparo al arco. En cuanto al desempeño, este modelo mostró un mejor rendimiento cuando el foco era, justamente, un jugador en particular. Las Figuras 39, 40 y 41, construidas para "jugadores extremos", muestran que las distribuciones asociadas al Modelo 3 parecen ser las más acordes a la realidad, viéndose esto también reflejado en una nube de puntos más concentrada en la Figura 45. No obstante, cuando el interés se posa en el estudio de una gran cantidad de disparos, los tres modelos parecen comportarse de manera similar y correcta, como se observó en las distribuciones predictivas para la totalidad de goles, en los gráficos de calibración y en las métricas de desempeño. Los *posteriors* marginales generados por este tercer modelo presentaron un aspecto importante sobre el que hacer hincapié: el aumento de la incertidumbre.

Una rápida inspección de las figuras estudiadas en la Sección 5.4.1 es suficiente para concluir que la incertidumbre de las distribuciones se incrementa en gran medida con el Modelo 3. Mientras que la gran cantidad de datos de entrenamiento tiene como consecuencia una reducción en la variabilidad del *posterior* estimado con los dos primeros modelos, la baja cantidad de disparos por jugador y la incorporación de una fuente de variabilidad adicional provocan que aquellos construidos con el último modelo parezcan demasiado inciertos como para ser considerados "buenos resultados". Sin embargo, no necesariamente mayor variabilidad significa peor rendimiento. Según Scholtes y Karakuş (2024), la incertidumbre asociada a las estimaciones del xG permite comprender mejor las dificultades inherentes a la evaluación del rendimiento en el ámbito del análisis deportivo. Mediante metodologías como la regresión bayesiana, los investigadores pueden cuantificar e interpretar eficazmente la variabilidad en las predicciones del xG. Adicionalmente, este aumento de la incertidumbre no trae consigo un peor desempeño global del modelo; las métricas de la Tabla 10 muestran incluso una mejoría en los valores. Considerando solamente dos, tres o cuatro variables, los modelos parecen obtener valores parecidos a los reportados por Stats Perform, una de las empresas líderes de este mercado. Queda como trabajo futuro realizar un estudio de esta clase, pero que tenga en cuenta más variables: posición del arquero, cantidad de jugadores en el triángulo de tiro, distancia entre la pelota y el primer defensor, utilización del pie hábil, entre tantas otras posibles.

Una de las potenciales causas por las que los modelos simples aquí construidos presentan valores cercanos a los de Stats Perform puede ser la ya mencionada sobreestimación de las probabilidades de gol en el fútbol argentino. Como instancia adicional de este trabajo, se llevó a cabo un remuestreo *bootstrap* de 2.000 repeticiones, tomando muestras con reposición de los 19.460 disparos disponibles y calculando, en cada una, la diferencia entre la media de las probabilidades de gol proporcionadas por Stats Perform y la proporción observada de goles. El intervalo de confianza del 95% obtenido para esta diferencia no contiene al cero, lo que constituye evidencia de un sesgo positivo en las estimaciones de la empresa. No todos los jugadores de todas las ligas del mundo tienen el mismo nivel resolutivo. Ni Stats Perform, ni ninguna otra empresa proveedora de datos, por cuestiones de mercado, detallan en sus sitios *webs* el modelo utilizado para el cálculo del xG. No se explica en ninguna parte si el modelo es el mismo para todas las ligas, si se calibra cada cierto tiempo o si cambian las

variables explicativas consideradas. Todos estos factores pueden ser fundamentales a la hora de comparar a los jugadores dentro de un torneo en particular o a lo largo de diferentes años de carrera.

El estudio en detalle del sesgo en las estimaciones de Stats Perform, la posibilidad de que exista un sesgo por las dimensiones de los campos de juegos de ciertos equipos, o la incorporación de pendientes específicas por jugador, son algunas posibles extensiones de este trabajo. Herranz Martínez (2026) entrena un modelo de xG para utilizarlo como uno de los tantos criterios en el *scouting* de jugadores. En ese trabajo, y en algunos otros de la literatura, se ajustan modelos de esta clase pero utilizando XGBoost. La incorporación del jugador que dispara y su posición en dichos modelos constituye otra posible línea de investigación, tanto para evaluar si estas variables permiten mejorar las estimaciones del xG al utilizar otras metodologías, como para estudiar su utilidad en aplicaciones específicamente orientadas a comparar el rendimiento de jugadores. Por último, si bien el conjunto de disparos aquí estudiado constó de una gran cantidad registros, fueron pocos aquellos que se correspondían con situaciones de verdadero peligro según el modelo de Stats Perform, hecho que puede servir como descripción del momento actual del fútbol local. Utilizar algunas métricas, entre ellas el xG, para estudiar qué tan atractivas resultan algunas ligas para el público neutral es otra posible continuación de esta tesina.

Más allá de la metodología elegida y de la finalidad del modelo que se construya, está claro que una de las mayores dificultades reside en la obtención de los datos. Las bases de datos públicas que contienen información adicional sobre cada disparo están limitadas a algunos torneos y años en particular y, por ende, no tendrían utilidad si el fin es evaluar el presente del fútbol argentino, por ejemplo. Quizá, el avance de los métodos de relevamiento que se ha desarrollado en el último tiempo lleve a facilitar la incorporación de estas variables adicionales a los datos de eventos, construyendo así bases de datos libres más completas y ricas, que permitan a analistas y aficionados construir nuevos modelos y obtener conclusiones de mayor interés sobre el fútbol a nivel global.

7. Anexo

7.1. Versiones de *software* utilizadas

- Python: 3.12.13
- PyMC: 5.28.5
- R: 4.5.0

7.2. Correcciones a los nombres de futbolistas

Correcciones llevadas a cabo en los nombres de los futbolistas de la base de FotMob para que cada jugador tenga un nombre y apellido único:

- Agustín García Basso se renombró como Agustín Basso.
- Franco Jara se renombró como Franco Daniel Jara.
- Carlos Arce se renombró como Carlos Martín Arce.
- Lucas Menossi se renombró como Lucas Ariel Menossi.
- Eric Remedi se renombró como Eric Daian Remedi.
- Yonatan Goitia se renombró como Jonatan Goitia.
- Dos jugadores aparecían con el nombre de Alan Rodríguez. Se les agregó su segundo nombre: Alan Francisco Rodríguez y Alan Jesús Rodríguez.
- Dos jugadores aparecían con el nombre de Ignacio Fernández. Uno de ellos fue reemplazado por Equi Fernández.
- Dos jugadores aparecían con el nombre de Matías Gómez. Se les agregó su segundo nombre: Matías Ezequiel Gómez y Matías Nicolás Gómez.
- Dos jugadores aparecían con el nombre de Nicolás Fernández. Uno de ellos fue reemplazado por Uvita Fernández.
- Dos jugadores aparecían con el nombre de Julián Fernández. Se agregó el segundo nombre a uno de ellos: Julián Rodrigo Fernández.
- Dos jugadores aparecían con el nombre de Tiago Palacios. Se les agregó su segundo nombre: Tiago Tomás Palacios y Tiago Asael Palacios.
- Dos jugadores aparecían con el nombre de Eric Ramírez. Se les agregó su segundo nombre: Eric Kleybel Ramírez y Eric Iván Ramírez.
- Dos jugadores aparecían con el nombre de Matías Galarza. Se les agregó su segundo nombre o apellido: Matías Alejandro Galarza y Matías Galarza Fonda.
- Dos jugadores aparecían con el nombre de Santiago Sosa. Se les agregó su segundo nombre: Santiago Nahuel Sosa y Santiago Leonel Sosa.
- Se agregó segundo nombre a Francisco González para no confundirlo con González Metilli.
- Se corrigió que Benjamín Schamine aparecía en algunos registros con tilde y en otros sin.

Correcciones llevadas a cabo en los nombres de los futbolistas de la base de FBRef para que cada jugador tenga un nombre y apellido único:

- Ezequiel Fernández se renombró como Equi Fernández.
- Matías Gómez se renombró como Matías Nicolás Gómez.
- Julián Fernández se renombró por Julián Rodrigo Fernández.
- Matías Galarza se renombró por Matías Galarza Fonda.
- David González se renombró como Maximiliano González.
- Dos jugadores aparecían con el nombre de Francisco González. Se agregó el segundo nombre a uno de ellos y el segundo apellido al otro: Francisco González Metilli y Francisco Agustín González.
- Dos jugadores aparecían con el nombre de Alan Rodríguez. Se les agregó su segundo nombre: Alan Francisco Rodríguez y Alan Jesús Rodríguez.
- Dos jugadores aparecían con el nombre de Nicolás Fernández. Se los reemplazó por: Uvita Fernández y Nicolás Andrés Fernández.
- Dos jugadores aparecían con el nombre de Tiago Palacios. Se les agregó su segundo nombre: Tiago Tomás Palacios y Tiago Asael Palacios.
- Dos jugadores aparecían con el nombre de Eric Ramírez. Se les agregó su segundo nombre: Eric Iván Ramírez y Eric Kleybel Ramírez.
- Dos jugadores aparecían con el nombre de Santiago Sosa. Se les agregó su segundo nombre: Santiago Nahuel Sosa y Santiago Leonel Sosa.

7.3. Diagnósticos de convergencia de las cadenas

Tabla 11
Estadístico de Gelman-Rubin y número efectivo de muestra para los parámetros del Modelo 1

Parámetro	$\hat{R}$	N_{eff}
α	1,001	3.091
β_1	1,001	2.409
β_2	1,002	2.020
β_3	1,002	2.099

Figura 47
Gráficos de traza de los parámetros del Modelo 1

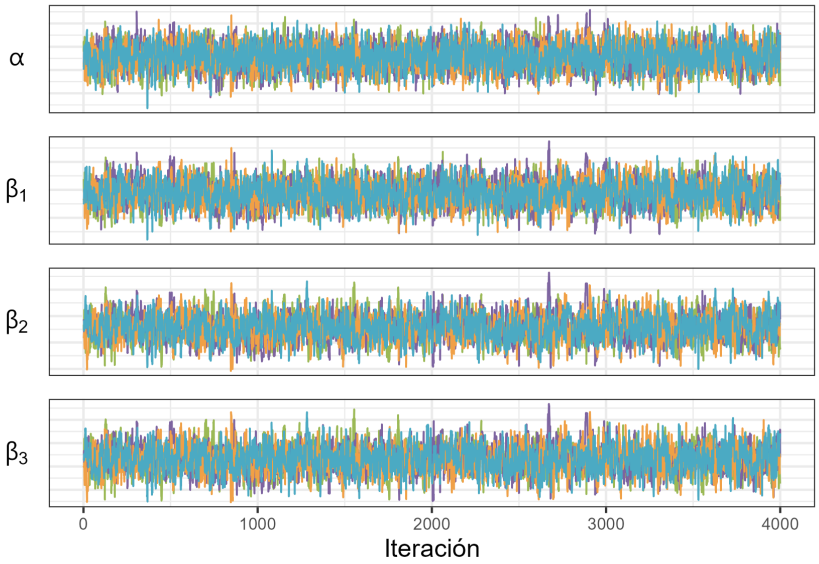


Tabla 12
Estadístico de Gelman-Rubin y número efectivo de muestra para los parámetros del Modelo 2

Parámetro	$\hat{R}$	N_{eff}
α_{DF}	1,001	7.289
α_{MCD}	1,001	7.451
α_{MCO}	1,001	6.007
α_{DL}	1,002	3.497
β_1	1,003	2.327
β_2	1,004	2.038
β_3	1,004	2.121

Figura 48
Gráficos de traza de los parámetros del Modelo 2

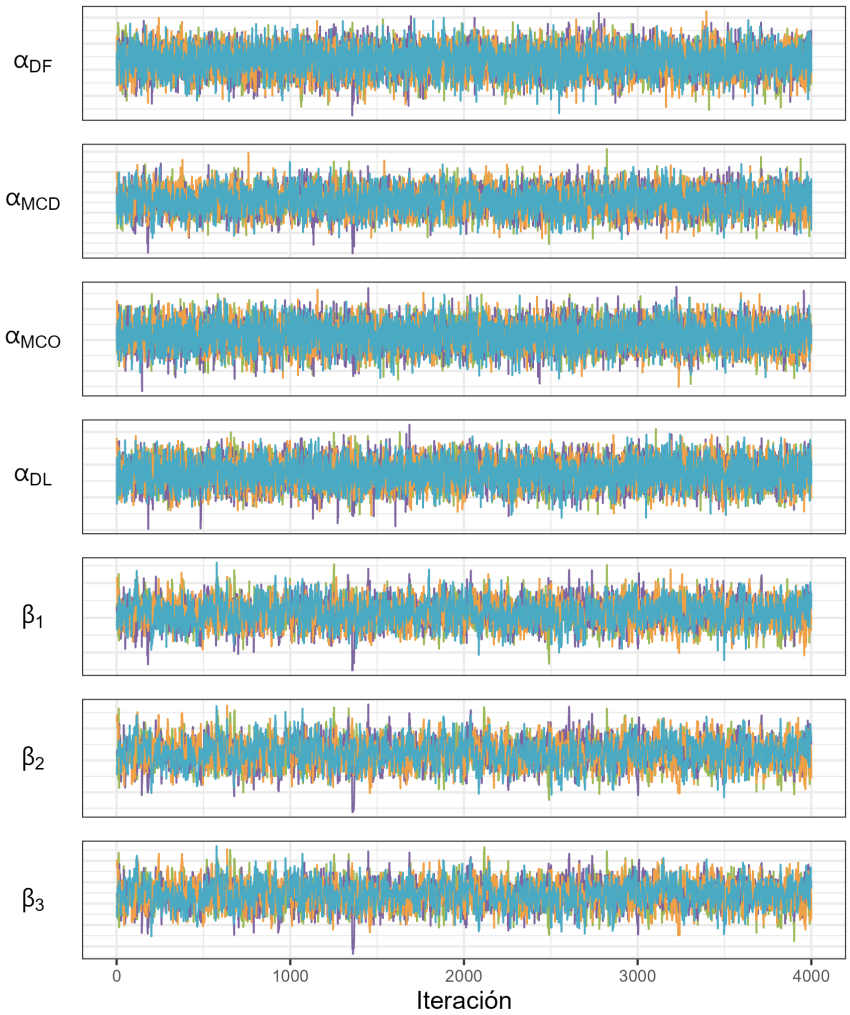
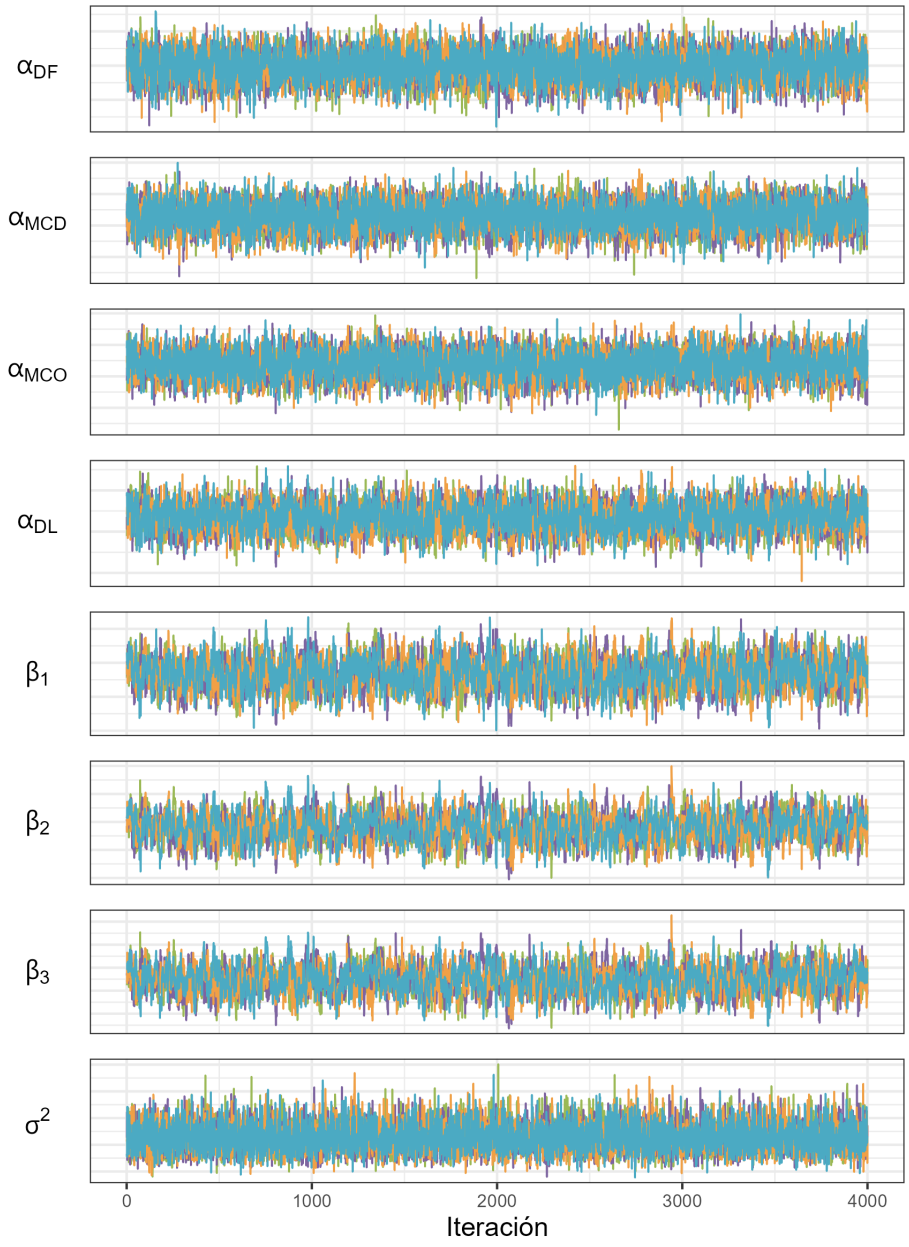


Tabla 13
Estadístico de Gelman-Rubin y número efectivo de muestra para los parámetros asociados a efectos fijos del Modelo 3

Parámetro	$\hat{R}$	N_{eff}
α_{DF}	1,000	5.602
α_{MCD}	1,000	5.670
α_{MCO}	1,000	4.411
α_{DL}	1,000	2.624
β_1	1,001	1.505
β_2	1,001	1.293
β_3	1,001	1.367
σ_u	1,001	8.275

Figura 49

Gráficos de traza de los parámetros asociados a efectos fijos del Modelo 3



7.4. Gráficos del CRPS para los Modelos 1 y 2

Figura 50

CRPS obtenido con el Modelo 1 para cada valor de probabilidad de gol reportado por Stats Perform



Figura 51

CRPS obtenido con el Modelo 2 para cada valor de probabilidad de gol reportado por Stats Perform

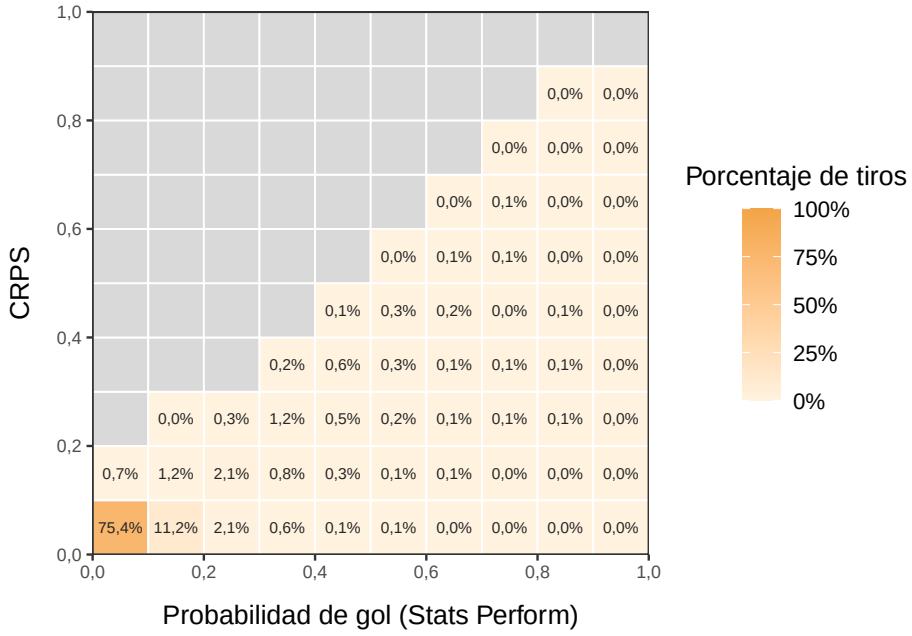


Figura 52
CRPS y Error Medio Absoluto obtenidos con el Modelo 1

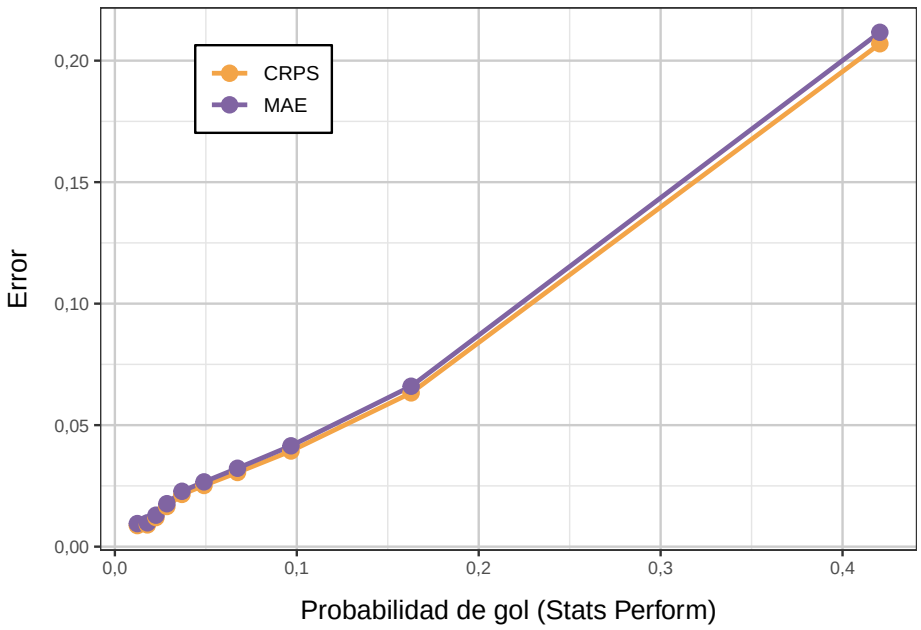
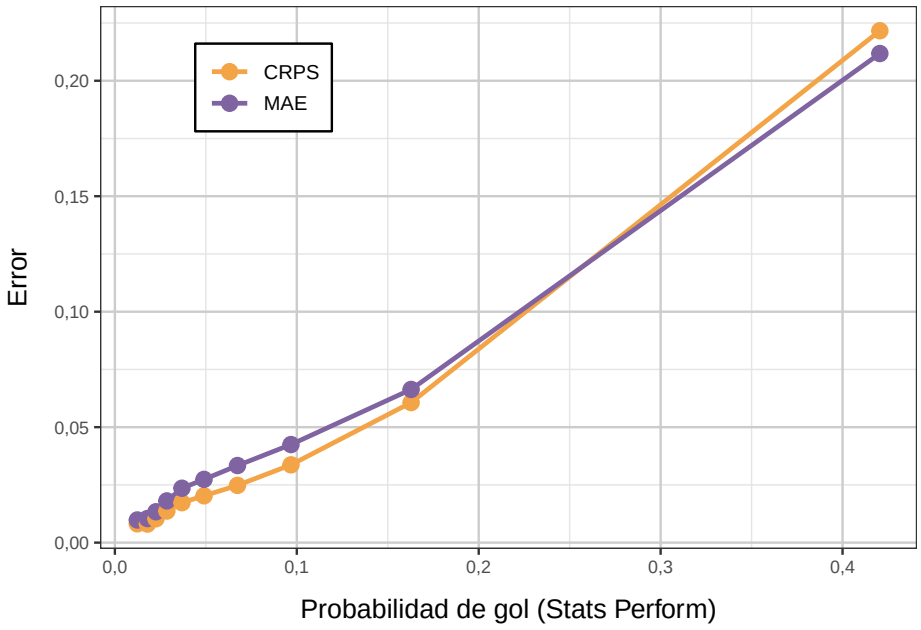


Figura 53
CRPS y Error Medio Absoluto obtenidos con el Modelo 2



8. Bibliografía

Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C. J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C. C., Martin, O. A., Osthege, M., Vieira, R., Wiecki, T., & Zinkov, R. (2023). PyMC: A Modern, and Comprehensive Probabilistic Programming Framework in Python. *PeerJ Computer Science*, *9*, e1516. https://doi.org/10.7717/peerj-cs.1516

Aguirre, J. (2018,). *Primer plano: El big data en el fútbol y cómo lo usan Belgrano, Talleres e Instituto*. https://www.lavoz.com.ar/deportes/futbol/primer-plano-el-big-data-en-el-futbol-y-como-lo-usan-belgrano-talleres-e-instituto/

Anzer, G., Arnsmeyer, K., Bauer, P., Bekkers, J., Brefeld, U., Davis, J., Evans, N., Kempe, M., Robertson, S. J., Smith, J. W., & Van Haaren, J. (2024,). *Common Data Format (CDF): A Standardized Format for Match Data in Football (Soccer)*. https://arxiv.org/abs/2505.15820

Brechot, M., & Flepp, R. (2018). *Dealing with randomness in match outcomes: how to rethink performance evaluation and decision-making in European club football* (UZH Business Working Paper Series No. 374). https://ssrn.com/abstract=3122219

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, *78*(1), 1-3. https://journals.ametsoc.org/view/journals/mwre/78/1/1520-0493_1950_078_0001_vofeit_2_0_co_2.xml

Bürkner, P.-C., Gabry, J., Kay, M., & Vehtari, A. (2020). *Posterior: Tools for Working with Posterior Distributions*. https://mc-stan.org/posterior/

Carey, M. (2024,). *How Data Departments Have Evolved and Spread Across English Football Clubs*. https://www.nytimes.com/athletic/5697684/2024/09/03/football-analytics-uk-evolution/

Catapult. (2024,). *Baseball Analytics: What It Is & How to Win More Games with Data*. https://www.catapult.com/blog/baseball-data-analytics

Conde, M. (2023,). *Todo lo que se pierde Valdano por despreciar el análisis de datos en el fútbol*. https://sport.jotdown.es/2023/todo-lo-que-se-pierde-valdano-por-despreciar-el-analisis-de-datos-en-el-futbol/

Deming, A. (2018,). *Statistics in the Laboratory: Pooling*. https://www.americanlaboratory.com/353521-Statistics-in-the-Laboratory-Pooling/

Durgapal, A., & Rowlinson, A. (2025,). *mplsoccer: Soccer Analytics and Visualisation in Python*. https://mplsoccer.readthedocs.io/

ESPN Argentina. (2025,). *F90*. https://www.infobae.com/deportes/2025/02/12/la-reaccion-de-ruggeri-cuando-escucho-un-analisis-del-dt-martin-anselmi-basado-en-las-estadisticas-que-quilombo-que-tiene-en-la-cabeza/

Evangelista, I., & Capertto, T. (2024). *Apuntes de clase de Estadística Bayesiana*.

Fujii, K. (2025). *Machine Learning in Sports: Open Approach for Next Play Analytics*. Springer. https://link.springer.com/book/10.1007/978-981-96-1445-5

Fédération Internationale de Football Association. (s. f.). *Pitch Dimensions and Surrounding Areas*. https://publications.fifa.com/es/football-stadiums-guidelines/technical-guideline/stadium-guidelines/pitch-dimensions-and-surrounding-areas/

Gantman, M. (2021,). *El fútbol argentino incorpora la inteligencia artificial de Smart Gear*. https://bigdatasports.media/2021/02/02/el-futbol-argentino-incorpora-el-tracking--optico-de-smart-gear/

Gelman, A., & Rubin, D. B. (1992). Inference from Iterative Simulation Using Multiple Sequences. *Statistical Science*, *7*(4), 457-472.

Gneiting, T., & Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, *102*(477), 359-378. https://doi.org/10.1198/016214506000001437

Goodman, M. (2018,). *A New Way to Measure Keepers' Shot Stopping: Post-Shot Expected Goals*. https://statsbomb.com/articles/soccer/a-new-way-to-measure-keepers--shot-stopping-post-shot-expected-goals/

Herranz Martínez, M. (2026). *Sistema de scouting de futbolistas basado en datos: clasificación de estilos de juego y predicción de rentabilidad mediante aprendizaje automático* [Tesis de grado].

Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, *15*, 1593-1623.

Iapteff, L., Le Coz, S., Rioland, M., Houde, T., Carling, C., & Imbach, F. (2025). Toward Interpretable Expected Goals Modeling Using Bayesian Mixed Models. *Frontiers in Sports and Active Living*, *7*, 1504362.

International Football Association Board. (2023,). *Reglas de Juego 2023/24*.

Johnson, A. A., Ott, M. Q., & Dogucu, M. (2021). *Bayes Rules! An Introduction to Applied Bayesian Modeling*. CRC Press. https://www.bayesrulesbook.com/

Jordan, A., Krüger, F., & Lerch, S. (2019). Evaluating Probabilistic Forecasts with scoringRules. *Journal of Statistical Software*, *90*(12). https://doi.org/10.18637/jss.v090.i12

Khder, M. A. (2021). Web Scraping or Web Crawling: State of Art, Techniques, Approaches and Application. *International Journal of Advanced Soft Computing Applications*, *13*(3).

Laio, F., & Tamea, S. (2007). Verification tools for probabilistic forecasts of continuous hydrological variables. *Hydrology and Earth System Sciences*, *11*(4), 1267-1277. https://doi.org/10.5194/hess-11-1267-2007

Lambert, B. (2018). *A Student's Guide to Bayesian Statistics*. SAGE Publications.

Landino, V. (2025, febrero). *How F1 Teams Use Data to Scout Drivers*. Motorsport Week. https://www.motorsportweek.com/2025/02/15/how-f1-teams-use-data-to-scout-drivers/

Liga Profesional de Fútbol. (2023,). *Reglamento de los Torneos de la Liga Profesional de Fútbol de AFA 2023*.

Mead, J., O'Hare, A., & McMenemy, P. (2023). Expected Goals in Football: Improving Model Performance and Demonstrating Value. *PLOS ONE*, *18*(4), e282295. https://doi.org/10.1371/journal.pone.0282295

Mukherjee, S. (2024,). *The Nuances of Expected Goals (xG): Understanding Football's Most Misunderstood and Misused Statistic*. https://medium.com/@drsmukherjee/the-nuances-of--expected-goals-xg-understanding-footballs-most-misunderstood-and-misused-5b85773e9314

NBA Stuffer. (s. f.). *NBA Teams That Have Analytics Department*. https://www.nbastuffer.com/analytics101/nba-teams-that-have-analytics-department/

NBAstuffer. (s. f.). *How NBA Teams Use Advanced Stats to Draft Smarter*. NBAstuffer. https://www.nbastuffer.com/how-nba-teams-use-analytics-to-draft/

Nsolo, E., Lambrix, P., & Carlsson, N. (2019). Player Valuation in European Football. En U. Brefeld, J. Davis, J. Van Haaren, & A. Zimmermann (eds.), *Machine Learning and Data Mining for Sports Analytics: Vol. 11330. Machine Learning and Data Mining for Sports Analytics*. https://doi.org/10.1007/978-3-030-17274-9_4

Rábanos, F. (2024,). *LanusStats*. https://github.com/federicorabanos/LanusStats

Scholtes, A., & Karakuş, O. (2024). Bayes-xG: Player and Position Correction on Expected Goals (xG) Using Bayesian Hierarchical Approach. *Frontiers in Sports and Active Living*, *6*, 1348983. https://doi.org/10.3389/fspor.2024.1348983

Senn, W. (2024). *Addressing Evaluation Challenges on the Expected Goals (xG) Metric in Football Analysis* [Tesis de grado].

SkillCorner. (s. f.). *XY Tracking Data [Football]*. https://www.skillcorner.com/

Sport Analytics. (2025,). *What Teams Are Boosting Their Performance with Data Analysis?*. https://sportanalyticspro.com/football-top-teams/

Stats Perform. (s. f.-b). *Opta Event Definitions*. https://www.statsperform.com/opta-event--definitions/

Stats Perform. (s. f.-a). *Working with Leading Teams, Leagues and Federations*. https://www.statsperform.com/team-performance/performance-solutions-for-football/

Sumpter, D. (2022). *Soccermatics*. Bloomsbury Publishing.

Umemoto, R., & Fujii, K. (2023,). *Evaluation of Team Defense Positioning by Computing Counterfactuals Using StatsBomb 360 Data*. https://statsbomb.com/

Universidad Nacional de La Plata. (2017,). *Incorporarán tecnología informática de la UNLP en el club Gimnasia*. https://unlp.edu.ar/institucional/investigadores_de_la_unlp_incorporaran_tecnologias_informaticas_en_el_club_gimnasia_y_esgrima_la_plata-956--5956/

Vehtari, A., Simpson, D., Carpenter, B., Bürkner, P.-C., & Gelman, A. (2021). Rank-Normalization, Folding, and Localization: An Improved $\hat{R}$ for Assessing Convergence of MCMC. *Bayesian Analysis*, *16*(2), 667-718.

Whitmore, J. (2021,). *What Are Expected Goals on Target (xGOT)?*. https://theanalyst.com/2021/what-are-expected-goals-on-target-xgot/

Whitmore, J. (2023,). *What Is Expected Goals (xG)?*. https://theanalyst.com/articles/what-is--expected-goals-xg